

Chapitre 3. Régression linéaire factorielle

Introduction comprehensive à l'analyse statistique (linéaire) multivariée

École d'ingénieur.e.s en Agronomie & Agroalimentaire - 2e année

Léo Dort

leo.dort@institut-agro.fr

Ressources & Références pour ce chapitre

- Ressource Rmarkdown compagnon : [apollo.Rmd](#) (avec quelques légères modifications.)
- Références principales : Ce cours est tiré du Cours de Sophie Donnet (CR INRAe)
- Livres : Régression avec R (3e édition) de Pierre-André Cornillon, Nicolas Hengartner, Eric Matzner-Lober et Laurent Rouvière

Être quantitative ou ne pas être quantitative ?

- Jusqu'à présent, les variables explicatives étaient quantitatives continues.
- Dans le jeu de données `apollo.Rdata`, des variables explicatives qualitatives ont été mesurées et peuvent apporter un intérêt à l'étude.

Comment intégrer au modèle linéaire des variables qualitatives ?

- Dans ce chapitre, nous allons étudier le cas :
 - d'une seule variable explicative qualitative : analyse de variance à un facteur (et le voir comme une régression linéaire) ;
 - de deux variables explicatives qualitatives : analyse de variance à deux facteurs ; et
 - le cas d'une variable explicative qualitative associée à une variable explicative quantitative : analyse de la covariance.

1. Introduction
2. Analyse de variance à un facteur is back !
3. Analyse de variance à deux facteurs fixes
4. Analyse de la covariance
5. Quelques méthodes de régressions avancées

1. Introduction

2. Analyse de variance à un facteur is back !

(a) Modélisation du problème & Problème régulier

(b) Modèle singulier

(c) Validation du modèle & Comparaison de traitements

3. Analyse de variance à deux facteurs fixes

4. Analyse de la covariance

5. Quelques méthodes de régressions avancées


Contexte (1)

- Le secteur influence-t-il l'abondance du papillon Apollon ?
- La variable sector possède 4 modalités : Champigny, Haut Maurienne, Haute Tarentaise et Pralognan.
- Nous commençons par une représentation graphique des données : ici les boîtes à moustaches semblent la plus pertinente.

Contexte (2)

```
ggplot(apollo) +  
  aes(x = sector, y = logabondance, fill = sector) +  
  geom_boxplot(alpha = 0.25) +  
  geom_jitter(aes(color = sector)) +  
  labs(  
    x = "Secteur",  
    y = "Logarithme de l'abondance"  
  ) +  
  theme(  
    axis.title = element_text(size = 10, color = "grey40"),  
    axis.text = element_text(size = 8),  
    legend.position = "none"  
  )
```

Contexte (3)



- Il semble que le secteur influence l'abondance du papillon Apollon.

1. Introduction

2. Analyse de variance à un facteur is back !

(a) Modélisation du problème & Problème régulier

(b) Modèle singulier

(c) Validation du modèle & Comparaison de traitements

3. Analyse de variance à deux facteurs fixes

4. Analyse de la covariance

5. Quelques méthodes de régressions avancées

Notations

- Supposons que la variable explicative X soit qualitative et qu'elle possède I modalités.

- Chaque modalité i est prise par n_i observations (de sorte que $\sum_{i=1}^I n_i = n$).

- Par exemple, si nous prenons l'ordre alphabétique (Champagny, Haute Maurienne, Haute Tarentaise, Pralognan,), nous avons :


$$n_1 = 22, \quad n_2 = 28, \quad n_3 = 24 \quad \text{et} \quad n_4 = 26.$$

- y_{ij} représente la valeur de la variable à expliquer pour le j -ème individu ayant pris la i -ème modalité.

Modèle régulier

- On suppose que $y_{i,j}$ est la réalisation de variables aléatoires i.i.d. $Y_{i,j}$. Nous cherchons à savoir si le facteur X fait varier la variable Y .
- Le modèle est le suivant :

$$Y_{i,j} = \mu_i + \varepsilon_{i,j}, \quad i \in \{1, \dots, I\}, j \in \{1, \dots, n_i\}$$



- où
 - les variables aléatoires ε_i , appelées erreurs, sont des variables aléatoires i.i.d. de loi $\mathcal{N}(0, \sigma^2)$ de variance σ^2 inconnue ; et
 - les paramètres μ_i sont inconnus et fixes (déterministes).

Modèle régulier & Écriture matricielle

- Posons :

$$X^r = \begin{pmatrix} 1 & & & & \\ \vdots & & & & \\ 1 & & & & \\ & 1 & & & \\ & \vdots & & & \\ & 1 & & & \\ & & \ddots & & \\ & & & \ddots & \\ & & & & 1 \\ & & & & \vdots \\ & & & & 1 \end{pmatrix}, \quad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_I \end{pmatrix} \quad \text{et} \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}.$$

- Alors, nous avons l'écriture matricielle suivante :

$$\mathbf{Y} = X^r \mu + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I_n).$$

- Le modèle est dit régulier car la matrice de design X^r est de rang plein !

Estimations

- Chaque paramètre μ_i est estimé par la moyenne empirique des observations dans la modalité i :

$$\hat{\mu}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{i,j} = \bar{y}_{i,\cdot}.$$

- La valeur ajustée $\hat{y}_{i,j}$ sont alors $\hat{y}_{i,j} = \hat{\mu}_i$.

- La variance inconnue σ^2 s'estime par

$$\hat{\sigma}^2 = \frac{1}{n - I} \sum_{i,j} (y_{i,j} - \hat{\mu}_i)^2.$$

estimateur sans biais

Sous R

```
model <- lm(formula = logabondance ~ -1 + sector,  
            data = apollo)
```

```
summary(model)
```

Call:

```
lm(formula = logabondance ~ -1 + sector, data = apollo)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.6217	-1.1564	0.0049	1.1978	3.5236

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
sectorHauteMaurienne	5.7404	0.3131	18.334	< 2e-16 ***
sectorHauteTarentaise	5.1625	0.3382	15.265	< 2e-16 ***
sectorPralognan	2.2450	0.3249	6.909	5.32e-10 ***
sectorChampagny	4.8132	0.3532	13.627	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.657 on 96 degrees of freedom

Multiple R-squared: 0.8932, Adjusted R-squared: 0.8887

F-statistic: 200.6 on 4 and 96 DF, p-value: < 2.2e-16

Commentaires

- Le test global de Fisher n'a ici que peu d'intérêt !

▸ En effet, il teste :

$$(\mathcal{H}_0) : \mu_1 = \mu_2 = \mu_3 = \mu_4 = 0 \quad \text{contre} \quad (\mathcal{H}_1) : \text{"l'un des } \mu_i \text{ n'est pas nul"}.$$

- La question pertinente est : « la localité du site d'observation influence-t-elle l'abondance du papillon Apollon ? »

- Cette question se traduit par le test suivant :

$$(\mathcal{H}_0) : \mu_1 = \mu_2 = \mu_3 = \mu_4 \quad \text{contre} \quad (\mathcal{H}_1) : \text{"les } \mu_i \text{ ne sont pas tous égaux"}.$$

- Pour répondre à cette question, nous introduisons un effet moyen μ : une ordonnée à l'origine !

1. Introduction

2. Analyse de variance à un facteur is back !

(a) Modélisation du problème & Problème régulier

(b) Modèle singulier

(c) Validation du modèle & Comparaison de traitements

3. Analyse de variance à deux facteurs fixes

4. Analyse de la covariance

5. Quelques méthodes de régressions avancées

Modèle singulier

- On suppose que la variable $y_{i,j}$ est la réalisation d'une variable aléatoire $Y_{i,j}$, avec :

$$Y_{i,j} = \mu + \alpha_i + \varepsilon_{i,j} \quad i \in \{1, \dots, I\}, \quad j \in \{1, \dots, n_i\}.$$

- Nous avons introduit un effet moyen μ .
- Pour chaque i , α_i est l'effet de la i -ème modalité sur la variable à expliquer y par rapport à l'effet moyen :

$$\mu_i = \mu + \alpha_i \quad \text{qui se lit aussi } \alpha_i = \mu_i - \mu.$$

- μ est vu comme un niveau de référence et α_i s'entend comme une différence par rapport au niveau de référence.

Écriture matricielle

- $I + 1$ paramètres à estimer

$$X^s = \begin{pmatrix} 1 & 1 & & & \\ \vdots & \vdots & & & \\ 1 & 1 & & & \\ 1 & & 1 & & \\ \vdots & & \vdots & & \\ 1 & & 1 & & \\ \vdots & & & \ddots & \\ 1 & & & & 1 \\ \vdots & & & & \vdots \\ 1 & & & & 1 \end{pmatrix}.$$

- X^s n'est plus de rang plein, ce qui pose des problèmes d'identifiabilité :
 - I équations $\mu_i = \mu + \alpha_i$, mais $I + 1$ paramètres ...
- Il faut donc introduire une nouvelle contrainte !

Rendre le modèle identifiable en le contraignant

- Contrainte $\mu = 0$: modèle régulier.
- Contrainte $\alpha_1 = 0$: alors $\mu = \mu_1$. L'effet moyen est l'effet de la première modalité.
 - Les autres $\alpha_i = \mu_i - \mu_1$ mesurent donc les différences des autres modalités avec cette modalité de référence.
- Contrainte $\sum_{i=1}^I \alpha_i = 0$: l'effet moyen est alors la moyenne des effets de chaque modalité.
 - Puisque $\forall i = 1, \dots, I, \mu + \alpha_i = \mu_i$ entraîne que $\sum_{i=1}^I \mu + \sum_{i=1}^I \alpha_i = \sum_{i=1}^I \mu_i$. D'où $\mu = \frac{1}{I} \sum_{i=1}^I \mu_i$ sous la contrainte.
- Contrainte linéaire quelconque : en utilisant l'option `contrasts` ou `C(...)`.
- Par défaut, c'est la contrainte $\alpha_1 = 0$ qui est utilisé dans la fonction `lm()`.

Estimation des paramètres du modèle singulier

Contrainte $\alpha_1 = 0$.

- Par identification, $\mu_1 = \mu + \alpha_1$ et alors $\mu_1 = \mu$. Une estimation de μ est alors :

$$\hat{\mu} = \hat{\mu}_1 = \frac{1}{n_1} \sum_{j=1}^{n_1} y_{1,j} = \bar{y}_{1,.} .$$

- De même, $\mu_2 = \mu + \alpha_2$ ou autrement écrit $\alpha_2 = \mu_2 - \mu$. Une estimation de α_2 est alors :

$$\hat{\alpha}_2 = \hat{\mu}_2 - \hat{\mu} = \frac{1}{n_2} \sum_{j=1}^{n_2} y_{2,j} - \frac{1}{n_1} \sum_{j=1}^{n_1} y_{1,j} = \bar{y}_{2,.} - \bar{y}_{1,.} .$$

- De la même manière, pour tout $i = 2, \dots, I$, $\mu_i = \mu + \alpha_i$ ou autrement écrit $\alpha_i = \mu_i - \mu$. Une estimation de α_i est alors :

$$\hat{\alpha}_i = \hat{\mu}_i - \hat{\mu} = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{i,j} - \frac{1}{n_1} \sum_{j=1}^{n_1} y_{1,j} = \bar{y}_{i,.} - \bar{y}_{1,.} .$$

Commentaires

- Si on change de contrainte, on change d'interprétation !
 - Mêmes résultats en terme de prédiction et de tests, quelque soit l'écriture du modèle.
 - La différence est dans l'interprétation des coefficients et donc des tests.
- Exemple pour la contrainte $\alpha_1 = 0$:
 - Coefficient de l'intercept = effet de la première modalité.
 - Autres coefficients = différences d'effet avec cette première modalité.
 - Le test de Fisher associé à ce modèle a pour hypothèse :
$$(\mathcal{H}_0) : \alpha_2 = \alpha_3 = \dots = \alpha_I = 0 \quad \text{contre} \quad (\mathcal{H}_1) : \exists i \in \{2, \dots, I\}, \alpha_i \neq 0 .$$
 - Ce qui correspond donc bien à l'égalité des effets de chaque modalité.

- Vérifions avec le test global de Fisher l'influence du secteur sur l'abondance du papillon Apollon.

```
model <- lm(formula = logabondance ~ sector,
             data = apollo)
```

```
summary(model)
```

- La p -valeur du test de Fisher est très basse ($3.075e-11$), on rejette donc ($\mathcal{H}_0$) : nous pouvons conclure, au risque d'erreur de 1ère espèce de 5% (par exemple), que le secteur influence l'abondance du papillon Apollon.

Call:

```
lm(formula = logabondance ~ sector, data = apollo)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.6217	-1.1564	0.0049	1.1978	3.5236

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	5.7404	0.3131	18.334	< 2e-16	***
sectorHauteTarentaise	-0.5779	0.4609	-1.254	0.2130	
sectorPralognan	-3.4954	0.4512	-7.746	9.74e-12	***
sectorChampagny	-0.9271	0.4720	-1.964	0.0524	.

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.657 on 96 degrees of freedom

Multiple R-squared: 0.4163, Adjusted R-squared: 0.3981

F-statistic: 22.83 on 3 and 96 DF, p-value: 3.075e-11

Commentaires

- Nous obtenons les mêmes résultats entre les deux contraintes $\mu = 0$ et $\alpha_1 = 0$.
- Nous pouvons (facilement) retrouver les résultats de la première sortie sous la contrainte $\mu = 0$:

Coefficients:

	Estimate
sectorHauteMaurienne	5.7404
sectorHauteTarentaise	5.1625
sectorPralognan	2.2450
sectorChampagny	4.8132

à partir des résultats de la seconde sous la contrainte $\alpha_1 = 0$:

Coefficients:

	Estimate
(Intercept)	5.7404
sectorHauteTarentaise	-0.5779
sectorPralognan	-3.4954
sectorChampagny	-0.9271

Changement de contraintes

- Si on change de contrainte, on change d'interprétation.
- Pour prendre la seconde modalité comme référence :

```
lm(formula = logabondance ~ C(sector, base = 2), data = apollo)
```

- Si nous voulons utiliser la contrainte $\sum_{i=1}^I \alpha_i = 0$, il suffit d'utiliser la commande :

```
lm(formula = logabondance ~ C(sector, sum), data = apollo)
```

1. Introduction

2. Analyse de variance à un facteur is back !

(a) Modélisation du problème & Problème régulier

(b) Modèle singulier

(c) Validation du modèle & Comparaison de traitements

3. Analyse de variance à deux facteurs fixes


4. Analyse de la covariance

5. Quelques méthodes de régressions avancées

Analyses des résidus & Tests multiples

- Nous renvoyons à l'analyse des résidus concernant la régression linéaire multiple.

```
par(mfrow = c(2,2))
plot(model)
```



- Pour comparer les traitements, nous renvoyons au cours introductif aux tests statistiques de 1ère année pour tout ce qui concerne les tests multiples.

```
pairwise.t.test(apollo$logabondance, apollo$sector,
                p.adj.sut.method = "bonferroni")
```

	HauteMaurienne	HauteTarentaise	Pralognan
HauteTarentaise	1.00	-	-
Pralognan	5.8e-11	7.7e-08	-
Champagny	0.31	1.00	3.6e-06

P value adjustment method: bonferroni

Test de Student 2 à 2 avec correction de Bonferroni

1. Introduction
2. Analyse de variance à un facteur is back !
3. Analyse de variance à deux facteurs fixes
 - (a) Modèle régulier & Modèle singulier
 - (b) Validation du modèle & Test du modèle
 - (c) Tests des facteurs
 - (d) Analyse de variance à 3 facteurs
4. Analyse de la covariance
5. Quelques méthodes de régressions avancées

1. Introduction
2. Analyse de variance à un facteur is back !
3. Analyse de variance à deux facteurs fixes
 - (a) Modèle régulier & Modèle singulier
 - (b) Validation du modèle & Test du modèle
 - (c) Tests des facteurs
 - (d) Analyse de variance à 3 facteurs
4. Analyse de la covariance
5. Quelques méthodes de régressions avancées

Contexte

- Deux facteurs : nous modélisons l'abondance du papillon Apollo par le secteurs (2 modalités) et le mode de gestion du site (2 modalités).
- Nous pourrions généraliser les résultats à un nombre quelconque de facteurs.
 - Afin d'alléger les notations, nous nous restreignons au cas de deux facteurs.

Modélisation

- Supposons que le premier facteur ait I modalités et le second J modalités.
- $y_{i,j,k}$: la k -ème observation dans les modalités i pour le premier facteur et j pour le deuxième facteur.
- Supposons que nous disposions de $n_{i,j}$ observations pour les modalités i et j .
- $y_{i,j,k}$ est la réalisation d'une variable aléatoire $Y_{i,j,k}$ suivant le modèle :

$$Y_{i,j,k} = \mu_{i,j} + \varepsilon_{i,j,k}, \quad k \in \{1, \dots, n_{i,j}\}, i \in \{1, \dots, I\}, j \in \{1, \dots, J\},$$

- où
 - les erreurs $\varepsilon_{i,j,k} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$; et
 - les paramètres $\mu_{i,j}$ sont inconnus et fixes (déterministes).

Estimation des paramètres du modèle régulier

- Posons

$$\bar{y}_{i,j,\cdot} = \frac{1}{n_{i,j}} \sum_{k=1}^{n_{i,j}} y_{i,j,k}$$

la moyenne des valeurs y sur les observations ayant pris la modalité j pour le premier facteur et la modalité j pour le second facteur.

Proposition

$$\hat{\mu}_{i,j} = \bar{y}_{i,j,\cdot} .$$

- Par conséquent, une estimation de la variance inconnue σ^2 est obtenue par :

$$\hat{\sigma}^2 = \frac{1}{n - IJ} \sum_{i,j,k} (y_{i,j,k} - \hat{\mu}_{i,j})^2 .$$

Modèle singulier

- Pour mieux analyser l'influence des facteurs, nous considérons la décomposition suivante de la moyenne $\mu_{i,j}$ inconnue :

$$\mu_{i,j} = \mu + \alpha_i + \beta_j + \gamma_{i,j}.$$

- Cette écriture n'est pas unique !
- $I \times J$ paramètres $\mu_{i,j}$ décomposés en $1 + I + J + I \times J$ nouveaux paramètres !
 - $1 + I + J$ paramètres de plus (à estimer) ...
 - Il faut donc imposer $1 + I + J$ contraintes linéaires indépendantes.

Contraintes classiques

- Contrainte de type analyse par cellule = modèle régulier :

$$\mu = 0, \quad \forall i \in \{1, \dots, I\}, \alpha_i = 0, \quad \forall j \in \{1, \dots, J\}, \beta_j = 0 ,$$

- Contrainte de type cellule de référence : Contrainte par défaut sous $\mathcal{R}$

$$\alpha_1 = 0, \quad \beta_1 = 0, \quad \forall j \in \{1, \dots, J\}, \gamma_{1,j} = 0, \quad \forall i \in \{1, \dots, I\}, \gamma_{i,1} = 0 ,$$

- Contrainte de type « somme » :

$$\sum_{i=1}^I \alpha_i = 0, \quad \sum_{j=1}^J \beta_j = 0, \quad \forall j \in \{1, \dots, J\}, \sum_{i=1}^I \gamma_{i,j} = 0, \quad \forall i \in \{1, \dots, I\}, \sum_{j=1}^J \gamma_{i,j} = 0 ,$$

Interprétation des nouveaux coefficients

$$\mu_{i,j} = \mu + \alpha_i + \beta_j + \gamma_{i,j}$$

- α_i : effet principal de la modalité i du premier facteur
- β_j : effet principal de la modalité j du second facteur
- $\gamma_{i,j}$: effet d'interaction entre les modalités i et j du premier et second facteur resp.
- μ : effet moyen (dépendant comme précédemment des contraintes imposées)

Sous R (1)

```
model1 <- lm(logabondance ~ sector * grazing,  
             data = apollo)  
  
summary(model1)
```

- Nous trouvons les mêmes résultats en utilisant la formule :

```
lm(logabondance ~ sector + grazing + sector:grazing, data = apollo)
```

Sous R (2)

Call:

```
lm(formula = logabondance ~ sector + grazing + sector:grazing,  
    data = apollo)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.4335	-0.9944	-0.0247	1.0360	4.0229

- Facteur 1 : sector

- ▶ Modalité 1 : HauteMaurienne

- Facteur 2 : grazing

- ▶ Modalité 1 : ungrazed

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.24112	0.45860	11.428	< 2e-16 ***
sectorHauteTarentaise	-0.26685	0.69550	-0.384	0.7021
sectorPralognan	-2.89820	0.60184	-4.816	5.75e-06 ***
sectorChampagny	-0.04095	0.64856	-0.063	0.9498
grazinggrazed	0.93192	0.62657	1.487	0.1403
sectorHauteTarentaise:grazinggrazed	-0.60923	0.92806	-0.656	0.5132
sectorPralognan:grazinggrazed	-1.25024	0.94141	-1.328	0.1874
sectorChampagny:grazinggrazed	-1.87774	0.95221	-1.972	0.0516 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.654 on 92 degrees of freedom

Multiple R-squared: 0.4429, Adjusted R-squared: 0.4005



F-statistic: 10.45 on 7 and 92 DF, p-value: 1.364e-09

1. Introduction
2. Analyse de variance à un facteur is back !
3. Analyse de variance à deux facteurs fixes
 - (a) Modèle régulier & Modèle singulier
 - (b) Validation du modèle & Test du modèle
 - (c) Tests des facteurs
 - (d) Analyse de variance à 3 facteurs
4. Analyse de la covariance
5. Quelques méthodes de régressions avancées



Analyse des résidus

- Nous renvoyons à l'analyse des résidus concernant la régression linéaire multiple.

```
par(mfrow = c(2,2))  
plot(model1)
```



- Ici, il ne semble n'y avoir aucune obstruction aux postulats [P1]-[P4] de validation des résidus.



Test du modèle

- Le test de la pertinence du modèle teste les hypothèses suivantes :

$$(\mathcal{H}_0) : Y_{i,j,k} = \mu + \varepsilon_{i,j,k} \quad \text{contre} \quad (\mathcal{H}_1) : Y_{i,j,k} = \mu + \alpha_i + \beta_j + \gamma_{i,j,k} + \varepsilon_{i,j,k} .$$

- Le résultat est donné directement dans la sortie `summary`.

Call:

```
lm(formula = logabondance ~ sector + grazing + sector:grazing,  
    data = apollo)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.4335	-0.9944	-0.0247	1.0360	4.0229

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.24112	0.45860	11.428	< 2e-16 ***
sectorHauteTarentaise	-0.26685	0.69550	-0.384	0.7021
sectorPralognan	-2.89820	0.60184	-4.816	5.75e-06 ***
sectorChampagny	-0.04095	0.64856	-0.063	0.9498
grazinggrazed	0.93192	0.62657	1.487	0.1403
sectorHauteTarentaise:grazinggrazed	-0.60923	0.92806	-0.656	0.5132
sectorPralognan:grazinggrazed	-1.25024	0.94141	-1.328	0.1874
sectorChampagny:grazinggrazed	-1.87774	0.95221	-1.972	0.0516 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.654 on 92 degrees of freedom

Multiple R-squared: 0.4429, Adjusted R-squared: 0.4005

F-statistic: 10.45 on 7 and 92 DF, p-value: 1.364e-09

- La p -valeur du test global de Fisher est $1.364e-09$, donc au risque d'erreur de 1ère espèce de 5% nous rejetons $(\mathcal{H}_0)$: au moins l'un des facteurs a une influence sur l'abondance du papillon Apollon (c'est-à-dire qu'au moins un des α_i et/ou β_j et/ou $\gamma_{i,j}$ est non nul).

Une collection de modèles

$$\mathcal{M}_{\mu} \quad : \quad \mathbf{Y}_{i,j,k} = \mu + \boldsymbol{\varepsilon}_{i,j,k}$$

$$\mathcal{M}_{\mu,\alpha} \quad : \quad \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \boldsymbol{\varepsilon}_{i,j,k}$$

$$\mathcal{M}_{\mu,\beta} \quad : \quad \mathbf{Y}_{i,j,k} = \mu + \beta_j + \boldsymbol{\varepsilon}_{i,j,k}$$

$$\mathcal{M}_{\mu,\alpha,\beta} \quad : \quad \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \beta_j + \boldsymbol{\varepsilon}_{i,j,k}$$

$$\mathcal{M}_{\alpha,\beta,\mu,\gamma} \quad : \quad \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \beta_j + \gamma_{i,j} + \boldsymbol{\varepsilon}_{i,j,k}$$

- $\mathcal{M}_{\mu,\alpha,\beta,\gamma}$: modèle complet.

- Prend en compte tous les phénomènes, mais comporte beaucoup de paramètres.

- $\mathcal{M}_{\mu,\alpha,\beta}$: modèle additif.

- Il suppose l'absence d'interaction entre les facteurs.

Test des interactions

- Avant de réaliser des tests sur l'influence des facteurs pris indépendamment, il est important de tester l'interaction de ces derniers.

- Le test est le suivant :

$$(\mathcal{H}_0) : Y_{i,j,k} = \mu + \alpha_i + \beta_j + \varepsilon_{i,j,k} \quad \text{contre} \quad (\mathcal{H}_1) : Y_{i,j,k} = \mu + \alpha_i + \beta_j + \gamma_{i,j} + \varepsilon_{i,j,k} .$$

- Il s'agit d'un test de modèles emboîtés (ou sous-modèles) : on réalise donc un test de Fisher (de comparaison de modèles).

- ▶ La statistique de test est :

$$F = \frac{\frac{1}{\text{rg}(X^{(\mu,\alpha,\beta,\gamma)}) - \text{rg}(X^{(\mu,\alpha,\beta)})} (\text{SCR}_{\mu,\alpha,\beta} - \text{SCR}_{\mu,\alpha,\beta,\gamma})}{\frac{1}{n - \text{rg}(X^{(\mu,\alpha,\beta,\gamma)})} \text{SCR}_{\mu,\alpha,\beta,\gamma}} ,$$

- ▶ Sous $(\mathcal{H}_0)$, $F \sim \mathcal{F}((I-1)(J-1), n-IJ)$, et on rejette $(\mathcal{H}_0)$ au seuil de 1ère espèce α si $F > q_{1-\alpha}^{\mathcal{F}((I-1)(J-1), n-IJ)}$.

```
model2 <- lm(logabondance ~ sector + grazing,
             data = apollo)
```

```
anova(model1, model2)
```

Analysis of Variance Table

Model 1: logabondance ~ sector * grazing

Model 2: logabondance ~ sector + grazing

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	92	251.54				
2	95	263.41	-3	-11.869	1.447	0.2343


- La p -valeur du test est élevée : au risque d'erreur de 1ère espèce de 5%, on ne peut pas conclure qu'il y a une interaction.
- Nous considérons donc dans la suite qu'il n'y a pas d'interaction, et nous sommes ramenés au modèle :

$$Y_{i,j,k} = \mu + \alpha_i + \beta_j + \epsilon_{i,j,k} .$$

1. Introduction
2. Analyse de variance à un facteur is back !
3. Analyse de variance à deux facteurs fixes
 - (a) Modèle régulier & Modèle singulier
 - (b) Validation du modèle & Test du modèle
 - (c) Tests des facteurs
 - (d) Analyse de variance à 3 facteurs
4. Analyse de la covariance
5. Quelques méthodes de régressions avancées

Tests des facteurs (1)

- Si nous avons pu enlever l'interaction, alors nous définissons le modèle sans interaction et nous testons l'effet de chaque facteur restant.



- Si le test des interactions rejette l'hypothèse nulle, alors il n'y a pas de sens à tester les facteurs séparément ! (Il ne peut y avoir d'interaction entre les facteurs sans les facteurs.)

Tests des facteurs (2)

- Dans l'exemple du jeu de données apollo, nous souhaitons savoir si la variable grazing est pertinente dans le modèle model2.
- Nous souhaitons donc comparer les deux modèles :

$$\mathcal{M}_{\mu,\alpha,\beta} : \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \beta_j + \epsilon_{i,j,k} \quad \text{et} \quad \mathcal{M}_{\mu,\alpha} : \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \epsilon_{i,j,k} .$$

```
model3 <- lm(logabondance ~ sector,  
             data = apollo)  
  
anova(model3, model2)
```

Tests des facteurs (3)

Analysis of Variance Table

Model 1: logabondance ~ sector

Model 2: logabondance ~ sector + grazing

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	96	263.51				
2	95	263.41	1	0.10548	0.038	0.8458

- La p -valeur du test est élevée : au risque d'erreur de 1ère espèce de 5%, on ne peut pas conclure que le mode de gestion a une influence sur l'abondance du papillon Apollon.
- Nous considérons donc dans la suite le modèle $\mathcal{M}_{\mu, \alpha}$ sans le second facteur :

$$Y_{i,j,k} = \mu + \alpha_i + \epsilon_{i,j,k} .$$

Tests des facteurs (4)

- Nous pouvons ensuite tester l'influence de la variable sector sur l'abondance du papillon Apollon dans le modèle model3.
- Puisque le modèle model3 retenu correspond à $\mathcal{M}_{\mu,\alpha}$, il s'agit donc de réaliser une analyse de variance à un facteur.
- Nous renvoyons à la partie sur l'analyse de variance à un facteur pour conclure sur la pertinence de ce facteur et à cette diapositive pour l'analyse sous R.

Tests des facteurs (5)

- Si nous avions précédemment, conclut que le facteur grazing influençait la variable d'intérêt, nous aurions comparé les modèles :

$$\mathcal{M}_{\mu,\alpha,\beta} : Y_{i,j,k} = \mu + \alpha_i + \beta_j + \varepsilon_{i,j,k} \quad \text{et} \quad \mathcal{M}_{\mu,\beta} : Y_{i,j,k} = \mu + \beta_j + \varepsilon_{i,j,k} .$$

```
model4 <- lm(logabondance ~ grazing,  
             data = apollo)
```

```
anova(model4, model3)
```

Analysis of Variance Table

Model 1: logabondance ~ grazing

Model 2: logabondance ~ sector

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	98	442.73				
2	96	263.51	2	179.22	32.645	1.527e-11 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

La p -valeur étant très faible, nous aurions au risque d'erreur de 5%, que le facteur sector influence la variable d'intérêt, c'est-à-dire que nous aurions conservé le modèle $\mathcal{M}_{\mu,\alpha,\beta}$.

1. Introduction
2. Analyse de variance à un facteur is back !
3. Analyse de variance à deux facteurs fixes
 - (a) Modèle régulier & Modèle singulier
 - (b) Validation du modèle & Test du modèle
 - (c) Tests des facteurs
 - (d) Analyse de variance à 3 facteurs
4. Analyse de la covariance
5. Quelques méthodes de régressions avancées

Passage à 3 facteurs ?

- Si nous souhaitons faire une ANOVA à 3 facteurs, nous procéderons de la même façon.
- Le modèle s'écrit alors de la manière suivante :

$$Y_{i,j,k,l} = \mu + \alpha_i + \beta_j + \gamma_k + \delta_{i,j} + \zeta_{i,k} + \eta_{j,k} + \theta_{i,j,k} + \varepsilon_{i,j,k,l} .$$

Effets des facteurs

Effets des interactions
2 à 2

Effet de l'interaction
des 3 facteurs

1. Introduction
2. Analyse de variance à un facteur is back !
3. Analyse de variance à deux facteurs fixes
4. Analyse de la covariance
 - (a) Modèle
 - (b) Inférence
5. Quelques méthodes de régressions linéaires factorielles avancées

1. Introduction
2. Analyse de variance à un facteur is back !
3. Analyse de variance à deux facteurs fixes
4. Analyse de la covariance
 - (a) Modèle
 - (b) Inférence
5. Quelques méthodes de régressions linéaires factorielles avancées

Contexte

- Analyse de la covariance : mélange de variables explicatives quantitatives et qualitatives
- Exemple avec une variable explicative quantitative x et un facteur :
 - s'il y a I modalités pour le facteur ;
 - s'il y a n_i observations pour la i -ème modalité ;
 - alors pour tout $i \in \{1, \dots, I\}$, nous rassemblons ces n_i observations :
 - $(y_{i,j})_{1 \leq j \leq n_i}$ pour la variable d'intérêt y ; ainsi que
 - $(x_{i,j})_{1 \leq j \leq n_i}$ pour la variable explicative quantitative x .
- Nous avons alors, possiblement, une régression sur la variable quantitative x différente selon les niveaux du facteur !

Illustration (1)





Illustration (2)




Modèle

- Nous supposons que $y_{i,j}$ est la réalisation d'une variable aléatoire $Y_{i,j}$ avec :

$$Y_{i,j} = b_i + a_i x_{i,j} + \varepsilon_{i,j}, \quad i \in \{1, \dots, I\}, j \in \{1, \dots, n_i\},$$

où

- Les erreurs $\varepsilon_{i,j,k} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$; et
 - Les paramètres a_i, b_i sont inconnus et fixes (déterministes).
- Cela correspond au modèle complet (le plus complexe) :
 - il y a autant de droites de régression que de modalités du facteur.



- Vigilance ! Le σ^2 est commun à toutes les données.

Modèle singulier

• Le modèle singulier

$$Y_{i,j} = b_i + a_i x_{i,j} + \epsilon_{i,j}, \quad i \in \{1, \dots, I\}, j \in \{1, \dots, n_i\},$$

peut se réécrire sous la forme suivante :


$$Y_{i,j} = (\mu + \beta_i) + (\alpha + \gamma_i) x_{i,j} + \epsilon_{i,j}, \quad i \in \{1, \dots, I\}, j \in \{1, \dots, n_i\},$$

où :

- $\gamma_{i,j}$ est l'interaction entre le facteur et la variable explicative quantitative.

Sous-modèles (1)

- Plusieurs cas de figures peuvent se présenter !



Sous-modèles (2)

A. Modèle complet : $Y_{i,j} = \mu + \beta_i + (\alpha + \gamma_i) x_{i,j} + \varepsilon_{i,j}$.

B. Modèle additif = modèle à interactions nulles :

$$Y_{i,j} = \mu + \beta_i + \alpha x_{i,j} + \varepsilon_{i,j} .$$

C. $\beta_i = 0$ pour tout i = les pentes sont différentes, mais même ordonnée à l'origine :

$$Y_{i,j} = \mu + (\alpha + \gamma_i) x_{i,j} + \varepsilon_{i,j} .$$

D. $\beta_i = \gamma_i = 0$ pour tout i = le facteur n'a pas d'effet :

$$Y_{i,j} = \mu + \alpha x_{i,j} + \varepsilon_{i,j} .$$

E. $\alpha_i = \gamma_i = 0$ = la covariable n'a pas d'effet :

$$Y_{i,j} = \mu + \beta_i + \varepsilon_{i,j} .$$

F. Modèle nul = $\beta_i = \alpha_i = \gamma_i = 0$:

$$Y_{i,j} = \mu + \varepsilon_{i,j} .$$

1. Introduction
2. Analyse de variance à un facteur is back !
3. Analyse de variance à deux facteurs fixes
4. Analyse de la covariance
 - (a) Modèle
 - (b) Inférence
5. Quelques méthodes de régressions linéaires factorielles avancées

Inférence (1)

- Toute l'inférence se passe de la même manière que précédemment.
 - Nous pouvons montrer que les estimateurs des moindres carrés des paramètres (a_i, b_i) sont obtenus en faisant la régression de y contre la variable x pour les données de la modalité i .
 - Les paramètres du modèle singulier sont non-identifiables.
 - Il faut imposer des contraintes.
 - R impose comme attendu $\beta_1 = \gamma_1 = 0$.
 - Nous obtenons l'estimation des paramètres du modèle singulier à partir de celle des (a_i, b_i) .

Inférence (2)

- Notons la valeur ajustée

$$\hat{y}_{i,j} = \hat{b}_i + \hat{a}_i x_{i,j} .$$

- Alors la variance σ^2 est estimée sans biais par :

$$\hat{\sigma}^2 = \frac{1}{n - 2I} \sum_{i=1}^I \sum_{j=1}^{n_i} (y_{i,j} - \hat{y}_{i,j})^2 .$$

- Les tests du facteur et de la covariance seront effectués en comparant les SCR des différents modèles en compétition.
 - Nous prendrons en compte le nombre de paramètres dans chaque modèle.
 - Nous pouvons utiliser la fonction `anova`.

Sous R : Modèle d'Ancova & Test de l'interaction

```
anco1 <- lm(logabondance ~ orientation_index * sector,  
            data = apollo)
```

```
summary(anco1)
```

Call:

```
lm(formula = logabondance ~ altitude_index * sector, data = apollo)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.8249	-0.9039	0.0444	0.8614	3.9202

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	10.6118544	1.3182272	8.050	2.83e-12	***
altitude_index	-0.0025702	0.0006849	-3.753	0.000306	***
sectorHauteTarentaise	3.2032243	1.9643181	1.631	0.106371	
sectorPralognan	0.3716806	2.1691158	0.171	0.864324	
sectorChampagny	-1.0896893	1.9813950	-0.550	0.583679	
altitude_index:sectorHauteTarentaise	-0.0016701	0.0009817	-1.701	0.092278	.
altitude_index:sectorPralognan	-0.0009785	0.0009742	-1.004	0.317832	
altitude_index:sectorChampagny	0.0002226	0.0009982	0.223	0.823991	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.213 on 92 degrees of freedom

Multiple R-squared: 0.7002, Adjusted R-squared: 0.6774

F-statistic: 30.7 on 7 and 92 DF, p-value: < 2.2e-16

- Il est possible de tester la significativité des coefficients d'interaction.
- Il suffit de regarder la p -valeur des correspondants au coefficient des termes d'interactions.

Modèle sans interaction & Test

```
anco2 <- lm(logabondance ~ orientation_index + sector,  
            data = apollo)
```

```
anova(anco2, anco1)
```

Analysis of Variance Table

Model 1: logabondance ~ altitude_index + sector

Model 2: logabondance ~ altitude_index * sector

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	95	142.21				
2	92	135.34	3	6.8598	1.5543	0.2059

- Le test de l'interaction du facteur et de la variable quantitative peut également se faire via la fonction `anova` (vu précédemment).
- Ici la p -valeur est élevée (0.2059), donc au risque d'erreur de 1ère de 5% nous ne rejetons pas ($\mathcal{H}_0$) : nous ne pouvons pas conclure qu'il y a une interaction.

Test de l'effet du facteur après ajustement de la covariable

- Une fois la non-interaction des variables établie, nous pouvons tester l'effet du facteur (et de la variable explicative quantitative).
- Une nouvelle fois, ce test peut se réaliser via la fonction `anova`.

```
anova(anco2)
```

Analysis of Variance Table

Response: logabondance

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
altitude_index	1	275.089	275.089	183.7740	< 2.2e-16	***
sector	3	34.191	11.397	7.6137	0.000129	***
Residuals	95	142.205	1.497			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

- La p -valeur du test d'effet de la variable facteur est très basse (0.000129), alors avec un risque d'erreur de 1ère espèce de 5%, nous pouvons conclure que le secteur a un effet sur l'abondance du papillon Apollon.

1. Introduction
2. Analyse de variance à un facteur is back !
3. Analyse de variance à deux facteurs fixes
4. Analyse de covariance
5. Quelques méthodes de régressions avancées

D'autres modèles à explorer

- Modèles linéaires non gaussien : Modèles linéaires généralisés (glm)
 - Régression logistique, Régression de Poisson, etc.
- Modèles linéaires mixtes (généralisés)
- Modèles de régression non-linéaires

This is the end of this chapter !

What will we do next time ?

Partie II. Réduction de dimension

Remarque sur la décomposition de variance

- En utilisant la décomposition :

$$y_{i,j} - \bar{y} = y_{i,j} - \bar{y}_i + \bar{y}_i - \bar{y} ,$$

nous pouvons montrer que :

$$\underbrace{\sum_{i,j} (y_{i,j} - \bar{y})^2}_{\text{Variation totale}} = \underbrace{\sum_{i=1}^I n_i (\bar{y}_i - \bar{y})^2}_{\text{Variation inter-groupes}} + \underbrace{\sum_{i,j} (y_{i,j} - \bar{y}_i)^2}_{\text{Variation intra-groupes}} ,$$

C'est la formule : SCT = SCM + SCR