

Extrait de « La Mathématique du Chat de Philippe Geluck »
de Daniel Justens
Disponible à Médiadoc



Chapitre 2. Régression linéaire multiple

Introduction comprehensive à l'analyse statistique (linéaire) multivariée

École d'ingénieur.e.s en Agronomie & Agroalimentaire - 2e année

Léo Dort

leo.dort@institut-agro.fr

Ressources & Références pour ce chapitre

- Ressource Rmarkdown compagnon : [apollo.Rmd](#)
(avec quelques légères modifications.)
- Références principales : Ce cours est tiré du Cours de Sophie Donnet (CR INRAe)
- Livres : Régression avec R (3e édition) de Pierre-André Cornillon, Nicolas Hengartner, Eric Matzner-Lober et Laurent Rouvière

Exemple compagnon du chapitre : Données

(Données inspirées d'un exemple issu d'un cours de Cathrine Mathias.)

Données écologiques du papillon *Parnassius apollo*

Le jeu de données *apollo* possède 100 lignes et 6 colonnes décrivant plusieurs variables environnementales, dans le cadre d'un suivi de population mené dans le Parc national de la Vanoise.

```
load('apollo.Rdata')
```

```
head(apollo)
```

	humidity_index <dbl>	altitude_index <dbl>	orientation_index <dbl>	logabondance <dbl>	sector <fctr>	grazing <fctr>
1	9.694338	1925.76	1.9667860	2.5121862	Pralognan	grazed
2	10.689511	1882.72	2.8300227	3.6229736	Pralognan	grazed
3	11.298474	1967.84	1.0720735	8.3132629	HauteTarentaise	ungrazed
4	11.198018	1804.16	0.2104998	6.8623379	HauteTarentaise	grazed
5	11.253549	2091.84	0.4967877	1.7761766	HauteMaurienne	grazed



Source : <http://biodiversite.vanoise-parcnational.fr>


Objectifs de cette étude

- D'un point de vue écologique :
 - étudier comment les conditions environnementales et les pratiques de gestion influencent l'abondance du papillon Apollon dans le Parc national de la Vanoise, dans une perspective de conservation d'une espèce menacée.
- D'un point de vue statistique :
 - comprendre l'influence de variables quantitatives sur la variable d'intérêt
 - étudier les méthodes statistiques permettant une analyse rigoureuse des données (modélisation, estimation, intervalles de confiance, tests statistiques, etc.).

Visualisation en dimension 1

- Intéressons-nous à l'éventuel lien entre l'abondance et l'altitude.


```
ggplot(apollo) +  
  geom_point(aes(x = logabondance, y = altitude_index))
```



Relation linéaire en dimension 1

- On observe une tendance décroissante le long d'une droite : le logarithme de l'abondance diminue lorsque l'altitude augmente.
- Si $y_i = \text{logabondance}$ et $x_i = \text{altitude}$ d'un site, alors :

$$\exists a, b \in \mathbb{R} \text{ tels que : } y_i \approx ax_i + b .$$




Régression linéaire simple

- À partir des données, il s'agit de déterminer les « meilleurs » coefficients a et b , c'est-à-dire résoudre un problème d'optimisation !
- Parmi toutes les droites possibles, on cherche celle qui minimise les écarts entre les valeurs observées y_i et celles obtenues par la droite $\hat{y}_i = ax_i + b$.

$$f(x) = ax + b$$

y_i la vraie observation

$\hat{y}_i = ax_i + b$ la valeur théorique
si le modèle suit la droite
d'équation $y = ax + b$



Régression linéaire simple

- La mesure d'écart retenue, ou fonction de coût (loss function) est l'erreur quadratique :

$$\|y - \hat{y}\|^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - ax_i - b)^2 ,$$


- $\hat{a}$ et $\hat{b}$ sont les uniques solutions du problème :

$$\operatorname{argmin}_{a,b \in \mathbb{R}} \sum_{i=1}^n (y_i - ax_i - b)^2 ,$$

pour lequel il existe une forme close (expression explicite) :

$$\hat{a} = \frac{\operatorname{Cov}(x, y)}{\operatorname{Var}(x)} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad \text{et} \quad \hat{b} = \bar{y} - \hat{a}\bar{x} .$$

```
ggplot(  
  apollo,  
  aes(x = altitude_index,  
       y = logabondance)  
) +  
  geom_point() +  
  geom_smooth(  
    method = lm,  
    formula = y ~ x,  
    se = TRUE,  
    color = 'turquoise4'  
  )
```



Régression linéaire simple

- La régression linéaire simple sera vue en détail lors du TD 1.
- Le modèle de régression linéaire simple peut-être déduit du modèle de régression multiple.
 - Pour le reste du cours, on se focalise sur la régression linéaire multiple.

Approche multivariée

- La modélisation précédente est simpliste.
- D'autres variables sont susceptibles d'avoir une influence sur la variable d'abondance, comme par exemple l'humidité ou l'orientation.
- Pour analyser la relation entre l'abondance, l'altitude, l'humidité et l'orientation, nous cherchons une fonction $f: \mathbb{R}^3 \longrightarrow \mathbb{R}$ telle que :

$$\text{logabondance} \approx f(\text{altitude}, \text{humidité}, \text{orientation}) .$$

- Si on suppose que le lien est linéaire, alors on cherche f sous la forme :

$$f(x_1, x_2, x_3) = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 ,$$


- Cela revient à estimer les paramètres β_1 , β_2 et β_3 .

Démarche générale

- En statistique, on cherche à expliquer ou prédire, une variable d'intérêt y en fonction d'une ou plusieurs autres variables explicatives $x_1, x_2, \dots, x_p$.
- On dispose de n ensembles de mesures $(x_{1,1}, x_{1,2}, \dots, x_{1,p}), \dots, (x_{n,1}, x_{n,2}, \dots, x_{n,p})$ et de $(y_1, y_2, \dots, y_n)$ pour apprendre la relation (potentielle) entre $x_1, x_2, \dots, x_p$ et y :

$$y \approx f(x_1, \dots, x_p) .$$

- On ne sait pas à l'avance :



- Si $x_1, \dots, x_p$ expliquent correctement y ; ou
- Quelle est la forme de la fonction f (si une seule variable explicative, on peut essayer de la deviner en traçant le nuage de points).

Notations

- y_i est la i -ème observation.

logabondance du papillon du i -ème site d'observation


- $y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$

- $x_{i,j}$ est la mesure de la j -ème variable sur la i -ème observation.

- $X = \begin{pmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,p} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,p} \\ \vdots & \vdots & & \vdots \\ x_{n,1} & x_{n,2} & \cdots & x_{n,p} \end{pmatrix}$ est appelée **matrice de design** : c'est la matrice des mesures $x_{i,j}$.

- $x_{i,\bullet}$ est la i -ème ligne de X .

- $x_{\bullet,j}$ est la j -ème colonne de X .



Toutes les variables en gras sont aléatoires !
Le reste est déterministe.

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
7. Ajustement du modèle & Sélection de variables

1. Introduction

2. Modélisation

(a) Modèle linéaire gaussien

(b) Écriture matricielle

3. Estimateurs des moindres carrés

4. Analyse des résidus & Validation du modèle

5. Prédiction

6. Inférences : Intervalles de confiance & Tests statistiques

7. Ajustement du modèle & Sélection de variables

1. Introduction

2. Modélisation

(a) Modèle linéaire gaussien

(b) Écriture matricielle

3. Estimateurs des moindres carrés

4. Analyse des résidus & Validation du modèle

5. Prédiction


6. Inférences : Intervalles de confiance & Tests statistiques

7. Ajustement du modèle & Sélection de variables

Modèle linéaire gaussien

- Nous supposons que les données y_i de la variable d'intérêt sont la réalisation d'une variable aléatoire Y_i telle que :

$$Y_i = \beta_1 x_{i,1} + \beta_2 x_{i,2} + \dots + \beta_p x_{i,p} + \varepsilon_i, \quad i = 1, \dots, n$$



où

- ▶ Les $x_{i,j}$ sont des nombres connus, déterministes (c'est-à-dire non aléatoires) ;
- ▶ Les paramètres β_j sont déterministes et inconnus ;
- ▶ Les variables aléatoires ε_i , appelées **erreurs**, sont des variables aléatoires i.i.d. de loi $\mathcal{N}(0, \sigma^2)$ de variance σ^2 inconnue.

À propos de l'ordonnée à l'origine

- Par simplification, nous avons supposé que f était linéaire.
- En réalité, la plupart du temps, la fonction f recherchée est affine, c'est-à-dire :

$$f(x_1, \dots, x_p) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p .$$

- À des fins de simplification, nous pouvons ré-écrire cette dernière égalité comme :

$$f(x_1, \dots, x_p) = \beta_0 x_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p ,$$

où nous avons introduit un vecteur x_0 dont toutes les composantes sont égales à 1.

- Plus simplement, nous allons écrire

$$Y_i = \beta_1 x_{i,1} + \beta_2 x_{i,2} + \dots + \beta_p x_{i,p} + \varepsilon_i, \quad i = 1, \dots, n$$

et considérer que la première variable est l'ordonnée à l'origine, c'est-à-dire la variable constante égale à 1, c'est-à-dire $x_1 = \mathbf{1}_n$.

1. Introduction

2. Modélisation

(a) Modèle linéaire gaussien

(b) Écriture matricielle

3. Estimateurs des moindres carrés


4. Analyse des résidus & Validation du modèle

5. Prédiction

6. Inférences : Intervalles de confiance & Tests statistiques

7. Ajustement du modèle & Sélection de variables

Écriture matricielle

• En notant, $\mathbf{Y} = \begin{pmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \\ \vdots \\ \mathbf{Y}_n \end{pmatrix}$, les égalités  se réécrivent :

$$\mathbf{Y}_i = \sum_{j=1}^p \beta_j x_{i,j} + \boldsymbol{\varepsilon}_i, \quad i = 1, \dots, n,$$

ou encore de manière plus compacte :

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

• À noter que :

- $\boldsymbol{\varepsilon} \sim \mathcal{N}(0, \sigma^2 I_n)$ est un vecteur gaussien ; et
- comme $\mathbf{X}$ et $\boldsymbol{\beta}$ sont déterministes, $\mathbf{Y}$ est aussi un vecteur gaussien avec $\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 I_n)$.

Hypothèses sur la matrice de design X

Hypothèse fondamentale pour le reste du cours :

La matrice de design X est de rang plein.

- C'est-à-dire que nous supposons que les variables explicatives (colonnes de X) sont linéairement indépendantes :
 - Si une colonne est combinaison linéaire des autres, alors nous ne pourrions pas distinguer les effets éventuels.
- Conséquence immédiate : $p \leq n$.

- Nous souhaitons expliquer l'abondance (logarithmique) par l'humidité, l'altitude et l'exposition d'un site.
- La fonction `lm()` (linear model) permet d'ajuster un modèle linéaire.

```
model <- lm(formula = logabondance ~ humidity_index + altitude_index + orientation_index,  
            data = apollo)
```

```
summary(model)
```

Call:

```
lm(formula = logabondance ~ humidity_index + altitude_index +
    orientation_index, data = apollo)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.3368	-0.7446	-0.0876	0.7586	5.2587

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	13.5439577	1.5234477	8.890	3.60e-14	***
humidity_index	0.0106327	0.1182602	0.090	0.929	
altitude_index	-0.0041094	0.0002928	-14.034	< 2e-16	***
orientation_index	-0.6217292	0.1196374	-5.197	1.14e-06	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.197 on 96 degrees of freedom

Multiple R-squared: 0.6956, Adjusted R-squared: 0.6861

F-statistic: 73.11 on 3 and 96 DF, p-value: < 2.2e-16

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
 - (a) Calcul de l'EMC
 - (b) Colinéarité des variables explicatives
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
7. Ajustement du modèle & Sélection de variables

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
 - (a) Calcul de l'EMC
 - (b) Colinéarité des variables explicatives
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
7. Ajustement du modèle & Sélection de variables

L'estimation $\hat{\beta}$ sous R

- La colonne Estimate renvoie l'estimation du vecteur β .

- Ici on a :

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \\ \hat{\beta}_4 \end{pmatrix} = \begin{pmatrix} 13.5439577 \\ 0.0106327 \\ -0.0041094 \\ -0.6217292 \end{pmatrix}.$$

Call:

```
lm(formula = logabondance ~ humidity_index + altitude_index +  
orientation_index, data = apollo)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.3368	-0.7446	-0.0876	0.7586	5.2587

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	13.5439577	1.5234477	8.890	3.60e-14	***
humidity_index	0.0106327	0.1182602	0.090	0.929	
altitude_index	-0.0041094	0.0002928	-14.034	< 2e-16	***
orientation_index	-0.6217292	0.1196374	-5.197	1.14e-06	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.197 on 96 degrees of freedom

Multiple R-squared: 0.6956, Adjusted R-squared: 0.6861

F-statistic: 73.11 on 3 and 96 DF, p-value: < 2.2e-16

Quel estimateur pour β ?

- Comme pour la régression linéaire simple, on cherche parmi toutes les droites possibles

$$y = \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p ,$$

celle qui est la « plus proche » du nuage des points.

- Nous cherchons donc les coefficients $\beta_1, \beta_2, \dots, \beta_p$ minimisant la distance entre les valeurs observées y_i et les valeurs de la droite $\beta_1 x_{i,1} + \beta_2 x_{i,2} + \dots + \beta_p x_{i,p}$.
- De nombreuses distances existent : la distance de Manhattan (somme des valeurs absolues), la norme euclidienne, la norme- p , la norme- ∞ , etc.

Estimation des moindres carrés

- L'estimation des moindres carrés est défini par le problème d'optimisation suivant :

$$\hat{\beta} = \operatorname{argmin}_{\beta \in \mathbb{R}^p} \sum_{i=1}^n \left(y_i - \sum_{j=1}^p \beta_j x_{i,j} \right)^2 .$$

- En écriture matricielle, cela conduit à :

$$\hat{\beta} = \operatorname{argmin}_{\beta \in \mathbb{R}^p} \|y - X\beta\|_2^2 ,$$

où $\|\cdot\|_2$ est la norme euclidienne.

Interprétation géométrique en dimension 1


- L'estimation des moindres carrés en dimension 1 est défini par le problème d'optimisation suivant :

$$\hat{\beta} = \operatorname{argmin}_{\beta_1, \beta_2 \in \mathbb{R}} \sum_{i=1}^n \left(y_i - \beta_1 - \beta_2 x_i \right)^2 .$$

$$f(x) = \beta_1 + \beta_2 x$$

y_i la vraie observation

$\hat{y}_i = \beta_1 + \beta_2 x_i$ la valeur théorique
si le modèle modèle
suit la droite
d'équation
 $y = \beta_1 + \beta_2 x$



Forme close pour l'EMC $\hat{\beta}$

- Lorsque la matrice de design est de rang plein, l'EMC $\hat{\beta}$ possède une forme close simple.

Théorème

Si la matrice de design X est de rang plein, alors

$$\hat{\beta} = (X^T X)^{-1} X^T y .$$

- Démonstration par algèbre linéaire.
- Voir la diapositive « Si la matrice X n'est pas de rang plein » en fin de diaporama.

- Vérifier par vous même que la fonction `lm()` et le calcul de l'estimation via la formule précédente donne les mêmes résultats.

```
X <- as.matrix(data = apollo[, 1:3], nrow = 100, ncol = 3)
X <- cbind(rep(1, 100), X)

XT <- t(X)

y <- apollo[, 4]

hat_beta <- solve(XT %*% X) %*% XT %*% y
```

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
 - (a) Calcul de l'EMC
 - (b) Colinéarité des variables explicatives
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
7. Ajustement du modèle & Sélection de variables

Colinéarité des variables explicatives (I)

- L'estimateur des moindres carrés est donc :

$$\hat{\beta} = (X^T X)^{-1} X^T Y \text{ qui est un vecteur gaussien de loi } \mathcal{N}(\beta, \sigma^2(X^T X)^{-1}).$$

- La variance de l'EMC dépend de la matrice de design ...
- Si il existe de grandes corrélations entre les variables, alors :
 - des coefficients de $(X^T X)^{-1}$ peuvent devenir énormes !
 - Les variances des estimateurs explosent !
 - Les tests de significativité sur ces coefficients peuvent faire accepter l'hypothèse de nullité ou de rejet à tort de variable significative !
 - Résultats instables, adjonction ou suppression de quelques observations peuvent bouleverser les valeurs et signes des coefficients !

Colinéarité des variables explicatives (2)

- L'estimateur des moindres carrés est donc :

$$\hat{\beta} = (X^T X)^{-1} X^T Y \text{ qui est un vecteur gaussien de loi } \mathcal{N}(\beta, \sigma^2(X^T X)^{-1}).$$

- Si le nombre de variables p est grand : l'EMC devient inutilisable ...
 - Si $n \leq p$, alors EMC est non unique et il n'y a plus de formule explicite pour $\hat{\beta}$.
 - Si $n \geq p$ et que p est grand, alors le risque de corrélation entre des variables est grand.
 - Autres techniques sont nécessaires !
 - La sélection de variables via des critères AIC, BIC, etc.
 - Des méthodes de pénalisation comme la pénalisation Lasso, Ridge, etc.

Des méthodes très intéressantes, utiles et utilisées à explorer par vous même !

Voir par exemple :

Introduction au Machine Learning, Chloé-Agathe Azencott (Chapitre 6)

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
 - (a) Résidus
 - (b) Validation des hypothèses du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
7. Ajustement du modèle & Sélection de variables

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
 - (a) Résidus
 - (b) Validation des hypothèses du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
7. Ajustement du modèle & Sélection de variables

Résidus

- Valeurs prédites ou ajustées par le modèle :

$$\hat{y}_i = \sum_{j=1}^p \hat{\beta}_j x_{i,j} = x_i \hat{\beta} .$$

- Résidus estimés :


$$\hat{e}_i = y_i - \hat{y}_i .$$

- Résidus ou estimateurs des erreurs inconnues :

$$\hat{\epsilon}_i = Y_i - \hat{Y}_i .$$


1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
 - (a) Résidus
 - (b) Validation des hypothèses du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
7. Ajustement du modèle & Sélection de variables

Hypothèses du modèle



- Tests, intervalles de confiance, prévisions que nous verrons plus tard, ne sont valables que sous l'hypothèse que les observations sont la réalisation d'un modèle linéaire gaussien.
- Nécessité de vérifier sur nos données que le modèle ajusté est valable !
- Rappels : le modèle linéaire gaussien requiert que les résidus satisfassent les propriétés suivantes :
 - [P1] : espérance nulle $\mathbb{E}[\varepsilon_i] = 0$;
 - [P2] : variance constante (homoscédasticité) $\mathbb{V}(\varepsilon_i) = \sigma^2$;
 - [P3] : indépendance ; et dans le cadre du modèle linéaire gaussien
 - [P4] : résidus gaussien $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$.

Illustration des hypothèses du modèle



Les distributions conditionnelles $p(Y | x)$ sont toutes gaussiennes avec la même variance, et les espérances conditionnelles de Y (ici notées $\mu_1, \dots, \mu_5$) sont alignées le long d'une droite.

Résidus sous R


- Les résidus sont accessibles par la commande `resid(model)`.

```
resid(model)
```

1	2	3	4	5	6	7	8
-0.401316136	0.793421338	5.258741160	1.591664953	-0.361635002	0.170736662	-0.801042630	0.363274190
9	10	11	12	13	14	15	16
0.712507500	0.581069138	-0.006406004	0.772582812	0.845431877	-0.552279462	0.503735242	-0.418329967
17	18	19	20	21	22	23	24
-1.444432283	0.657099438	1.225989178	1.142845504	2.044093688	1.560460010	0.347985713	1.495354708
25	26	27	28	29	30	31	32
-0.403985648	-0.439483153	-0.387512291	-1.915605358	-1.723582845	1.532293913	-1.408601285	-0.375482835
33	34	35	36	37	38	39	40
0.216696648	-0.342614513	-2.075657850	0.552810467	-1.844936514	-1.522861529	-0.427697826	0.756634789
41	42	43	44	45	46	47	48
1.134426103	-0.823784707	-0.057849246	-0.613726148	-1.845874502	1.686446172	-0.658051589	-1.260681902
49	50	51	52	53	54	55	56
0.980787907	-0.210704422	-0.492152078	1.652576908	-0.949209995	0.073269809	-0.258361597	-2.148823951

Validation graphique du modèle linéaire gaussien

```
par(mfrow = c(2,2))  
plot(reg_apollo)
```




[P3] : Indépendance des résidus

- L'indépendance des données (et des résidus) ne peut être assuré que par le protocole expérimental.

[P] : Centralité des résidus

- Graphe Residuals vs Fitted des résidus en fonctions des données prédites, c'est-à-dire le nuage $(\hat{y}_i, \hat{e}_i)$.
- Nuage de points centré et aligné sans structure particulière : nous nous satisfaisons.
- Nuage de points avec une structure particulière : le modèle n'est peut être pas adapté aux données.


```
plot(reg_apollo, 1)
```



[P2] : Homoscédasticité des résidus

- Graphe Scale-Location des résidus standardisés en fonction des données prédites, c'est-à-dire le nuage des $(\hat{y}_i, \frac{\hat{e}_i}{\widehat{se}_i})$.
- Nuage de points centré et aligné sans structure particulière : nous nous satisfaisons.
- Nuage de points avec une structure particulière : le modèle n'est peut être pas homoscédastique.


```
plot(reg_apollo, 3)
```



[P4] : Normalité des résidus

- Graphe Q-Q Residuals des quantiles des résidus standardisés en fonction des quantiles d'une loi normale centrée réduite.
- Points alignés le long de la première bissectrice : nous nous satisfaisons.

```
plot(reg_apollo, 2)
```



1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
7. Ajustement du modèle & Sélection de variables

Prévision (1)

- Objectif : Prévoir les valeurs de l'abondance du papillon Apollon pour de nouveaux sites d'observation du Parc national de la Vanoise en mesurant l'altitude, l'humidité et l'exposition du site.
- Nous avons une nouvelle donnée $x_{n+1} = (x_{n+1,1}, \dots, x_{n+1,p})$ qui correspond à un $(n+1)$ -ème individu, et nous ne connaissons pas la valeur y_{n+1} correspondante.
- Notons $\hat{y}_{n+1}^p$ la valeur prédite (y_{n+1} étant la vraie valeur, inconnue, non-mesurée). Nous n'observons que x_{n+1} .

Prévision (2)

Illustration en dimension 1

- Le modèle indique :

$$Y_{n+1} = \beta^T x_{n+1} + \varepsilon_{n+1}$$



$\hat{y}_{n+1}^p$

avec $\varepsilon_{n+1} \sim \mathcal{N}(0, \sigma^2)$ et ε_{n+1} indépendant des $(\varepsilon_i)_{1 \leq i \leq n}$.

- La prédiction $\hat{y}_{n+1}^p$ s'effectue grâce au modèle et à l'estimation $\hat{\beta}$:

Pour « prédit »

$$\hat{y}_{n+1}^p = \hat{\beta}^T x_{n+1} .$$



- L'estimation $\hat{\beta}$ est calculée avec les données initiales $(x_1, y_1), \dots, (x_n, y_n)$, et pas (x_{n+1}, y_{n+1}) .

Erreur de prévision

Théorème (Erreur de prévision)

L'erreur de prévision

$$\hat{\epsilon}_{n+1}^p = Y_{n+1} - \hat{Y}_{n+1}^p$$

vérifie

$$\mathbb{E}(\hat{\epsilon}_{n+1}^p) = 0 \quad \text{et} \quad \text{Var}(\hat{\epsilon}_{n+1}^p) = \sigma^2 \left(1 + x_{n+1}^T (X^T X)^{-1} x_{n+1} \right).$$

- Cette erreur est inconnue car la vraie valeur y_{n+1} est inconnue.
- $x_{n+1}^T (X^T X)^{-1} x_{n+1}$ est lié à la distance (non euclidienne) entre x_{n+1} et $\bar{x}$:
 - Plus x_{n+1} est éloignée de $\bar{x}$, plus la précision de la prévision diminue.

- La fonction `predict()` permet de prédire plusieurs valeurs directement à partir du modèle.
- Par exemple, pour un nouveau site d'observation à 2857 mètres d'altitude, ayant un indice d'humidité de 13.2 et un indice d'orientation de 1.17, nous obtenons :

```
xnew <- c(13.2, 2857, 1.17)
xnew <- data.frame(humidity_index = xnew[1],
                  altitude_index = xnew[2],
                  orientation_index = xnew[3])

predict(reg_apollo,
        new = xnew)
```

une valeur prédite de logabondance de 1.216418.

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
 - (a) Intervalles de confiance sur les paramètres
 - (b) Intervalles de confiance sur la prévision
 - (c) Test statistique sur un coefficient
 - (d) Test statistique sur un ensemble de coefficients
 - (e) Test du modèle
7. Ajustement du modèle & Sélection de variables

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
 - (a) Intervalles de confiance sur les paramètres
 - (b) Intervalles de confiance sur la prévision
 - (c) Test statistique sur un coefficient
 - (d) Test statistique sur un ensemble de coefficients
 - (e) Test du modèle
7. Ajustement du modèle & Sélection de variables

Intervalle de confiance sur les paramètres

- Une estimation est intéressante lorsqu'elle s'accompagne d'un intervalle de confiance.

Théorème (IC pour β et σ^2)

- i. Un IC de niveau $1 - \alpha$ pour le coefficient β_j est donné par

$$\left[\hat{\beta}_j \pm q_{1-\alpha/2}^{St(n-p)} \hat{\sigma} \sqrt{[(X^T X)^{-1}]_{jj}} \right].$$

- ii. Un IC de niveau $1 - \alpha$ pour la variance σ^2 est donné par

$$\left[\frac{(n-p) \hat{\sigma}^2}{q_{1-\alpha/2}^{\chi^2(n-p)}}, \frac{(n-p) \hat{\sigma}^2}{q_{\alpha/2}^{\chi^2(n-p)}} \right].$$

- La fonction `confint()` permet d'obtenir les intervalles de confiance des coefficients β_j .

```
confint(reg_apollo,  
        level = 0.95)
```

	2.5 %	97.5 %
(Intercept)	10.519937980	16.567977433
humidity_index	-0.224112025	0.245377332
altitude_index	-0.004690594	-0.003528144
orientation_index	-0.859207494	-0.384250811

- La probabilité que le vrai paramètre de l'humidité se trouve dans l'intervalle $[-0.2241, 0.2454]$ est 0.95.

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
 - (a) Intervalles de confiance sur les paramètres
 - (b) Intervalles de confiance sur la prévision
 - (c) Test statistique sur un coefficient
 - (d) Test statistique sur un ensemble de coefficients
 - (e) Test du modèle
7. Ajustement du modèle & Sélection de variables

Intervalle de confiance sur la prédiction

- Comme précédemment, il existe des intervalles de confiance explicites pour les valeurs prédites : on les appelle intervalles de prédiction.
- On rappelle que $x_{n+1} \in \mathbb{R}^p$ est un nouvel individu, et la valeur y_{n+1} est inconnue.

Théorème (Intervalle de prédiction pour une prévision)

Un IC de niveau $1 - \alpha$ pour une nouvelle valeur y_{n+1} est donné par

$$\left[x_{n+1}^T \hat{\beta}_j \pm q_{1-\alpha/2}^{St(n-p)} \hat{\sigma} \sqrt{x_{n+1}^T (X^T X)^{-1} x_{n+1} + 1} \right] .$$

- Donnons les intervalles de confiance pour la prévision de l'abondance du papillon Apollon sur deux nouveaux sites d'observation du Parc national de la Vanoise :
 - sur le premier site, les valeurs respectives de l'humidité, de l'altitude et de la orientation sont de 13.2, 2857, 1.17 ;
 - sur le second site, elles sont de 9.1, 2032, 0.89.
- L'intervalle de prédiction peut s'obtenir à partir de la fonction `predict()`.

Sous R (2)

```
humiditynew <- c(13.2, 9.1)
altitudenew <- c(2857, 2032)
orientationnew <- c(1.17, 0.89)
xnew <- data.frame(
  humidity_index = humiditynew,
  altitude_index = altitudenew,
  orientation_index = orientationnew
)

predict(
  reg_apollo,
  new = xnew,
  interval = "pred",
  level = 0.95
)
```

	fit	lwr	upr
1	1.216418	-1.262932	3.695768
2	4.737138	2.297181	7.177095

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
 - (a) Intervalles de confiance sur les paramètres
 - (b) Intervalles de confiance sur la prévision
 - (c) Test statistique sur un coefficient
 - (d) Test statistique sur un ensemble de coefficients
 - (e) Test du modèle
7. Ajustement du modèle & Sélection de variables

Test sur un coefficient (I)

- Nous nous posons ici la question de l'utilité d'une variable explicative.
 - Par exemple : l'altitude d'un site influence-t-elle l'abondance du papillon Apollon ?
- Nous souhaitons donc réaliser le test :
 $(\mathcal{H}_0)$: « la variable explicative n'est pas pertinente »
contre
 $(\mathcal{H}_1)$: « la variable explicative est pertinente ».
- Une variable explicative est considérée comme pertinente au seuil d'erreur de 1ère espèce α , si la p -valeur est $< \alpha$.
- Dire que la variable est inutile revient à dire que son coefficient est nul. Nous sommes donc amenés à réaliser le test suivant :

$$(\mathcal{H}_0) : \beta_j = 0 \quad \text{contre} \quad (\mathcal{H}_1) : \beta_j \neq 0 .$$

Test sur un coefficient (2)

Théorème (Test sur la pertinence d'un coefficient)

Considérons le problème de test :

$$(\mathcal{H}_0) : \beta_j = 0 \quad \text{contre} \quad (\mathcal{H}_1) : \beta_j \neq 0 .$$

Alors on rejette $(\mathcal{H}_0)$ au seuil d'erreur de 1ère espèce α , si

$$\frac{|\hat{\beta}_j|}{\hat{\sigma} \sqrt{[(X^T X)^{-1}]_{jj}}} > q_{1-\alpha/2}^{St(n-p)} .$$

• Découle du fait que

$$\hat{\beta}_j \sim \mathcal{N}(\beta, \sigma^2 (X^T X)^{-1}) ,$$

et si $\beta_j = 0$, alors

$$\frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{[(X^T X)^{-1}]_{jj}}} \sim St(n-p) .$$

- Le résultat du test se trouve dans le tableau Coefficients de la sortie `summary`.

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	13.543957706	1.5234476709	8.89033340	3.595476e-14
humidity_index	0.010632654	0.1182602186	0.08990897	9.285469e-01
altitude_index	-0.004109369	0.0002928111	-14.03420063	5.445785e-25
orientation_index	-0.621729153	0.1196373896	-5.19677966	1.139777e-06

- La colonne `t.value` renvoie la valeur de la statistique de test.
- La dernière colonne `Pr(>|t|)` renvoie la p -valeur du test.
- Au risque de 1ère espèce de 5%, les tests sont significatifs pour les variables `altitude_index` et `orientation_index` : l'altitude et l'orientation du site influencent linéairement l'abondance du papillon Apollon.

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
 - (a) Intervalles de confiance sur les paramètres
 - (b) Intervalles de confiance sur la prévision
 - (c) Test statistique sur un coefficient
 - (d) Test statistique sur un ensemble de coefficients
 - (e) Test du modèle
7. Ajustement du modèle & Sélection de variables

Test sur la pertinence d'un groupe de coefficients

- On peut aussi tester la pertinence d'un groupe de variables explicatives :
 - Tester la nullité simultanée de plusieurs coefficients

$$(\mathcal{H}_0) : \forall j \in \{p - q + 1, \dots, p\}, \beta_j = 0 \quad \text{contre} \quad (\mathcal{H}_1) : \exists j \in \{p - q + 1, \dots, p\}, \beta_j \neq 0 .$$

- Sous $(\mathcal{H}_0)$ le modèle est en réalité :

$$\mathbf{Y}_i = \sum_{j=1}^{p-q} \beta_j x_{i,j} + \boldsymbol{\varepsilon}_i , \quad i = 1, \dots, n .$$

- Autrement dit, avec $\tilde{\boldsymbol{\beta}} = (\beta_1, \dots, \beta_{p-q})^T$, on a

$$\mathbf{Y} = X_0 \tilde{\boldsymbol{\beta}} + \boldsymbol{\varepsilon}$$

avec $X_0 \in \mathcal{M}_{n \times (p-q)} = p - q$ premières colonnes de X .

Test groupé

- Notons
 - $\mathcal{M}_1$: modèle complet avec toutes les variables explicatives
 - $\mathcal{M}_0$: sous-modèle obtenu en enlevant les q dernières variables
- On soupçonne que le vrai modèle est le modèle $\mathcal{M}_0$.
- Le test précédent revient à comparer deux modèles, $\mathcal{M}_0$ et $\mathcal{M}_1$.
- Si $\mathcal{M}_0$ est le bon modèle, alors nous collecterons moins de données en vue de la prévision et nous estimerons mieux les paramètres.
- Remarquons qu'un modèle plus riche s'ajustera mieux aux données.
- MAIS ce gain d'ajustement « vaut-il le coup » ?
 - Un modèle plus riche implique plus de paramètres à estimer donc plus d'incertitude.
- Nous allons donc construire un test comparant deux modèles.

Sommes des Carrés Résiduels

• Notons :

$$\text{SCR} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \|Y - P_{[X]}Y\|^2 \quad \text{et} \quad \text{SCR}_0 = \sum_{i=1}^n (Y_i - \hat{Y}_i^0)^2 = \|Y - P_{[X_0]}Y\|^2,$$

• La matrice X_0 étant une sous-partie des colonnes de la matrice de design X , nous avons $[X_0] \subset [X]$.

► Nous avons donc $\text{SCR} \leq \text{SCR}_0$.

• Nous allons construire un test sur la différence $\text{SCR}_0 - \text{SCR}$, et rejeter $(\mathcal{H}_0)$ si cette différence est significativement plus grande que 0.

Test de Fisher

- La statistique du test de Fisher repose sur cette différence et prend en compte la taille des modèles en compétition :

$$F = \frac{(\text{SCR}_0 - \text{SCR}) / (n - p - (n - (p - q)))}{\text{SCR} / (n - p)} = \frac{(\text{SCR}_0 - \text{SCR}) / q}{\text{SCR} / (n - p)}.$$

- Sous $(\mathcal{H}_0)$, nous avons $F \sim \mathcal{F}(q, n - p)$.

Théorème (Test de comparaison de modèles Fisher)

Considérons le problème de test :

$$(\mathcal{H}_0) : \forall j \in \{p - q + 1, \dots, p\}, \beta_j = 0 \quad \text{contre} \quad (\mathcal{H}_1) : \exists j \in \{p - q + 1, \dots, p\}, \beta_j \neq 0.$$

Nous rejetons $(\mathcal{H}_0)$ au seuil d'erreur de 1ère espèce α , si $F > q_{1-\alpha}^{\mathcal{F}(q, n-p)}$, où $q_{1-\alpha}^{\mathcal{F}(q, n-p)}$ est le quantile d'une loi de Fisher à $(q, n - p)$ -d.d.l.

- La fonction `anova()` permet de réaliser ce test de Fisher et comparer deux modèles.

```
reg1 <- lm(logabondance ~ altitude_index,
           data = apollo)
```

```
anova(reg1, model)
```

Analysis of Variance Table

Model 1: logabondance ~ altitude_index

Model 2: logabondance ~ humidity_index + altitude_index + orientation_index

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	98	176.40				
2	96	137.44	2	38.95	13.602	6.293e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
 - (a) Intervalles de confiance sur les paramètres
 - (b) Intervalles de confiance sur la prévision
 - (c) Test statistique sur un coefficient
 - (d) Test statistique sur un ensemble de coefficients
 - (e) Test du modèle
7. Ajustement du modèle & Sélection de variables

Test du modèle ou test de Fisher global

- Nous souhaitons tester la pertinence de l'ensemble des variables.

- Modèle $\mathcal{M}_1$ fait intervenir l'ensemble des variables.
- Modèle $\mathcal{M}_0$ ne fait intervenir que l'ordonnée à l'origine.

- Il correspond au test suivant :

$$(\mathcal{H}_0) : \beta_2 = \dots = \beta_p = 0 \quad \text{contre} \quad (\mathcal{H}_1) : \exists j \in \{2, \dots, p\}, \beta_j \neq 0.$$

- Il s'agit d'un cas particulier du test précédent : test de nullité de $q = p - 1$ variables (toutes sauf l'ordonnée à l'origine $x_1 = 1$).

- Statistique de test :

$$F \stackrel{(\mathcal{H}_0)}{\sim} \mathcal{F}(p-1, n-p),$$

- Nous rejetons $(\mathcal{H}_0)$ au risque d'erreur de 1ère espèce α , si $F > q_{1-\alpha}^{\mathcal{F}(p-1, n-p)}$.

- Ce test est systématiquement réalisé par R, et le résultat est donné par le summary.

- Il apparaît à la dernière ligne.

```
summary(model)
```

- La p -valeur est inférieure à $2.2e-16$.
Nous rejetons donc ($\mathcal{H}_0$) au seuil d'erreur de 1ère espèce de 5% :
au moins l'une des variables explicatives est pertinente.

Call:

```
lm(formula = logabondance ~ humidity_index + altitude_index +  
orientation_index, data = apollo)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.3368	-0.7446	-0.0876	0.7586	5.2587

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	13.5439577	1.5234477	8.890	3.60e-14 ***
humidity_index	0.0106327	0.1182602	0.090	0.929
altitude_index	-0.0041094	0.0002928	-14.034	< 2e-16 ***
orientation_index	-0.6217292	0.1196374	-5.197	1.14e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 1.197 on 96 degrees of freedom

Multiple R-squared: 0.6956, Adjusted R-squared: 0.6861

F-statistic: 73.11 on 3 and 96 DF, p-value: < 2.2e-16

Résumé sur les tests de Student & Fisher

- Une petite p -valeur obtenue à la suite d'un test de Student de « significativité » d'une variable explicative incite à penser que « la variable est pertinente ».
- Une petite p -valeur obtenue à la suite d'un test global de Fisher incite à penser que « les variables explicatives sont pertinentes dans leur ensemble ».
- Une petite p -valeur suite à l'anova de comparaison de modèles incite à penser que « le modèle le plus riche des deux est le meilleur » (celui avec le plus de variables explicatives).
- Attention néanmoins à la sur-interprétation des p -valeurs.



1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
7. Ajustement du modèle
 - (a) Coefficient de détermination
 - (b) Coefficient de détermination ajusté

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
7. Ajustement du modèle
 - (a) Coefficient de détermination
 - (b) Coefficient de détermination ajusté

Sommes des carrés (I)

- Comme pour une anova à un facteur, nous allons comparer la variabilité totale des données avec la variabilité expliquée par le modèle.
- Variabilité totale des données :

$$\text{SCT} = \sum_{i=1}^n (y_i - \bar{y})^2 .$$

- Remarquons que SCT est égal à SCR_0 pour le modèle $\mathcal{M}_0$ ne faisant intervenir que l'ordonnée à l'origine :
 - Ce modèle est défini sans covariable, c'est-à-dire par $X^{(0)} = \mathbf{1}_n$.
 - Pour ce dernier, $\hat{\beta}_1 = \bar{y}$ et donc $\hat{y}_i = \bar{y}$.

Sommes des carrés (2)

- D'après le théorème de Pythagore, nous pouvons obtenir la décomposition de variances suivante :

$$\text{SCT} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

SCM : somme des carrés du modèle

Indicateur de variabilité expliquée par le modèle

SCR : somme des carrés résiduels

Indicateur de variabilité non-expliquée par le modèle

- Plus SCM est grande par rapport à SCT, plus le modèle explique la variabilité des observations.

Coefficient de détermination R^2

- Le coefficient de détermination du modèle est défini par :

$$R^2 = \frac{SCM}{SCT} = 1 - \frac{SCR}{SCT}.$$

- Il s'agit d'un indicateur mesurant l'ajustement du modèle aux données.
- Il peut également être utilisé pour comparer les performances entre deux modèles.
- Remarquons que $0 \leq R^2 \leq 1$.


- Si R^2 n'est pas suffisamment proche de 1, alors cela signifie que le modèle n'approche pas bien la variable y :
 - il peut manquer une ou plusieurs variables explicatives qu'il faudrait introduire dans le modèle ; ou
 - l'une ou plusieurs des variables explicatives n'interviennent pas de manière linéaire.

```
summary(model)$r.squared
```

```
[1] 0.6955704
```

1. Introduction
2. Modélisation
3. Estimateurs des moindres carrés
4. Analyse des résidus & Validation du modèle
5. Prédiction
6. Inférences : Intervalles de confiance & Tests statistiques
7. Ajustement du modèle
 - (a) Coefficient de détermination
 - (b) Coefficient de détermination ajusté

Limites du R^2



- Le coefficient R^2 ne peut être utilisé pour sélectionner les covariables pertinentes.
 - En effet, si X_q dénote la matrice composée des q premières colonnes de X , alors on a
$$\text{SCR}_{q+1} \leq \text{SCR}_q ,$$
 - D'où la croissance de la fonction $q \mapsto R_q^2$, où R_q^2 est le coefficient de détermination du modèle associé à X_q .
- Ainsi le R^2 augmente quelque soit la variable incluse.
 - Dans le jeu de données apollo, si nous ajoutons la variable « nombre de panneaux de randonnées », nous ajusterons mieux les observations alors que la covariable n'a aucun caractère explicatif du phénomène écologique étudié.
- Le R^2 ne peut pas être utilisé tel quel pour la comparaison de modèles de tailles différentes ou pour la sélection de variables pertinentes.
- Cependant, il peut être intéressant pour comparer des modèles de même dimension.

R^2 ajusté

- Le coefficient de détermination ajusté est une modification du R^2 qui tient compte du nombre de variables :

$$R_a^2 = 1 - \frac{n-1}{n-p} \frac{\text{SCR}}{\text{SCT}} .$$

- Autrement dit, R_a^2 est une valeur amoindrie du R^2 :
 - La valeur du R^2 est d'autant abaissée que le nombre p de variables explicatives du modèle est grand.
- Il existe d'autres critères de choix comme le critère BIC ou AIC qui ne sont pas traités dans ce cours.

Sous R

- Le R_a^2 est également donné par la sortie `summary` à la ligne Adjusted R-squared.

Call:

```
lm(formula = logabondance ~ humidity_index + altitude_index +  
orientation_index, data = apollo)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.3368	-0.7446	-0.0876	0.7586	5.2587

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	13.5439577	1.5234477	8.890	3.60e-14	***
humidity_index	0.0106327	0.1182602	0.090	0.929	
altitude_index	-0.0041094	0.0002928	-14.034	< 2e-16	***
orientation_index	-0.6217292	0.1196374	-5.197	1.14e-06	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.197 on 96 degrees of freedom

Multiple R-squared: 0.6956, Adjusted R-squared: 0.6861

F-statistic: 73.11 on 3 and 96 DF, p-value: < 2.2e-16

```
summary(model)
```

This is the end of this chapter !

What will we do next time ?

Chapitre 3. Régression linéaire factorielle

- Les diapositives suivantes développent différents points non vus en cours.
- Elles peuvent également donner des éléments précisant la compréhension de certaines parties.
- Elles peuvent être passées en première lecture, mais elles restent néanmoins des éléments importants de la régression linéaire multiple.

- A. Feuille de route pratique de la régression linéaire multiple
- B. Tests & Problème de colinéarité des variables explicatives
- C. Quelques points théoriques

- A. Feuille de route pratique de la régression linéaire multiple
- B. Tests & Problème de colinéarité des variables explicatives
- C. Quelques points théoriques

Feuille de route pratique

Pour l'analyse de données par un modèle linéaire gaussien :

1. Charger les données, vérifier que les variables sont bien de la nature attendue (qualitative / quantitative).
2. Écrire le modèle linéaire.
3. Valider le modèle par lecture des graphes des résidus.
4. Si problème, tenter de transformer la variable d'intérêt, ou certaines covariables.
5. Réaliser le test du modèle global
 - Si non-rejet, le modèle linéaire n'est pas adapté, et l'étude s'arrête ici.
 - Sinon, tester les paramètres, réaliser des prédictions en fonction de la question scientifique.

- A. Feuille de route pratique de la régression linéaire multiple
- B. Tests & Problème de colinéarité des variables explicatives
- C. Quelques points théoriques

Tests & Colinéarité des variables explicatives

- Explorons le problème de colinéarité des variables explicatives lors des tests de nullité d'un coefficient.

- Simulons le modèle linéaire suivant :

$$Y = x_2 + x_3 + x_4 + \varepsilon.$$

- Supposons que

- nous ne connaissons pas le vrai modèle ; et
- nous ayons à disposition les variables explicatives x_2, x_3, x_4, x_5 et l'ordonnée à l'origine.

- Nous ne savons donc pas que x_5 n'influence pas réellement y . Supposons que x_5 est très corrélée aux autres variables :

$$x_5 \approx 2x_2 + x_3.$$

Expérience numérique (I)

```
x2 <- rnorm(100)
x3 <- rnorm(100)
x4 <- rnorm(100)
c <- c(1, 1, rep(0, 98))
x5 <- 2 * x2 + x3 + c
eps <- rnorm(100)

y <- x2 + x3 + x4 + x5

summary(lm(y ~ x2 + x3 + x4 + x5))
```

Expérience numérique (2)

Call:

```
lm(formula = y ~ x2 + x3 + x4 + x5)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.51978	-0.76456	0.02375	0.83029	2.68741

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.003806	0.118647	-0.032	0.974
x2	-0.187887	1.699728	-0.111	0.912
x3	0.513360	0.840176	0.611	0.543
x4	0.902346	0.119250	7.567	2.44e-11 ***
x5	0.511832	0.841415	0.608	0.544

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.155 on 95 degrees of freedom
Multiple R-squared: 0.692, Adjusted R-squared: 0.679
F-statistic: 53.35 on 4 and 95 DF, p-value: < 2.2e-16

- Seule la variable x_4 est déclarée pertinente.
- Les p -valeurs des tests concernant les variables x_2 et x_3 sont élevées : nous les éliminerions à tort.
 - Elles sont « cachées » par x_5 .

Expérience numérique (3)

```
summary(lm(y ~ x2 + x3 + x4))
```

Call:

```
lm(formula = y ~ x2 + x3 + x4)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.53043	-0.75898	0.01422	0.82520	2.66711

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.006751	0.116985	0.058	0.954
x2	0.844115	0.103758	8.135	1.47e-12 ***
x3	1.019008	0.121746	8.370	4.66e-13 ***
x4	0.911697	0.117866	7.735	1.03e-11 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.151 on 96 degrees of freedom

Multiple R-squared: 0.6908, Adjusted R-squared: 0.6811

F-statistic: 71.48 on 3 and 96 DF, p-value: < 2.2e-16

- Regardons maintenant ce qu'il se passe quand nous réalisons la régression de y sur x_2 , x_3 et x_4 .
- Sans la présence de la variable x_5 , les trois variables x_2 , x_3 et x_4 deviennent pertinentes.

En résumé

- Si nous utilisons les tests de Student pour éliminer toutes les variables déclarées non pertinentes en même temps, nous prenons le risque d'en éliminer certaines qui sont pourtant pertinentes.
- Si au contraire, nous éliminons une à une les variables, en refaisant la régression à chaque fois, nous prenons moins de risque : nous commençons par enlever la variable x_5 , dont la p -valeur du test de Student est la plus grande (à l'exception de l'intercept) ; alors en réalisant à nouveau une régression sans cette variable, x_2 et x_3 « redeviennent » pertinentes.
- Si nous souhaitons plusieurs variables en même temps, mieux vaut réaliser un test de Fisher, comme vu dans une section précédente.

- A. Feuille de route pratique de la régression linéaire multiple
- B. Tests & Problème de colinéarité des variables explicatives
- C. Quelques points théoriques
 - (a) Si la matrice de design X n'est pas de rang plein
 - (b) Propriété de l'EMC $\hat{\beta}$
 - (c) Matrice de variance-covariance des résidus
 - (d) Estimateur de la variance σ^2
 - (e) Construction du test sur la pertinence d'un coefficient

- A. Feuille de route pratique de la régression linéaire multiple
- B. Tests & Problème de colinéarité des variables explicatives
- C. Quelques points théoriques
 - (a) Si la matrice de design X n'est pas de rang plein
 - (b) Propriété de l'EMC $\hat{\beta}$
 - (c) Matrice de variance-covariance des résidus
 - (d) Estimateur de la variance σ^2
 - (e) Construction du test sur la pertinence d'un coefficient

Si la matrice de design X n'est pas de rang plein

- $\hat{y} = P_{[X]}y$ reste l'unique solution du problème, mais elle ne s'exprime plus comme $X(X^T X)^{-1} X^T y$ (puisque la matrice $X^T X$ n'est plus inversible).
 - Cependant, cette projection existe toujours et est unique.
- $\hat{y} = P_{[X]}y$ peut toujours s'écrire sous la forme $\hat{y} = X\hat{\beta}$, mais cette écriture n'est pas unique.
 - En effet, l'équation matricielle $X\hat{\beta} = \hat{y}$ a toujours au moins une solution puisque $\hat{y} = P_{[X]}y \in \text{Image}(X)$.
 - Mais dans ce cas, on a même une infinité de solutions données par
$$\hat{\beta}_0 + \text{Ker}(X) ,$$
avec $\hat{\beta}_0$ une solution particulière.

- A. Feuille de route pratique de la régression linéaire multiple
- B. Tests & Problème de colinéarité des variables explicatives
- C. Quelques points théoriques
 - (a) Si la matrice de design X n'est pas de rang plein
 - (b) Propriété de l'EMC $\hat{\beta}$
 - (c) Matrice de variance-covariance des résidus
 - (d) Estimateur de la variance σ^2
 - (e) Construction du test sur la pertinence d'un coefficient

Propriétés de l'EMC $\hat{\beta}$

- Rappelons que l'estimateur des moindres carrés est donné par :

$$\hat{\beta} = (X^T X)^{-1} X^T Y .$$

Théorème (loi de l'EMC)

$$\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2 (X^T X)^{-1}) .$$

- Conséquences :
 - L'EMC $\hat{\beta}$ est sans biais.
 - L'opérateur de covariance fait intervenir l'inverse de $X^T X$.

- A. Feuille de route pratique de la régression linéaire multiple
- B. Tests & Problème de colinéarité des variables explicatives
- C. Quelques points théoriques
 - (a) Si la matrice de design X n'est pas de rang plein
 - (b) Propriété de l'EMC $\hat{\beta}$
 - (c) Matrice de variance-covariance des résidus
 - (d) Estimateur de la variance σ^2
 - (e) Construction du test sur la pertinence d'un coefficient

Matrice de Variance-Covariance des résidus

- La matrice de variance-covariance des résidus est $\Sigma_{\hat{\varepsilon}} = \sigma^2 (I_n - P_{[X]})$.
 - Elle contient le bruit σ^2 .
 - Puisque $P_{[X]}$ n'a aucune raison d'être diagonale, il en est de même de $\Sigma_{\hat{\varepsilon}}$.
 - Les termes diagonaux sont de plus non-égaux.
- Sous l'hypothèse d'un modèle linéaire gaussien, les résidus $\hat{\varepsilon}_i$:
 - sont donc gaussiens, centrés, comme l'erreur ε_i ;
 - mais ils n'ont pas tous la même variance, et ne sont en général pas indépendants.

Propriété importante

$\hat{\varepsilon}$ et $\hat{Y}$ sont indépendants.

- A. Feuille de route pratique de la régression linéaire multiple
- B. Tests & Problème de colinéarité des variables explicatives
- C. Quelques points théoriques
 - (a) Si la matrice de design X n'est pas de rang plein
 - (b) Propriété de l'EMC $\hat{\beta}$
 - (c) Matrice de variance-covariance des résidus
 - (d) Estimateur de la variance σ^2
 - (e) Construction du test sur la pertinence d'un coefficient

Estimateur de la variance σ^2

Proposition (Estimateur de la variance du bruit)

L'estimateur

$$\hat{\sigma}^2 = \frac{1}{n-p} \sum_{i=1}^n \hat{\epsilon}_i^2$$

est un estimateur sans biais de σ^2 . On a plus précisément :

$$(n-p) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-p)$$

où $\chi^2(n-p)$ est la loi du Khi-deux à $n-p$ d.d.l.

Conséquences : Estimateurs & Estimations des variances des coefficients $\hat{\beta}_j$

- Rappelons la loi des estimateurs des coefficients β_j :

$$\hat{\beta}_j \sim \mathcal{N}(\beta, \sigma^2(X^T X)^{-1}) .$$

- En particulier,

$$\sigma_{\hat{\beta}_j}^2 = \sigma^2 [(X^T X)^{-1}]_{jj} \quad \text{et} \quad \sigma_{\hat{\beta}_j, \hat{\beta}_k} = \sigma^2 [(X^T X)^{-1}]_{jk} .$$

- Pour calculer ces quantités, il faut connaître la variance σ^2 .
- Or σ^2 est inconnue en général, nous la remplaçons donc par un estimateur ; ici $\hat{\sigma}^2$.
- Alors

$$\hat{\sigma}_{\hat{\beta}_j}^2 = \hat{\sigma}^2 [(X^T X)^{-1}]_{jj} .$$

Variance sous R

```
summary(reg_apollo)$sigma^2
```

```
[1] 1.431722
```

- Les écarts-types de chaque coefficient $\hat{\beta}_j$ sont donnés dans la colonne Std.Error du tableau Coefficients de la sortie `summary`.

- A. Feuille de route pratique de la régression linéaire multiple
- B. Tests & Problème de colinéarité des variables explicatives
- C. Quelques points théoriques
 - (a) Si la matrice de design X n'est pas de rang plein
 - (b) Propriété de l'EMC $\hat{\beta}$
 - (c) Matrice de variance-covariance des résidus
 - (d) Estimateur de la variance σ^2
 - (e) Construction du test sur la pertinence d'un coefficient

Construction du test sur la pertinence d'un coefficient (0)

Théorème (Test sur la pertinence d'un coefficient)

Considérons le problème de test :

$$(\mathcal{H}_0) : \beta_j = 0 \quad \text{contre} \quad (\mathcal{H}_1) : \beta_j \neq 0 .$$

Alors on rejette $(\mathcal{H}_0)$ au seuil d'erreur de 1ère espèce α , si

$$\frac{|\hat{\beta}_j|}{\hat{\sigma} \sqrt{[(X^T X)^{-1}]_{jj}}} > q_{1-\alpha/2}^{St(n-p)} .$$

Construction du test sur la pertinence d'un coefficient (I)

- Rappelons que :

$$\hat{\beta}_j \sim \mathcal{N}(\beta_j, \sigma^2 (X^T X)^{-1}) ,$$

- Ce qui donne, pour la composante $\hat{\beta}_j$ de $\hat{\beta}$,

$$\hat{\beta}_j \sim \mathcal{N}(\beta_j, \sigma^2 [(X^T X)^{-1}]_{jj}) ,$$

- Donc sous $(\mathcal{H}_0)$, c'est-à-dire si $\beta_j = 0$,

$$\hat{\beta}_j \sim \mathcal{N}(0, \sigma^2 [(X^T X)^{-1}]_{jj}) , \quad \text{d'où} \quad \frac{\hat{\beta}_j}{\sqrt{\sigma^2 [(X^T X)^{-1}]_{jj}}} \sim \mathcal{N}(0, 1) ,$$

- Si $(\mathcal{H}_0)$ est fausse, alors $\beta_j \neq 0$ et donc

$$\hat{\beta}_j \sim \mathcal{N}(\beta_j, \sigma^2 [(X^T X)^{-1}]_{jj}) , \quad \text{d'où} \quad \frac{\hat{\beta}_j}{\sqrt{\sigma^2 [(X^T X)^{-1}]_{jj}}} \sim \mathcal{N}(\beta_j, 1) ,$$

Construction du test sur la pertinence d'un coefficient (2)

- Or σ^2 est inconnue. Nous la remplaçons par l'estimateur $\hat{\sigma}^2$, dont on connaît la loi !

$$(n-p) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-p) .$$

- Ainsi, sous $(\mathcal{H}_0)$, il en découle alors que :

$$\frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{[(X^T X)^{-1}]_{jj}}} \sim St(n-p) .$$

- D'où le test présenté : nous rejetons l'hypothèse $(\mathcal{H}_0)$ au seuil d'erreur de 1ère espèce α , si

$$\frac{|\hat{\beta}_j|}{\hat{\sigma} \sqrt{[(X^T X)^{-1}]_{jj}}} > q_{1-\alpha/2}^{St(n-p)} .$$