Chapitre 3. Régression linéaire factorielle

Introduction compréhensive à l'analyse statistique (linéaire) multivariée

École d'ingénieur.e.s en Agronomie & Agroalimentaire - 2e année

Léo Dort leo.dort@institut-agro.fr

Ressources & Références pour ce chapitre

- Ressource Rmarkdown compagnon : apollo.Rmd

(avec quelques légères modifications.)

- Références principales : Ce cours est tiré du Cours de Sophie Donnet (CR INRAe)

- Livres : Régression avec R (3e édition) de Pierre-André Cornillon, Nicolas Hengartner, Eric Matzner-Lober et Laurent Rouvière

Être quantitative ou ne pas être quantitative ?

- Jusqu'à présent, les variables explicatives étaient quantitatives continues.

- Dans le jeu de données `apollo.Rdata`, des variables explicatives qualitatives ont été mesurées et peuvent apporter un intérêt à l'étude.

  Comment intégrer au modèle linéaire des variables qualitatives ?

- Dans ce chapitre, nous allons étudier le cas :
  - d'une seule variable explicative qualitative : analyse de variance à un facteur (et le voir comme une régression linéaire) ;
  - de deux variables explicatives qualitatives : analyse de variance à deux facteurs ; et
  - le cas d'une variable explicative qualitative associée à une variable explicative quantitative : analyse de la covariance.

Plan

1. Introduction
2. Analyse de variance à un facteur is back !
3. Analyse de variance à deux facteurs fixes
4. Analyse de la covariance
5. Quelques méthodes de régressions avancées

Plan

1. Introduction

2. Analyse de variance à un facteur is back !

   (a) Modélisation du problème & Problème régulier

   (b) Modèle singulier

   (c) Validation du modèle & Comparaison de traitements

3. Analyse de variance à deux facteurs fixes

4. Analyse de la covariance

5. Quelques méthodes de régressions avancées

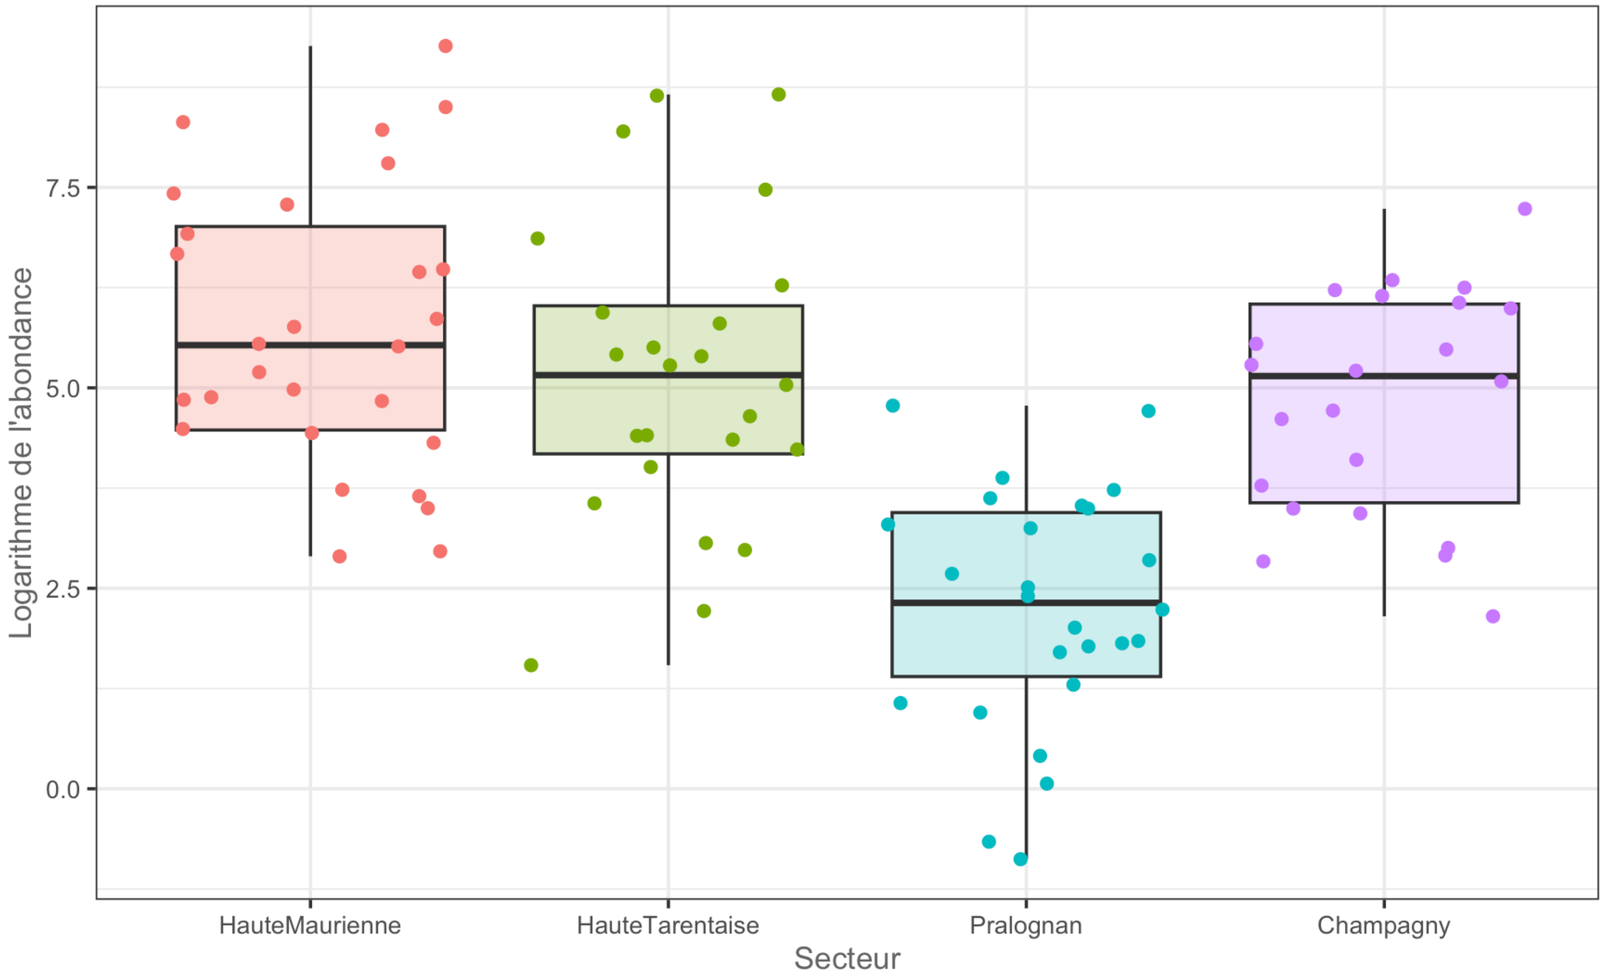
Contexte (1)

- Le secteur influence-t-il l'abondance du papillon Apollon ?
- La variable `sector` possède 4 modalités : Champigny, Haut Maurienne, Haute Tarentaise et Pralognan.
- Nous commençons par une représentation graphique des données : ici les boîtes à moustaches semblent la plus pertinente.

Contexte (2)

```
ggplot(apollo) +
    aes(x = sector, y = logabondance, fill = sector) +
    geom_boxplot(alpha = 0.25) +
    geom_jitter(aes(color = sector)) +
    labs(
      x = "Secteur",
      y = "Logarithme de l'abondance"
    ) +
    theme(
      axis.title = element_text(size = 10, color = "grey40"),
      axis.text = element_text(size = 8),
      legend.position = "none"
    )
```

Contexte (3)



- Il semble que le secteur influence l'abondance du papillon Apollon.

Plan

1. Introduction

2. Analyse de variance à un facteur is back !

   (a) Modélisation du problème & Problème régulier

   (b) Modèle singulier

   (c) Validation du modèle & Comparaison de traitements

3. Analyse de variance à deux facteurs fixes

4. Analyse de la covariance

5. Quelques méthodes de régressions avancées

Notations

- Supposons que la variable explicative X soit qualitative et qu'elle possède I modalités.
- Chaque modalité i est prise par n_i observations (de sorte que $\sum_{i=1}^{I} n_i = n$).
  - Par exemple, si nous prenons l'ordre alphabétique (Champagny, Haute Maurienne, Haute Tarentaise, Pralognan,), nous avons :

$$n_1 = 22, \quad n_2 = 28, \quad n_3 = 24 \quad \text{et} \quad n_4 = 26.$$

- y_{ij} représente la valeur de la variable à expliquer pour le j-ème individu ayant pris la i-ème modalité.

Modèle régulier

- On suppose que $y_{i,j}$ est la réalisation de variables aléatoires i.i.d. $\mathbf{Y}_{i,j}$. Nous cherchons à savoir si le facteur X fait varier la variable $\mathbf{Y}$.

- Le modèle est le suivant :

$$\mathbf{Y}_{i,j} = \mu_i + \boldsymbol{\varepsilon}_{i,j}, \qquad i \in \{1,\dots,I\}, j \in \{1,\dots,n_i\}$$



- où
  - les variables aléatoires ε_i, appelées erreurs, sont des variables aléatoires i.i.d. de loi $\mathcal{N}(0,\sigma^2)$ de variance σ^2 inconnue ; et
  - les paramètres μ_i sont inconnus et fixes (déterministes).

Modèle régulier & Écriture matricielle

- Posons :

$$X^r = \begin{pmatrix} 1 & & & & & \\ \vdots & & & & & \\ 1 & & & & & \\ & 1 & & & & \\ & \vdots & & & & \\ & 1 & & \ddots & & \\ & & & & \ddots & \\ & & & & & 1 \\ & & & & & \vdots \\ & & & & & 1 \end{pmatrix}, \qquad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_I \end{pmatrix} \qquad \text{et} \qquad \boldsymbol{\varepsilon} = \begin{pmatrix} \boldsymbol{\varepsilon}_1 \\ \boldsymbol{\varepsilon}_2 \\ \vdots \\ \boldsymbol{\varepsilon}_n \end{pmatrix}.$$

- Alors, nous avons l'écriture matricielle suivante :

$$\mathbf{Y} = X^r \mu + \boldsymbol{\varepsilon}, \qquad \boldsymbol{\varepsilon} \sim \mathcal{N}(0, \sigma^2 I_n).$$

- Le modèle est dit **régulier** car la matrice de design X^r est de rang plein !

Estimations

- Chaque paramètre μ_i est estimé par la moyenne empirique des observations dans la modalité i :

$$\hat{\mu}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{i,j} = \bar{y}_{i,\cdot}.$$

- La valeur ajustée $\hat{y}_{i,j}$ est alors $\hat{y}_{i,j} = \hat{\mu}_i$.

- La variance inconnue σ^2 s'estime par

$$\hat{\sigma}^2 = \frac{1}{n - I} \sum_{i,j} \left(y_{i,j} - \hat{\mu}_i \right)^2 .$$

estimateur sans biais

Sous R

```
model <- lm(formula = logabondance ~ -1 + sector,
            data = apollo)

summary(model)
```

```
Call:
lm(formula = logabondance ~ -1 + sector, data = apollo)

Residuals:
    Min      1Q  Median      3Q     Max
-3.6217 -1.1564  0.0049  1.1978  3.5236

Coefficients:
                      Estimate Std. Error t value Pr(>|t|)
sectorHauteMaurienne    5.7404     0.3131  18.334  < 2e-16 ***
sectorHauteTarentaise   5.1625     0.3382  15.265  < 2e-16 ***
sectorPralognan         2.2450     0.3249   6.909 5.32e-10 ***
sectorChampagny         4.8132     0.3532  13.627  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.657 on 96 degrees of freedom
Multiple R-squared:  0.8932,    Adjusted R-squared:  0.8887
F-statistic: 200.6 on 4 and 96 DF,  p-value: < 2.2e-16
```

Commentaires

- Le test global de Fisher n'a ici que peu d'intérêt !
  - En effet, il teste :

$$(\mathscr{H}_0) : \mu_1 = \mu_2 = \mu_3 = \mu_4 = 0 \qquad \text{contre} \qquad (\mathscr{H}_1) : \text{"l'un des } \mu_i \text{ n'est pas nul"}.$$

- La question pertinente est : « la localité du site d'observation influence-t-elle l'abondance du papillon Apollon ? »

- Cette question se traduit par le test suivant :

$$(\mathscr{H}_0) : \mu_1 = \mu_2 = \mu_3 = \mu_4 \qquad \text{contre} \qquad (\mathscr{H}_1) : \text{"les } \mu_i \text{ ne sont pas tous égaux"}.$$

- Pour répondre à cette question, nous introduisons un effet moyen μ : une ordonnée à l'origine !

Plan

1. Introduction

2. Analyse de variance à un facteur is back !

   (a) Modélisation du problème & Problème régulier

   (b) Modèle singulier

   (c) Validation du modèle & Comparaison de traitements

3. Analyse de variance à deux facteurs fixes

4. Analyse de la covariance

5. Quelques méthodes de régressions avancées

Modèle singulier

- On suppose que la variable $y_{i,j}$ est la réalisation d'une variable aléatoire $\mathbf{Y}_{i,j}$, avec :

$$\mathbf{Y}_{i,j} = \mu + \alpha_i + \boldsymbol{\varepsilon}_{i,j} \qquad i \in \{1,\dots,I\},\ j \in \{1,\dots,n_i\}.$$

- Nous avons introduit un effet moyen μ.

- Pour chaque modalité i, α_i est l'effet de cette modalité sur la variable à expliquer y par rapport à l'effet moyen :

$$\mu_i = \mu + \alpha_i \quad \text{qui se lit aussi } \alpha_i = \mu_i - \mu.$$

- μ est vu comme un niveau de référence et α_i s'entend comme une différence par rapport au niveau de référence.

Écriture matricielle

- $I+1$ paramètres à estimer

$$X^s = \begin{pmatrix} 1 & 1 & & & \\ \vdots & \vdots & & & \\ 1 & 1 & & & \\ 1 & & 1 & & \\ \vdots & & \vdots & & \\ 1 & & 1 & & \\ \vdots & & & \ddots & \\ 1 & & & & 1 \\ \vdots & & & & \vdots \\ 1 & & & & 1 \end{pmatrix}.$$

- X^s n'est plus de rang plein, ce qui pose des problèmes d'identifiabilité :
  - I équations $\mu_i = \mu + \alpha_i$, mais $I+1$ paramètres ...

- Il faut donc introduire une nouvelle contrainte !

Rendre le modèle identifiable en le contraignant

/!\ Ici 1ère modalité = modalité de référence !

- Contrainte $\mu = 0$: modèle régulier.
- Contrainte $\alpha_1 = 0$: alors $\mu = \mu_1$. L'effet moyen est l'effet de la première modalité.
  - Les autres $\alpha_i = \mu_i - \mu_1$ mesurent donc les différences (les effets) des autres modalités avec cette modalité de référence.
- Contrainte $\sum_{i=1}^{I} \alpha_i = 0$: l'effet moyen est alors la moyenne des effets de chaque modalité.
  - Puisque $\forall i = 1, \ldots, I, \quad \mu + \alpha_i = \mu_i$ entraine que $\sum_{i=1}^{I} \mu + \sum_{i=1}^{I} \alpha_i = \sum_{i=1}^{I} \mu_i$. D'où $\mu = \frac{1}{I} \sum_{i=1}^{I} \mu_i$ sous la contrainte.
- Contrainte linéaire quelconque : en utilisant l'option `contrasts` ou `C(...)`.
- Par défaut, c'est la contrainte $\alpha_1 = 0$ qui est utilisé dans la fonction `lm()`.

Estimation des paramètres du modèle singulier

Contrainte (par défaut) $\alpha_1 = 0$.

- Par identification, $\mu_1 = \mu + \alpha_1$ et alors $\mu_1 = \mu$. Une estimation de μ est alors :

$$\hat{\mu} = \hat{\mu}_1 = \frac{1}{n_1}\sum_{j=1}^{n_1} y_{1,j} = \bar{y}_{1,\cdot}.$$

- De même, $\mu_2 = \mu + \alpha_2$ ou autrement écrit $\alpha_2 = \mu_2 - \mu$. Une estimation de α_2 est alors :

$$\hat{\alpha}_2 = \hat{\mu}_2 - \hat{\mu} = \frac{1}{n_2}\sum_{j=1}^{n_2} y_{2,j} - \frac{1}{n_1}\sum_{j=1}^{n_1} y_{1,j} = \bar{y}_{2,\cdot} - \bar{y}_{1,\cdot}.$$

- De la même manière, pour tout $i = 2,\ldots,I$, $\mu_i = \mu + \alpha_i$ ou autrement écrit $\alpha_i = \mu_i - \mu$. Une estimation de α_i est alors :

$$\hat{\alpha}_i = \hat{\mu}_i - \hat{\mu} = \frac{1}{n_i}\sum_{j=1}^{n_i} y_{i,j} - \frac{1}{n_1}\sum_{j=1}^{n_1} y_{1,j} = \bar{y}_{i,\cdot} - \bar{y}_{1,\cdot}.$$

Commentaires

- Si on change de contrainte, on change d'interprétation !
  - Mêmes résultats en terme de prédiction et de tests, quelque soit l'écriture du modèle.
  - La différence est dans l'interprétation des coefficients et donc des tests.

- Exemple pour la contrainte $\alpha_1 = 0$:
  - Coefficient de l'(Intercept) = effet de la modalité de référence.
  - Autres coefficients = différences d'effet avec cette modalité de référence.
  - Le test de Fisher associé à ce modèle a pour hypothèse :

$$(\mathscr{H}_0) : \alpha_2 = \alpha_3 = \ldots = \alpha_I = 0 \qquad \text{contre} \qquad (\mathscr{H}_1) : \exists i \in \{2,\ldots,I\},\ \alpha_i \neq 0 \ .$$

  - Ce qui correspond donc bien à l'égalité des effets de chaque modalité.

Sous R

- Vérifions avec le test global de Fisher l'influence du secteur sur l'abondance du papillon Apollon.

```
model <- lm(formula = logabondance ~ sector,
            data = apollo)

summary(model)
```

```
Call:
lm(formula = logabondance ~ sector, data = apollo)

Residuals:
    Min      1Q  Median      3Q     Max
-3.6217 -1.1564  0.0049  1.1978  3.5236

Coefficients:
                     Estimate Std. Error t value Pr(>|t|)
(Intercept)            5.7404     0.3131  18.334  < 2e-16 ***
sectorHauteTarentaise -0.5779     0.4609  -1.254   0.2130
sectorPralognan       -3.4954     0.4512  -7.746 9.74e-12 ***
sectorChampagny       -0.9271     0.4720  -1.964   0.0524 .
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.657 on 96 degrees of freedom
Multiple R-squared:  0.4163,    Adjusted R-squared:  0.3981
F-statistic: 22.83 on 3 and 96 DF,  p-value: 3.075e-11
```

- La p-valeur du test de Fisher est très basse (3.075e-11), on rejette donc $(\mathscr{H}_0)$: nous pouvons conclure, au risque d'erreur de 1ère espèce de 5% (par exemple), que le secteur influence l'abondance du papillon Apollon.

Commentaires

- Nous obtenons les mêmes résultats entre les deux contraintes $\mu = 0$ et $\alpha_1 = 0$.

- Nous pouvons (facilement) retrouver les résultats de la première sortie sous la contrainte $\mu = 0$:

```
Coefficients:
                        Estimate
sectorHauteMaurienne      5.7404
sectorHauteTarentaise     5.1625
sectorPralognan           2.2450
sectorChampagny           4.8132
```

$\mu_{\text{HauteTarentaise}} = 5.1625$

à partir des résultats de la seconde sous la contrainte $\alpha_1 = 0$:

```
Coefficients:
                        Estimate
(Intercept)               5.7404
sectorHauteTarentaise    -0.5779
sectorPralognan          -3.4954
sectorChampagny          -0.9271
```

$$\begin{aligned}\mu_{\text{HauteTarentaise}} &= \mu_{\text{HauteMaurienne}} + \alpha_{\text{HauteTarentaise}} \\ &= 5.7404 - 0.5779 \\ &= 5.1625\end{aligned}$$

Changement de contraintes

- Si on change de contrainte, on change d'interprétation.
- Pour prendre la seconde modalité comme référence :

```
lm(formula = logabondance ~ C(sector, base = 2), data = apollo)
```

- Si nous voulons utiliser la contrainte $\sum_{i=1}^{I} \alpha_i = 0$, il suffit d'utiliser la commande :

```
lm(formula = logabondance ~ C(sector, sum), data = apollo)
```

Plan

1. Introduction

2. Analyse de variance à un facteur is back !

   (a) Modélisation du problème & Problème régulier

   (b) Modèle singulier

   (c) Validation du modèle & Comparaison de traitements

3. Analyse de variance à deux facteurs fixes

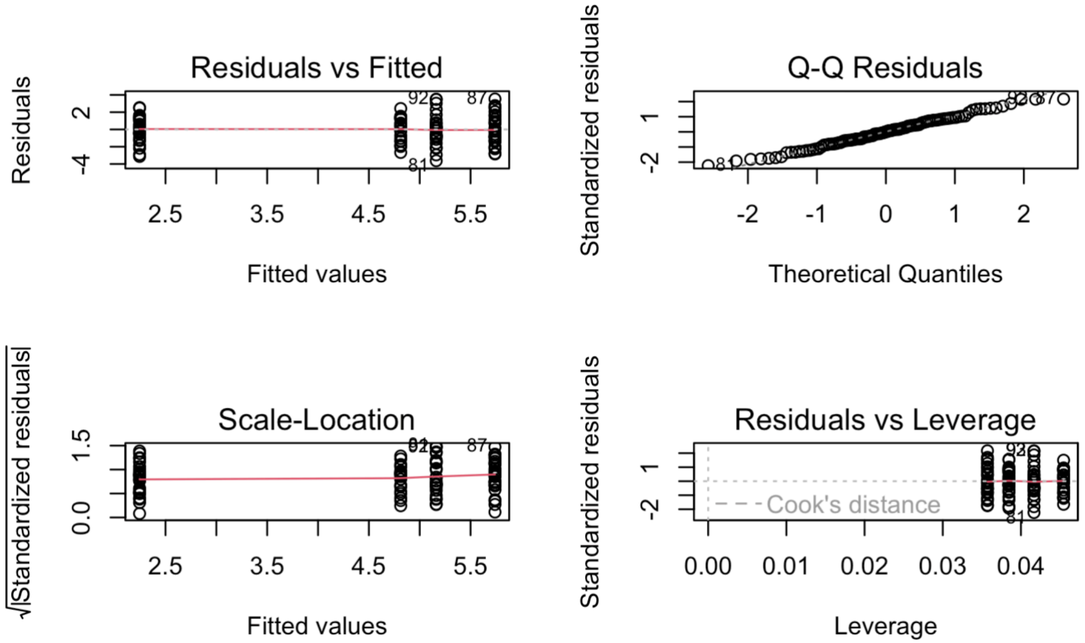
4. Analyse de la covariance

5. Quelques méthodes de régressions avancées

Analyses des résidus & Tests multiples

- Nous renvoyons à l'analyse des résidus concernant la régression linéaire multiple.

```
par(mfrow = c(2,2))
plot(model)
```



- Pour comparer les traitements, nous renvoyons au cours introductif aux tests statistiques de 1ère année pour tout ce qui concerne les tests multiples.

```
pairwise.t.test(apollo$logabondance, apollo$sector,
                p.adjsut.method = "bonferroni")
```

Test de Student 2 à 2 avec correction de Bonferroni

```
                HauteMaurienne HauteTarentaise Pralognan
HauteTarentaise 1.00           -               -
Pralognan       5.8e-11        7.7e-08         -
Champagny       0.31           1.00            3.6e-06

P value adjustment method: bonferroni
```

Plan

1. Introduction

2. Analyse de variance à un facteur is back !

3. Analyse de variance à deux facteurs fixes

   (a) Modèle régulier & Modèle singulier

   (b) Validation du modèle & Test du modèle

   (c) Tests d'effet des facteurs

   (d) Analyse de variance à 3 facteurs

4. Analyse de la covariance

5. Quelques méthodes de régressions avancées

Plan

1. Introduction

2. Analyse de variance à un facteur is back !

3. Analyse de variance à deux facteurs fixes

   (a) Modèle régulier & Modèle singulier

   (b) Validation du modèle & Test du modèle

   (c) Tests d'effet des facteurs

   (d) Analyse de variance à 3 facteurs

4. Analyse de la covariance

5. Quelques méthodes de régressions avancées

Contexte

- Deux facteurs : nous modélisons l'abondance du papillon Apollo par le secteur (2 modalités) et le mode de gestion du site (2 modalités).

- Nous pourrons généraliser les résultats à un nombre quelconque de facteurs.
  - Afin d'alléger les notations, nous nous restreignons au cas de deux facteurs.

Modélisation

- Supposons que le premier facteur ait I modalités et le second J modalités.
- $y_{i,j,k}$: la k-ème observation dans les modalités i pour le premier facteur et j pour le deuxième facteur.
- Supposons que nous disposions de $n_{i,j}$ observations pour les modalités i et j.
- $y_{i,j,k}$ est la réalisation d'une variable aléatoire $\mathbf{Y}_{i,j,k}$ suivant le modèle :

$$\mathbf{Y}_{i,j,k} = \mu_{i,j} + \boldsymbol{\varepsilon}_{i,j,k}, \qquad k \in \{1,\dots,n_{i,j}\},\ i \in \{1,\dots,I\},\ j \in \{1,\dots,J\},$$

- où
  - les erreurs $\boldsymbol{\varepsilon}_{i,j,k} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,\sigma^2)$; et
  - les paramètres $\mu_{i,j}$ sont inconnus et fixes (déterministes).

Estimation des paramètres du modèle régulier

- Posons

$$\overline{y}_{i,j,.} \;=\; \frac{1}{n_{i,j}} \sum_{k=1}^{n_{i,j}} y_{i,j,k}$$

la moyenne des valeurs y sur les observations ayant pris la modalité i pour le premier facteur et la modalité j pour le second facteur.

Proposition

$$\hat{\mu}_{i,j} \;=\; \overline{y}_{i,j,.} \;.$$

- Par conséquent, une estimation de la variance inconnue σ^2 est obtenue par :

$$\hat{\sigma}^2 \;=\; \frac{1}{n - IJ} \sum_{i,j,k} \left(y_{i,j,k} \;-\; \hat{\mu}_{i,j} \right)^2 \;.$$

Modèle singulier

- Pour mieux analyser l'influence des facteurs, nous considérons la décomposition suivante de la moyenne $\mu_{i,j}$ inconnue :

$$\mu_{i,j} = \mu + \alpha_i + \beta_j + \gamma_{i,j} .$$

- Cette écriture n'est pas unique !

- $I \times J$ paramètres $\mu_{i,j}$ décomposés en $1 + I + J + I \times J$ nouveaux paramètres !
  - $1 + I + J$ paramètres de plus (à estimer) avec cette écriture ...
  - Il faut donc imposer $1 + I + J$ contraintes linéairement indépendantes.

Contraintes classiques

- **Contrainte de type analyse par cellule = modèle régulier :**

$$\mu = 0, \qquad \forall i \in \{1,\dots,I\},\ \alpha_i = 0, \qquad \forall j \in \{1,\dots,J\},\ \beta_j = 0\ .$$

- **Contrainte de type cellule de référence :** Contrainte par défaut sous R

$$\alpha_1 = 0, \qquad \beta_1 = 0, \qquad \forall j \in \{1,\dots,J\},\ \gamma_{1,j} = 0, \qquad \forall i \in \{1,\dots,I\},\ \gamma_{i,1} = 0\ .$$

- **Contrainte de type « somme » :**

$$\sum_{i=1}^{I} \alpha_i = 0, \qquad \sum_{j=1}^{J} \beta_j = 0, \qquad \forall j \in \{1,\dots,J\},\ \sum_{i=1}^{I} \gamma_{i,j} = 0, \qquad \forall i \in \{1,\dots,I\},\ \sum_{j=1}^{J} \gamma_{i,j} = 0\ .$$

Interprétation des nouveaux coefficients

$$\mu_{i,j} = \mu + \alpha_i + \beta_j + \gamma_{i,j}$$

- α_i : effet principal de la modalité i du premier facteur
- β_j : effet principal de la modalité j du second facteur
- $\gamma_{i,j}$: effet d'interaction entre les modalités i et j du premier et second facteur resp.
- μ : effet moyen (dépendant comme précédemment des contraintes imposées)

Sous R (1)

```
model1 <- lm(logabondance ~ sector * grazing,
             data = apollo)

summary(model1)
```

- Nous trouvons les mêmes résultats en utilisant la formule :

```
lm(logabondance ~ sector + grazing + sector:grazing, data = apollo)
```

Sous R (2)

- Facteur 1 : sector
  - Modalité 1 : HauteMaurienne
- Facteur 2 : grazing
  - Modalité 1 : ungrazed

```
Call:
lm(formula = logabondance ~ sector + grazing + sector:grazing,
    data = apollo)

Residuals:
    Min      1Q  Median      3Q     Max
-3.4335 -0.9944 -0.0247  1.0360  4.0229

Coefficients:
                                      Estimate Std. Error t value Pr(>|t|)
(Intercept)                            5.24112    0.45860  11.428  < 2e-16 ***
sectorHauteTarentaise                 -0.26685    0.69550  -0.384   0.7021
sectorPralognan                       -2.89820    0.60184  -4.816 5.75e-06 ***
sectorChampagny                       -0.04095    0.64856  -0.063   0.9498
grazinggrazed                          0.93192    0.62657   1.487   0.1403
sectorHauteTarentaise:grazinggrazed   -0.60923    0.92806  -0.656   0.5132
sectorPralognan:grazinggrazed         -1.25024    0.94141  -1.328   0.1874
sectorChampagny:grazinggrazed         -1.87774    0.95221  -1.972   0.0516 .
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.654 on 92 degrees of freedom
Multiple R-squared:  0.4429,    Adjusted R-squared:  0.4005
F-statistic: 10.45 on 7 and 92 DF,  p-value: 1.364e-09
```

Aide à l'interprétation des coefficients (1)

- (Intercept) : l'ordonnée à l'origine est l'abondance moyenne pour les modalités de références (Haute Maurienne et non-pâturage).

- sectorHauteTarentaise : ce coefficient donne la différence d'abondance moyenne due au changement de région de Haute Maurienne à HauteTarentaise pour le mode non-pâturage.

- grazinggrazed : ce coefficient donne la différence moyenne d'abondance entre pâturage et non-pâturage pour la région de référence.

```
Call:
lm(formula = logabondance ~ sector + grazing + sector:grazing,
    data = apollo)

Residuals:
    Min      1Q  Median      3Q     Max
-3.4335 -0.9944 -0.0247  1.0360  4.0229

Coefficients:
                                  Estimate Std. Error t value Pr(>|t|)
(Intercept)                        5.24112    0.45860  11.428  < 2e-16 ***
sectorHauteTarentaise             -0.26685    0.69550  -0.384   0.7021
sectorPralognan                   -2.89820    0.60184  -4.816 5.75e-06 ***
sectorChampagny                   -0.04095    0.64856  -0.063   0.9498
grazinggrazed                      0.93192    0.62657   1.487   0.1403
sectorHauteTarentaise:grazinggrazed -0.60923    0.92806  -0.656   0.5132
sectorPralognan:grazinggrazed      -1.25024    0.94141  -1.328   0.1874
sectorChampagny:grazinggrazed      -1.87774    0.95221  -1.972   0.0516 .
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.654 on 92 degrees of freedom
Multiple R-squared:  0.4429,    Adjusted R-squared:  0.4005
F-statistic: 10.45 on 7 and 92 DF,  p-value: 1.364e-09
```

Aide à l'interprétation des coefficients (2)

- `sectorPralognan:grazinggrazed` : ce coefficient d'interaction montrent la différence entre les abondances moyennes pour la combinaison Pralognan et pâturage, comparée à la moyenne des effets additifs seulement.

La moyenne de l'abondance pour la combinaison `Pralognan:grazed` est égale à

`5.24112` (ordonnée à l'origine)

`- 2.8982` (Pralognan)

`+ 0.93192` (grazed)

`- 1.25024` (Pralognan : grazed)

`= 2.0246.`

```
Call:
lm(formula = logabondance ~ sector + grazing + sector:grazing,
    data = apollo)

Residuals:
    Min      1Q  Median      3Q     Max
-3.4335 -0.9944 -0.0247  1.0360  4.0229

Coefficients:
                                  Estimate Std. Error t value Pr(>|t|)
(Intercept)                        5.24112    0.45860  11.428  < 2e-16 ***
sectorHauteTarentaise             -0.26685    0.69550  -0.384   0.7021
sectorPralognan                   -2.89820    0.60184  -4.816 5.75e-06 ***
sectorChampagny                   -0.04095    0.64856  -0.063   0.9498
grazinggrazed                      0.93192    0.62657   1.487   0.1403
sectorHauteTarentaise:grazinggrazed -0.60923    0.92806  -0.656   0.5132
sectorPralognan:grazinggrazed      -1.25024    0.94141  -1.328   0.1874
sectorChampagny:grazinggrazed      -1.87774    0.95221  -1.972   0.0516 .
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.654 on 92 degrees of freedom
Multiple R-squared:  0.4429,    Adjusted R-squared:  0.4005
F-statistic: 10.45 on 7 and 92 DF,  p-value: 1.364e-09
```

Plan

1. Introduction

2. Analyse de variance à un facteur is back !

3. Analyse de variance à deux facteurs fixes

   (a) Modèle régulier & Modèle singulier

   (b) Validation du modèle & Test du modèle

   (c) Tests d'effet des facteurs

   (d) Analyse de variance à 3 facteurs

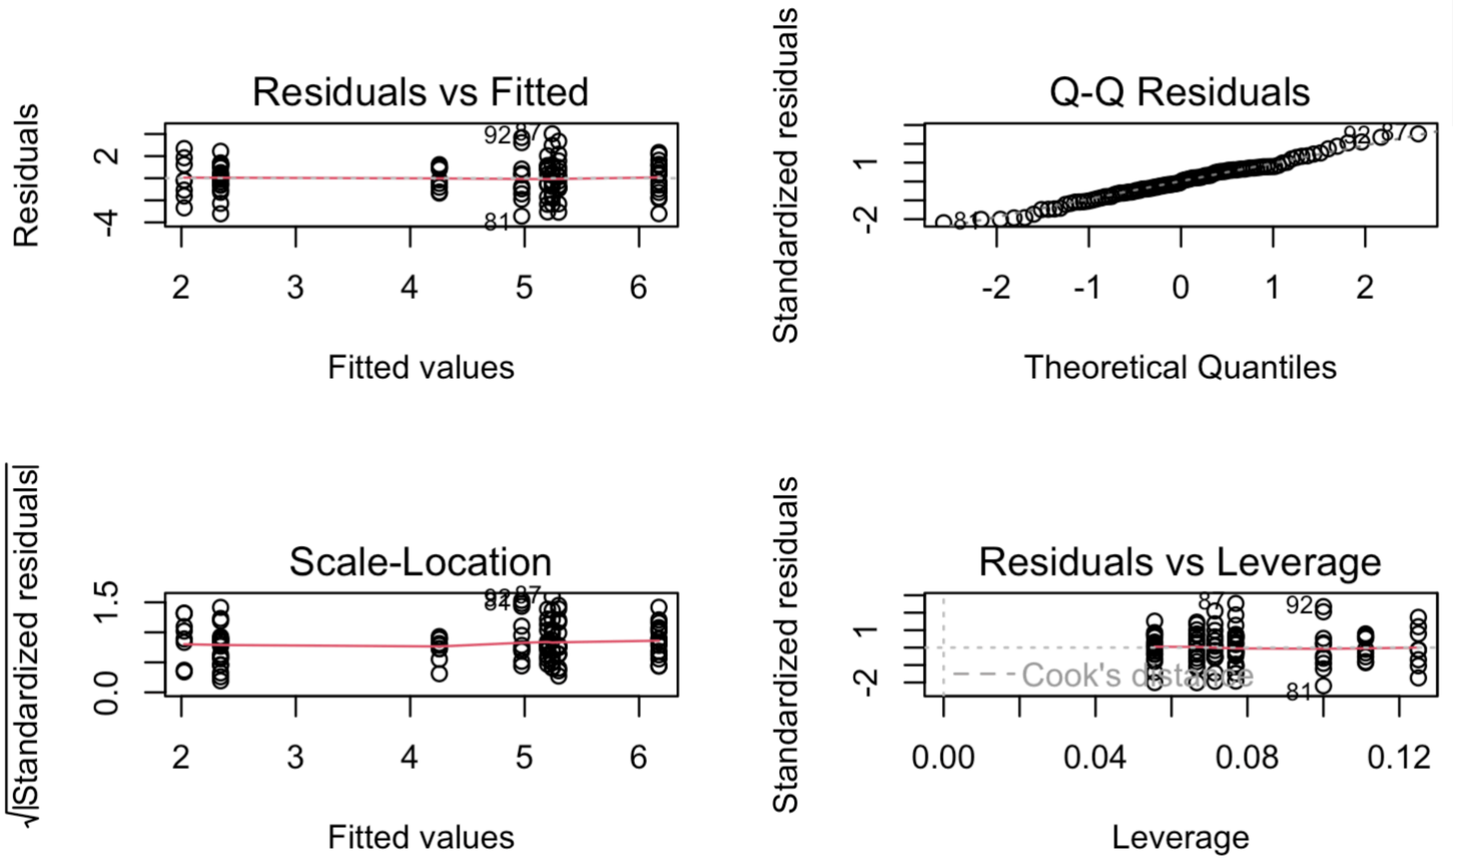
4. Analyse de la covariance

5. Quelques méthodes de régressions avancées

Analyse des résidus

- Nous renvoyons à l'analyse des résidus concernant la régression linéaire multiple.

```
par(mfrow = c(2,2))
plot(model1)
```



- Ici, il semble n'y avoir aucune obstruction aux postulats [P1]-[P4] de validation des résidus.

Test du modèle

- Le test de la pertinence du modèle teste les hypothèses suivantes :

$$(\mathscr{H}_0) : \mathbf{Y}_{i,j,k} = \mu + \boldsymbol{\varepsilon}_{i,j,k} \quad \text{contre} \quad (\mathscr{H}_1) : \mathbf{Y}_{i,j,k} = \mu + + \alpha_i + \beta_j + \gamma_{i,j,k} + \boldsymbol{\varepsilon}_{i,j,k}.$$

- Le résultat est donné directement dans la sortie `summary()`.

- La p-valeur du test global de Fisher est `1.364e-09`, donc au risque d'erreur de 1ère espèce de 5% nous rejetons $(\mathscr{H}_0)$: au moins l'un des facteurs a une influence sur l'abondance du papillon Apollon (c'est-à-dire qu'au moins un des α_i et/ou β_j et/ou $\gamma_{i,j}$ est non nul).

```
Call:
lm(formula = logabondance ~ sector + grazing + sector:grazing,
    data = apollo)

Residuals:
    Min      1Q  Median      3Q     Max
-3.4335 -0.9944 -0.0247  1.0360  4.0229

Coefficients:
                                  Estimate Std. Error t value Pr(>|t|)
(Intercept)                        5.24112    0.45860  11.428  < 2e-16 ***
sectorHauteTarentaise             -0.26685    0.69550  -0.384   0.7021
sectorPralognan                   -2.89820    0.60184  -4.816 5.75e-06 ***
sectorChampagny                   -0.04095    0.64856  -0.063   0.9498
grazinggrazed                      0.93192    0.62657   1.487   0.1403
sectorHauteTarentaise:grazinggrazed -0.60923    0.92806  -0.656   0.5132
sectorPralognan:grazinggrazed      -1.25024    0.94141  -1.328   0.1874
sectorChampagny:grazinggrazed      -1.87774    0.95221  -1.972   0.0516 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.654 on 92 degrees of freedom
Multiple R-squared:  0.4429,    Adjusted R-squared:  0.4005
F-statistic: 10.45 on 7 and 92 DF,  p-value: 1.364e-09
```

Une collection de modèles

$$
\begin{aligned}
\mathscr{M}_{\mu} \quad &: \quad \mathbf{Y}_{i,j,k} = \mu + \boldsymbol{\varepsilon}_{i,j,k} \\
\mathscr{M}_{\mu,\alpha} \quad &: \quad \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \boldsymbol{\varepsilon}_{i,j,k} \\
\mathscr{M}_{\mu,\beta} \quad &: \quad \mathbf{Y}_{i,j,k} = \mu + \beta_j + \boldsymbol{\varepsilon}_{i,j,k} \\
\mathscr{M}_{\mu,\alpha,\beta} \quad &: \quad \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \beta_j + \boldsymbol{\varepsilon}_{i,j,k} \\
\mathscr{M}_{\alpha,\beta,\mu,\gamma} \quad &: \quad \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \beta_j + \gamma_{i,j} + \boldsymbol{\varepsilon}_{i,j,k}
\end{aligned}
$$

- $\mathscr{M}_{\mu,\alpha,\beta,\gamma}$: modèle complet.
  - Prend en compte tous les phénomènes, mais comporte beaucoup de paramètres.
- $\mathscr{M}_{\mu,\alpha,\beta}$: modèle additif.
  - Il suppose l'absence d'interaction entre les facteurs.

Test des interactions

- Avant de réaliser des tests sur l'influence des facteurs pris indépendamment, il est important de tester l'interaction de ces derniers.

- Le test est le suivant :

$$(\mathscr{H}_0) : \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \beta_j + \boldsymbol{\varepsilon}_{i,j,k} \qquad \text{contre} \qquad (\mathscr{H}_1) : \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \beta_j + \gamma_{i,j} + \boldsymbol{\varepsilon}_{i,j,k} \ .$$

- Il s'agit d'un test de modèles emboîtés (ou sous-modèles) : on réalise donc un test de Fisher (de comparaison de modèles).

  - La statistique de test est :

$$F = \frac{\dfrac{1}{\mathrm{rg}\left(X^{(\mu,\alpha,\beta,\gamma)}\right) - \mathrm{rg}\left(X^{(\mu,\alpha,\beta)}\right)} \left(\mathrm{SCR}_{\mu,\alpha,\beta} - \mathrm{SCR}_{\mu,\alpha,\beta,\gamma}\right)}{\dfrac{1}{n - \mathrm{rg}\left(X^{(\mu,\alpha,\beta,\gamma)}\right)} \mathrm{SCR}_{\mu,\alpha,\beta,\gamma}} \ .$$

  - Sous $(\mathscr{H}_0)$, $F \sim \mathscr{F}\left((I-1)(J-1), n-IJ\right)$, et on rejette $(\mathscr{H}_0)$ au seuil de 1ère espèce α si $F > q_{1-\alpha}^{\mathscr{F}((I-1)(J-1), n-IJ)}$.

Sous R

```
model2 <- lm(logabondance ~ sector + grazing,
             data = apollo)

anova(model1, model2)
```

```
Analysis of Variance Table

Model 1: logabondance ~ sector * grazing
Model 2: logabondance ~ sector + grazing
  Res.Df    RSS Df Sum of Sq     F Pr(>F)
1     92 251.54
2     95 263.41 -3   -11.869 1.447 0.2343
```

- La p-valeur du test est élevée : au risque d'erreur de 1ère espèce de 5%, on ne peut pas conclure qu'il y a une interaction.

- Nous considérons donc dans la suite qu'il n'y a pas d'interaction, et nous sommes ramenés au modèle :

$$\mathbf{Y}_{i,j,k} = \mu + \alpha_i + \beta_j + \boldsymbol{\varepsilon}_{i,j,k} .$$

Plan

1. Introduction

2. Analyse de variance à un facteur is back !

3. Analyse de variance à deux facteurs fixes

   (a) Modèle régulier & Modèle singulier

   (b) Validation du modèle & Test du modèle

   (c) Tests d'effet des facteurs

   (d) Analyse de variance à 3 facteurs

4. Analyse de la covariance

5. Quelques méthodes de régressions avancées

Tests d'effet des facteurs (1)

- Si nous avons pu montrer l'absence (statistique) dune interaction, alors nous définissons le modèle sans interaction et nous testons l'effet de chaque facteur restant.



- Si le test des interactions rejette l'hypothèse nulle, alors il n'y a pas de sens à tester les facteurs séparément ! (Il ne peut y avoir d'interaction entre les facteurs sans les facteurs.)

Tests d'effet des facteurs (2)

- Dans l'exemple du jeu de données apollo, nous souhaitons savoir si la variable grazing est pertinente dans le modèle model2.

- Nous souhaitons donc comparer les deux modèles :

$$\mathscr{M}_{\mu,\alpha,\beta} : \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \beta_j + \boldsymbol{\varepsilon}_{i,j,k} \qquad \text{et} \qquad \mathscr{M}_{\mu,\alpha} : \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \boldsymbol{\varepsilon}_{i,j,k} \ .$$

```
model3 <- lm(logabondance ~ sector,
             data = apollo)

anova(model3, model2)
```

Tests d'effet des facteurs (3)

```
Analysis of Variance Table

Model 1: logabondance ~ sector
Model 2: logabondance ~ sector + grazing
  Res.Df    RSS Df Sum of Sq     F Pr(>F)
1     96 263.51
2     95 263.41  1   0.10548 0.038 0.8458
```

- La p-valeur du test est élevée : au risque d'erreur de 1ère espèce de 5%, on ne peut pas conclure que le mode de gestion a une influence sur l'abondance du papillon Apollon.

- Nous considérons donc dans la suite le modèle $\mathscr{M}_{\mu,\alpha}$ sans le second facteur :

$$\mathbf{Y}_{i,j,k} = \mu + \alpha_i + \boldsymbol{\varepsilon}_{i,j,k} .$$

Tests d'effet des facteurs (4)

- Nous pouvons ensuite tester l'influence de la variable sector sur l'abondance du papillon Apollon dans le modèle model3.

- Puisque le modèle model3 retenu correspond à $\mathcal{M}_{\mu,\alpha}$, il s'agit donc de réaliser une analyse de variance à un facteur.

- Nous renvoyons à la partie sur l'analyse de variance à un facteur pour conclure sur la pertinence de ce facteur et à cette diapositive pour l'analyse sous R.

Tests d'effet des facteurs (5)

- Si nous avions précédemment, conclut que le facteur grazing influençait la variable d'intérêt, nous aurions comparé les modèles :

$$\mathscr{M}_{\mu,\alpha,\beta} : \mathbf{Y}_{i,j,k} = \mu + \alpha_i + \beta_j + \boldsymbol{\varepsilon}_{i,j,k} \quad \text{et} \quad \mathscr{M}_{\mu,\beta} : \mathbf{Y}_{i,j,k} = \mu + \beta_j + \boldsymbol{\varepsilon}_{i,j,k} \, .$$

```
model4 <- lm(logabondance ~ grazing,
             data = apollo)

anova(model4, model3)
```

```
Analysis of Variance Table

Model 1: logabondance ~ grazing
Model 2: logabondance ~ sector
  Res.Df    RSS Df Sum of Sq      F    Pr(>F)
1     98 442.73
2     96 263.51  2    179.22 32.645 1.527e-11 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

La p-valeur étant très faible, nous aurions au risque d'erreur de 1ère espèce de 5%, que le facteur sector influence la variable d'intérêt, c'est-à-dire que nous aurions conservé le modèle $\mathscr{M}_{\mu,\alpha,\beta}$.

Plan

1. Introduction

2. Analyse de variance à un facteur is back !

3. Analyse de variance à deux facteurs fixes

   (a) Modèle régulier & Modèle singulier

   (b) Validation du modèle & Test du modèle

   (c) Tests d'effet des facteurs

   (d) Analyse de variance à 3 facteurs

4. Analyse de la covariance

5. Quelques méthodes de régressions avancées

Passage à 3 facteurs ?

- Si nous souhaitons procéder à une ANOVA à 3 facteurs, nous procéderons de la même façon.

- Le modèle s'écrit alors de la manière suivante :

$$\mathbf{Y}_{i,j,k,l} = \mu + \underbrace{\alpha_i + \beta_j + \gamma_k}_{\text{Effets des facteurs}} + \underbrace{\delta_{i,j} + \zeta_{i,k} + \eta_{j,k}}_{\text{Effets des interactions 2 à 2}} + \underbrace{\theta_{i,j,k}}_{\text{Effet de l'interaction des 3 facteurs}} + \boldsymbol{\varepsilon}_{i,j,k,l} .$$

Plan

1. Introduction

2. Analyse de variance à un facteur is back !

3. Analyse de variance à deux facteurs fixes

4. Analyse de la covariance

   (a) Modèle

   (b) Inférence

5. Quelques méthodes de régressions linéaires factorielles avancées

Plan

1. Introduction

2. Analyse de variance à un facteur is back !

3. Analyse de variance à deux facteurs fixes

4. Analyse de la covariance

   (a) Modèle

   (b) Inférence

5. Quelques méthodes de régressions linéaires factorielles avancées

Contexte

- Analyse de la covariance : mélange de variables explicatives quantitatives continues et qualitatives

- Exemple avec une variable explicative quantitative continue x et un facteur :
  - s'il y a I modalités pour le facteur ;
  - s'il y a n_i observations pour la i-ème modalité ;
  - alors pour tout $i \in \{1,\dots,I\}$, nous rassemblons ces n_i observations :
    - $(y_{i,j})_{1\leq j\leq n_i}$ pour la variable d'intérêt y ; ainsi que
    - $(x_{i,j})_{1\leq j\leq n_i}$ pour la variable explicative quantitative x.

- Nous avons alors, possiblement, une régression sur la variable quantitative x différente selon les niveaux du facteur !

Illustration (1)

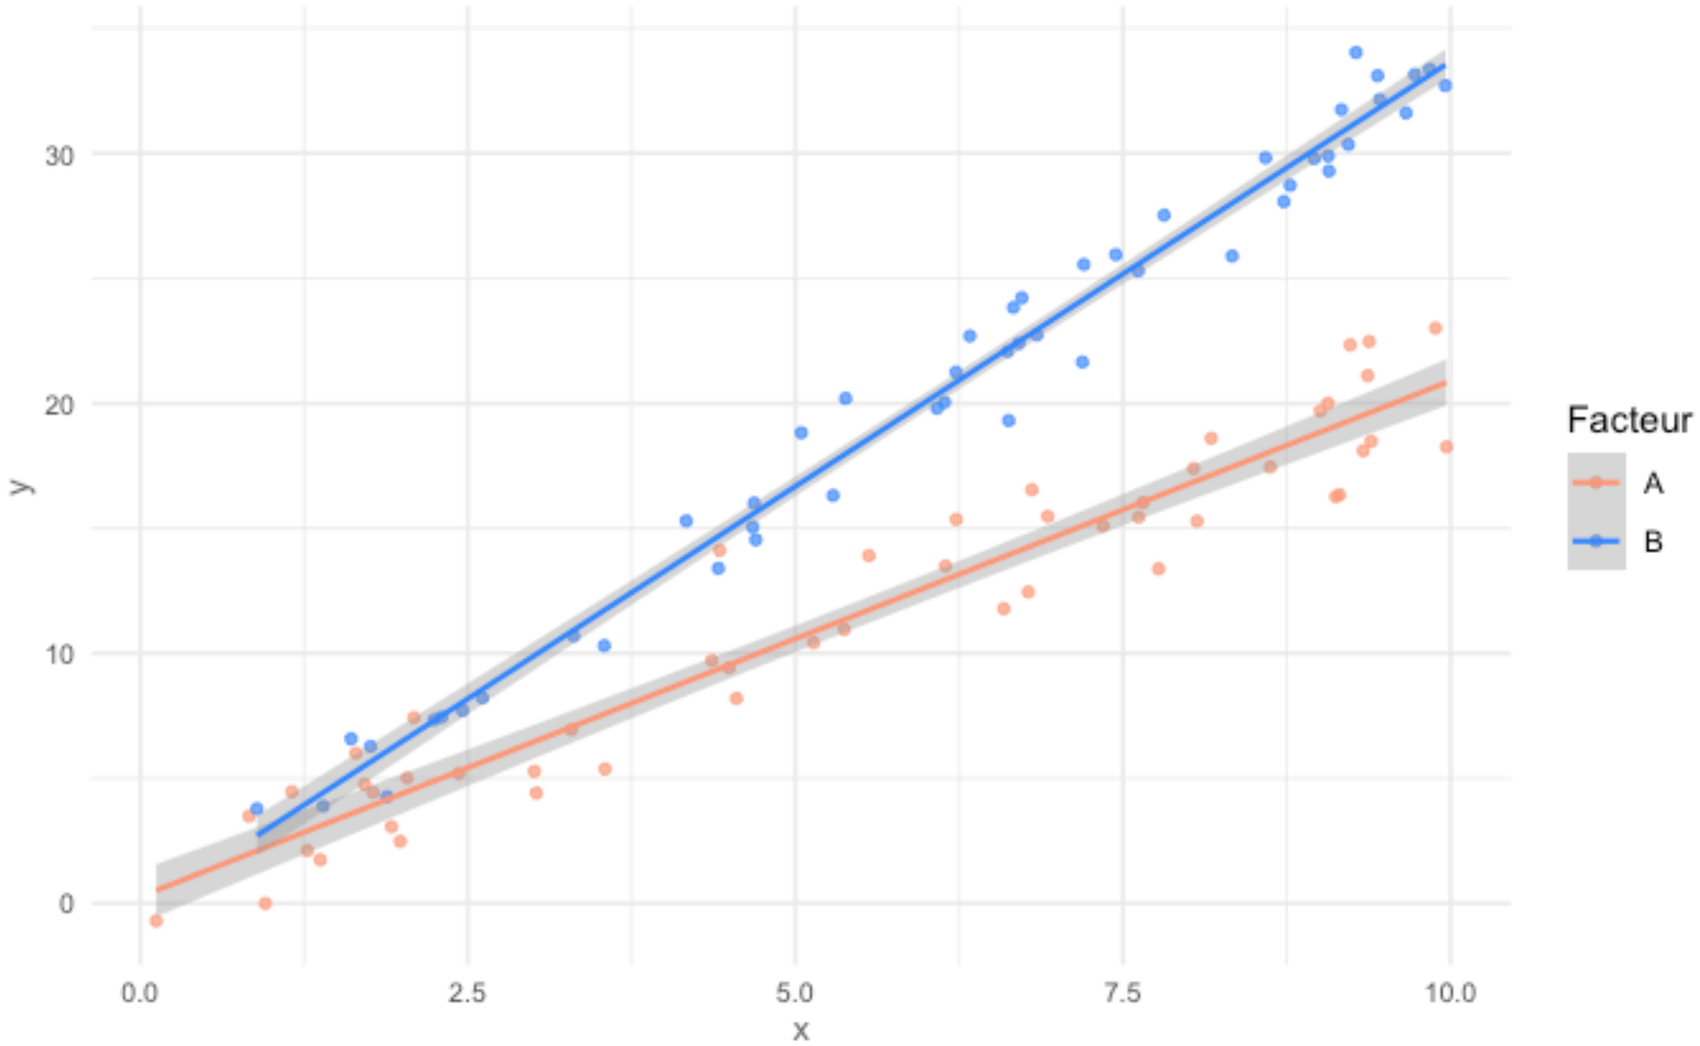
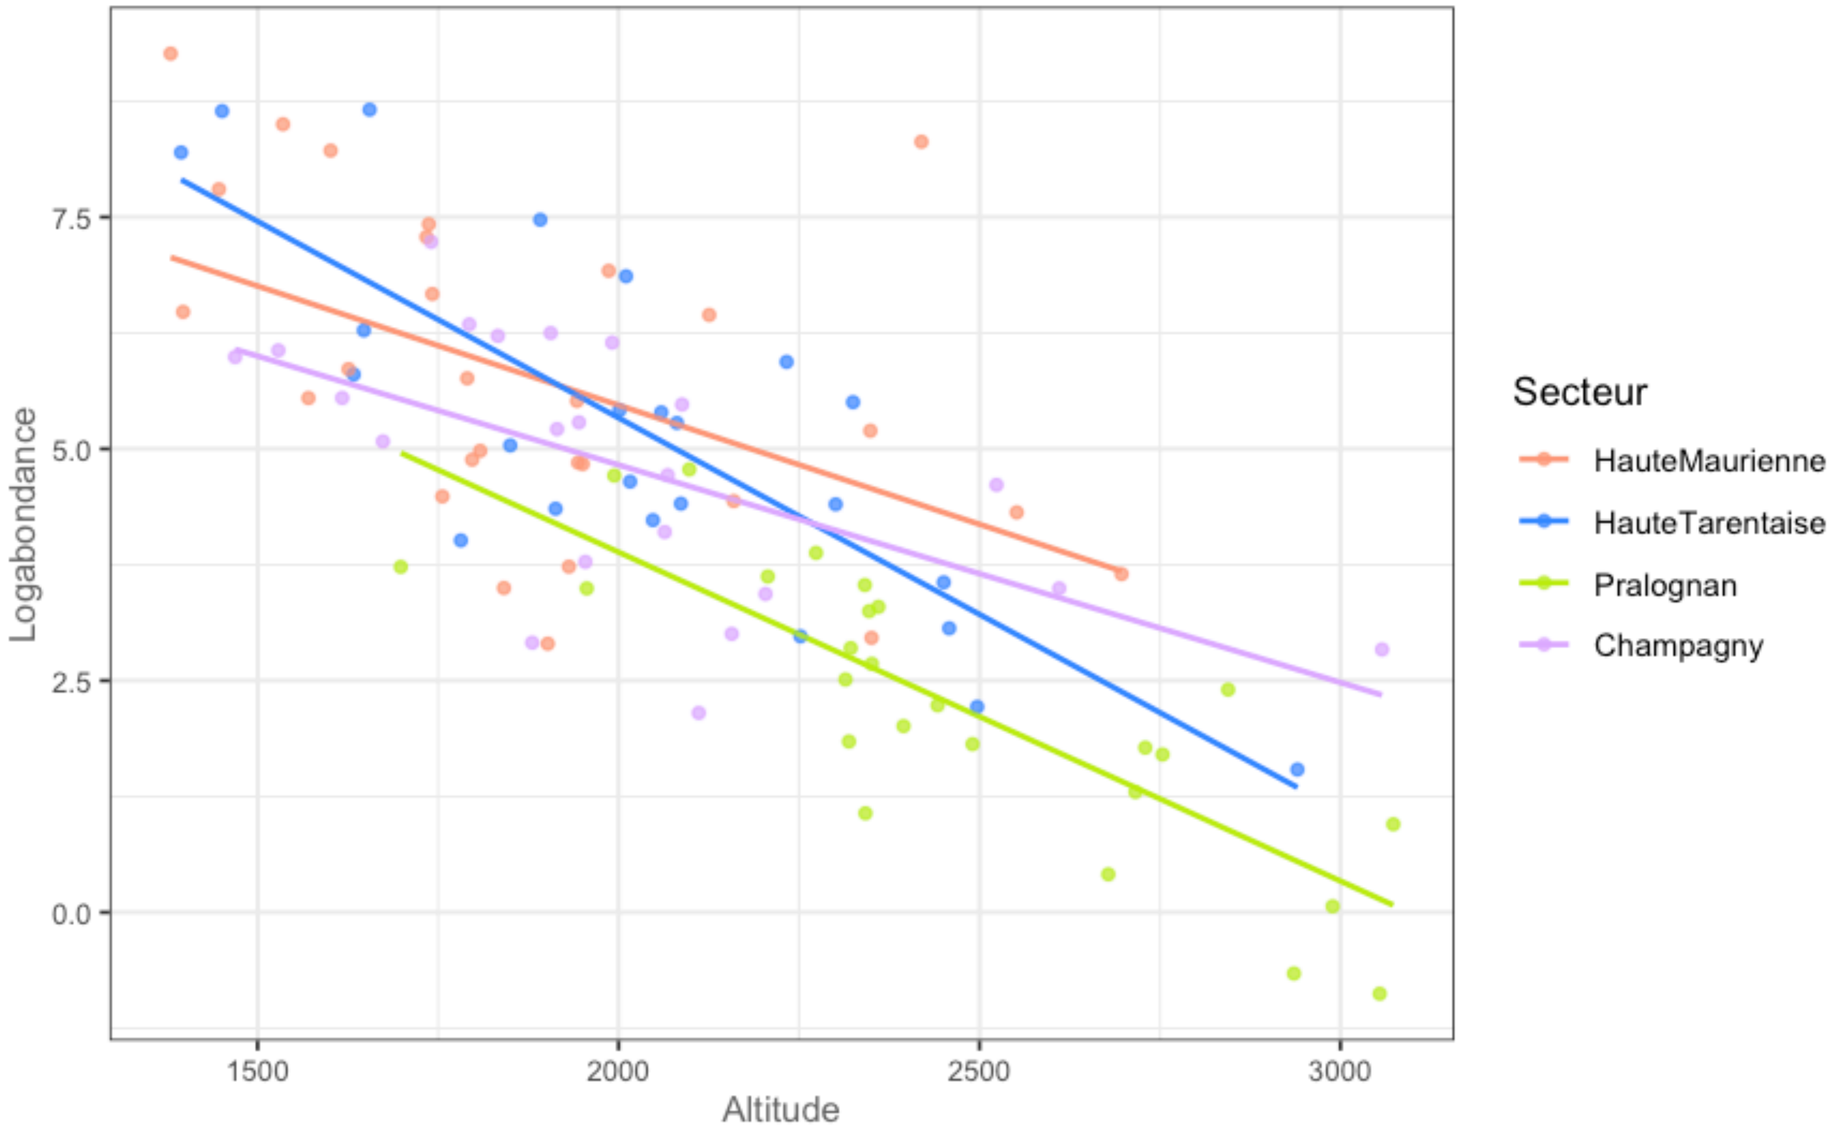


Illustration (2)



Modèle

- Nous supposons que $y_{i,j}$ est la réalisation d'une variable aléatoire $\mathbf{Y}_{i,j}$ avec :

$$\mathbf{Y}_{i,j} = b_i + a_i x_{i,j} + \boldsymbol{\varepsilon}_{i,j}, \quad i \in \{1,\dots,I\}, j \in \{1,\dots,n_i\},$$

où

  - les erreurs $\boldsymbol{\varepsilon}_{i,j} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,\sigma^2)$; et
  - les paramètres a_i, b_i sont inconnus et fixes (déterministes).

- Cela correspond au modèle complet (le plus complexe) :
  - il y a autant de droites de régression que de modalités du facteur.



- Vigilance ! Le σ^2 est commun à toutes les données.

Modèle singulier

- Le modèle singulier

$$\mathbf{Y}_{i,j} = b_i + a_i x_{i,j} + \boldsymbol{\varepsilon}_{i,j}, \quad i \in \{1,\dots,I\}, j \in \{1,\dots,n_i\},$$

peut se réécrire sous la forme suivante :

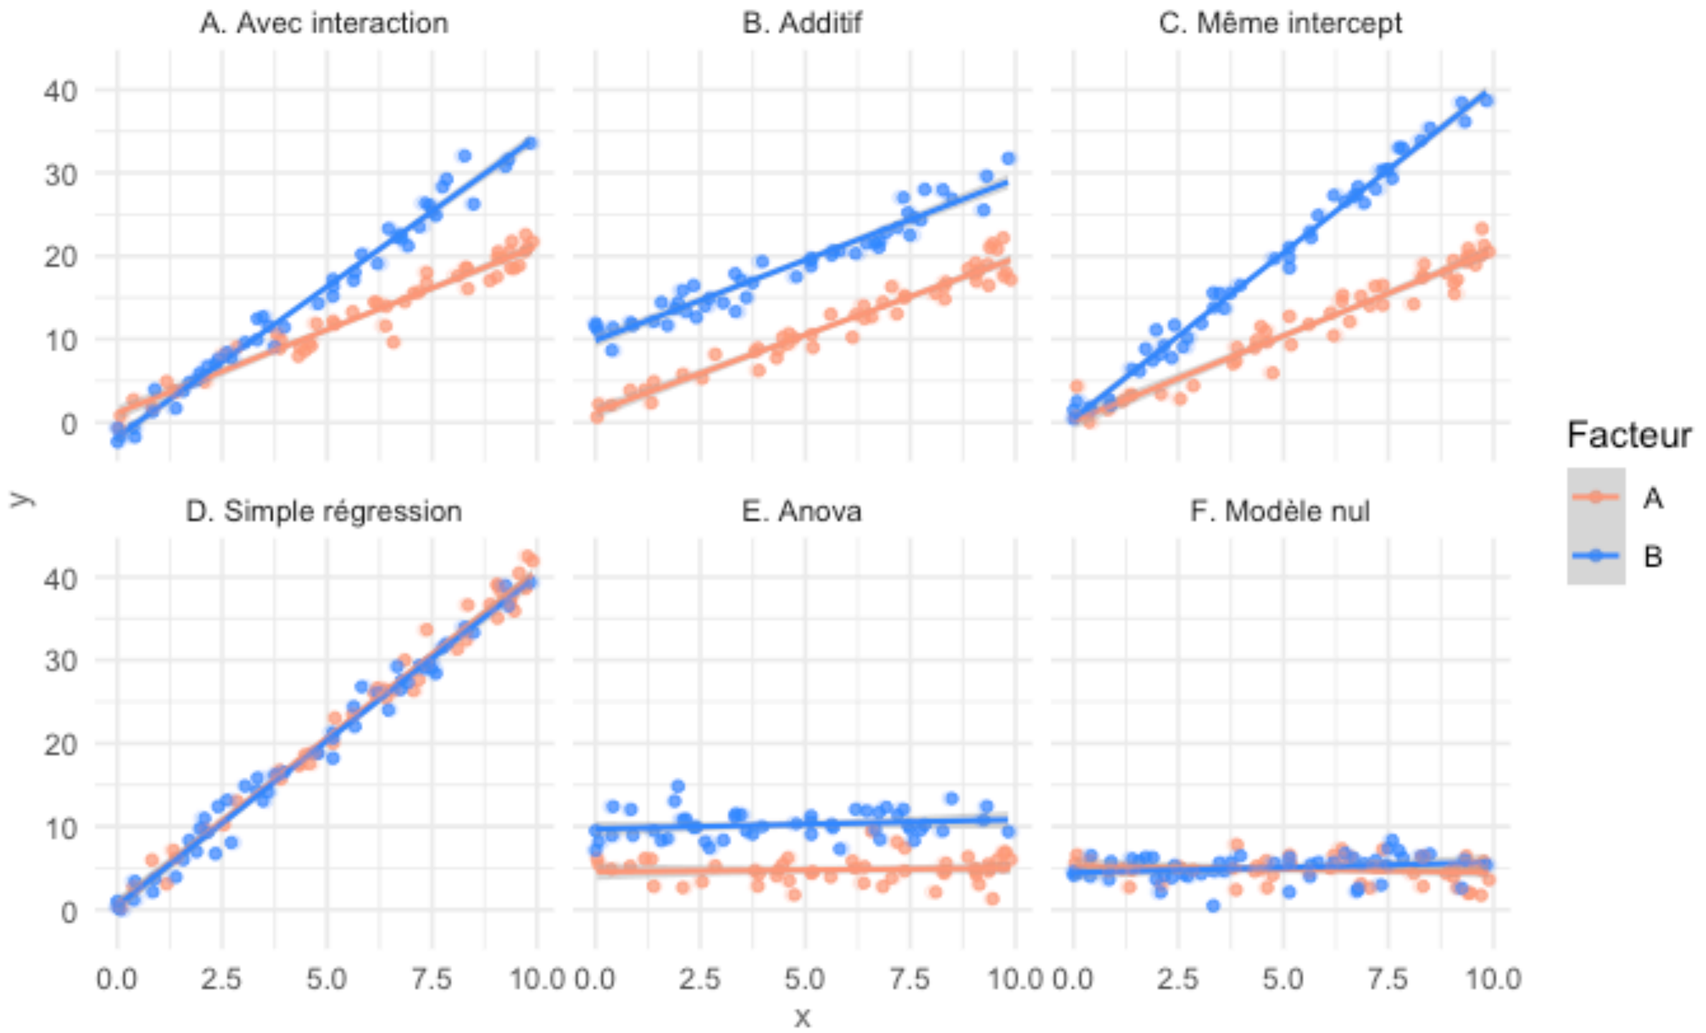
$$\mathbf{Y}_{i,j} = (\mu + \beta_i) + (\alpha + \gamma_i) x_{i,j} + \boldsymbol{\varepsilon}_{i,j}, \quad i \in \{1,\dots,I\}, j \in \{1,\dots,n_i\},$$

où :

- μ : ordonnée à l'origine moyenne des droites de régression
- α : pente moyenne des droites de régression
- β_i : effet de la modalité i sur l'ordonnée à l'origine
- γ_i : interaction entre la modalité i et la variable explicative quantitative (effet sur la pente)

Sous-modèles (1)

- Plusieurs cas de figures peuvent se présenter !



Sous-modèles (2)

A. Modèle complet : $\mathbf{Y}_{i,j} = \mu + \beta_i + (\alpha + \gamma_i)\, x_{i,j} + \boldsymbol{\varepsilon}_{i,j}$.

B. Modèle additif = modèle à interactions nulles :

$$\mathbf{Y}_{i,j} = \mu + \beta_i + \alpha\, x_{i,j} + \boldsymbol{\varepsilon}_{i,j} .$$

C. $\beta_i = 0$ pour tout i = les pentes sont différentes, mais même ordonnée à l'origine :

$$\mathbf{Y}_{i,j} = \mu + (\alpha + \gamma_i)\, x_{i,j} + \boldsymbol{\varepsilon}_{i,j} .$$

D. $\beta_i = \gamma_i = 0$ pour tout i = le facteur n'a pas d'effet :

$$\mathbf{Y}_{i,j} = \mu + \alpha\, x_{i,j} + \boldsymbol{\varepsilon}_{i,j} .$$

E. $\alpha_i = \gamma_i = 0$ = la covariable n'a pas d'effet :

$$\mathbf{Y}_{i,j} = \mu + \beta_i + \boldsymbol{\varepsilon}_{i,j} .$$

F. Modèle nul = $\beta_i = \alpha_i = \gamma_i = 0$:

$$\mathbf{Y}_{i,j} = \mu + \boldsymbol{\varepsilon}_{i,j} .$$

Plan

1. Introduction

2. Analyse de variance à un facteur is back !

3. Analyse de variance à deux facteurs fixes

4. Analyse de la covariance

   (a) Modèle

   (b) Inférence

5. Quelques méthodes de régressions linéaires factorielles avancées

Inférence (I)

- Toute l'inférence se passe de la même manière que précédemment.
  - Nous pouvons montrer que les estimateurs des moindres carrés des paramètres (a_i, b_i) sont obtenus en faisant la régression de y contre la variable x pour les données de la modalité i.
  - Les paramètres du modèle singulier sont non-identifiables.
    - Il faut imposer des contraintes.
    - R impose comme attendu $\beta_1 = \gamma_1 = 0$.
    - Nous obtenons l'estimation des paramètres du modèle singulier à partir de celle des (a_i, b_i).

Inférence (2)

- Notons la valeur ajustée

$$\hat{y}_{i,j} = \hat{b}_i + \hat{a}_i \, x_{i,j} \, .$$

- Alors la variance σ^2 est estimée sans biais par :

$$\hat{\sigma}^2 = \frac{1}{n-2I} \sum_{i=1}^{I} \sum_{j=1}^{n_i} \left(y_{i,j} - \hat{y}_{i,j} \right)^2 \, .$$

- Les tests d'effets du facteur et de la covariable seront effectués en comparant les SCR des différents modèles en compétition.
  - Nous prendrons en compte le nombre de paramètres dans chaque modèle.
  - Nous pouvons utiliser la fonction anova().

Interprétation des coefficients (1)

```
anco1 <- lm(logabondance ~ altitude_index * sector,
            data = apollo)

summary(anco1)
```

```
Call:
lm(formula = logabondance ~ altitude_index * sector, data = apollo)

Residuals:
    Min      1Q  Median      3Q     Max
-2.8249 -0.9039  0.0444  0.8614  3.9202

Coefficients:
                                  Estimate Std. Error t value Pr(>|t|)
(Intercept)                     10.6118544  1.3182272   8.050 2.83e-12 ***
altitude_index                  -0.0025702  0.0006849  -3.753 0.000306 ***
sectorHauteTarentaise            3.2032243  1.9643181   1.631 0.106371
sectorPralognan                  0.3716806  2.1691158   0.171 0.864324
sectorChampagny                 -1.0896893  1.9813950  -0.550 0.583679
altitude_index:sectorHauteTarentaise -0.0016701  0.0009817  -1.701 0.092278 .
altitude_index:sectorPralognan  -0.0009785  0.0009742  -1.004 0.317832
altitude_index:sectorChampagny   0.0002226  0.0009982   0.223 0.823991
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.213 on 92 degrees of freedom
Multiple R-squared:  0.7002,    Adjusted R-squared:  0.6774
F-statistic:  30.7 on 7 and 92 DF,  p-value: < 2.2e-16
```

- Intercept : ordonnée à l'origine de la droite de l'abondance en fonction de l'altitude, en région Haute Maurienne.

- altitude_index : pente de la droite de l'abondance en fonction de l'altitude, en région Haute Maurienne.

Interprétation des coefficients (2)

```
anco1 <- lm(logabondance ~ altitude_index * sector,
            data = apollo)

summary(anco1)
```

```
Call:
lm(formula = logabondance ~ altitude_index * sector, data = apollo)

Residuals:
    Min      1Q  Median      3Q     Max
-2.8249 -0.9039  0.0444  0.8614  3.9202

Coefficients:
                                   Estimate Std. Error t value Pr(>|t|)
(Intercept)                      10.6118544  1.3182272   8.050 2.83e-12 ***
altitude_index                   -0.0025702  0.0006849  -3.753 0.000306 ***
sectorHauteTarentaise             3.2032243  1.9643181   1.631 0.106371
sectorPralognan                   0.3716806  2.1691158   0.171 0.864324
sectorChampagny                  -1.0896893  1.9813950  -0.550 0.583679
altitude_index:sectorHauteTarentaise -0.0016701  0.0009817  -1.701 0.092278 .
altitude_index:sectorPralognan   -0.0009785  0.0009742  -1.004 0.317832
altitude_index:sectorChampagny    0.0002226  0.0009982   0.223 0.823991
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.213 on 92 degrees of freedom
Multiple R-squared:  0.7002,    Adjusted R-squared:  0.6774
F-statistic:  30.7 on 7 and 92 DF,  p-value: < 2.2e-16
```

- `Pralognan` : effet du passage à la région Pralognan sur l'ordonnée à l'origine de la droite d'abondance en fonction de l'altitude.

- `altitude_index:Pralognan` : effet du passage à la région Pralognan sur la pente de la droite d'abondance en fonction de l'altitude.

Sous R : Modèle d'Ancova & Test de l'interaction

```
anco1 <- lm(logabondance ~ altitude_index * sector,
            data = apollo)

summary(anco1)
```

```
Call:
lm(formula = logabondance ~ altitude_index * sector, data = apollo)

Residuals:
    Min      1Q  Median      3Q     Max
-2.8249 -0.9039  0.0444  0.8614  3.9202

Coefficients:
                                   Estimate Std. Error t value Pr(>|t|)
(Intercept)                      10.6118544  1.3182272   8.050 2.83e-12 ***
altitude_index                   -0.0025702  0.0006849  -3.753 0.000306 ***
sectorHauteTarentaise             3.2032243  1.9643181   1.631 0.106371
sectorPralognan                   0.3716806  2.1691158   0.171 0.864324
sectorChampagny                  -1.0896893  1.9813950  -0.550 0.583679
altitude_index:sectorHauteTarentaise -0.0016701  0.0009817  -1.701 0.092278 .
altitude_index:sectorPralognan   -0.0009785  0.0009742  -1.004 0.317832
altitude_index:sectorChampagny    0.0002226  0.0009982   0.223 0.823991
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.213 on 92 degrees of freedom
Multiple R-squared:  0.7002,    Adjusted R-squared:  0.6774
F-statistic:  30.7 on 7 and 92 DF,  p-value: < 2.2e-16
```

- Il est possible de tester la significativité des coefficients d'interaction.
- Il suffit de regarder la p-valeur des correspondants au coefficient des termes d'interactions.

Modèle sans interaction & Test

```r
anco2 <- lm(logabondance ~ orientation_index + sector,
            data = apollo)

anova(anco2, anco1)
```

```
Analysis of Variance Table

Model 1: logabondance ~ altitude_index + sector
Model 2: logabondance ~ altitude_index * sector
  Res.Df    RSS Df Sum of Sq      F Pr(>F)
1     95 142.21
2     92 135.34  3    6.8598 1.5543 0.2059
```

- Le test de l'interaction du facteur et de la variable quantitative peut également se faire via la fonction anova() (vu précédemment).

- Ici la p-valeur est élevée (0.2059), donc au risque d'erreur de 1ère de 5% nous ne rejetons pas $(\mathscr{H}_0)$: nous ne pouvons pas conclure qu'il y a une interaction.

Test de l'effet du facteur après ajustement de la covariable

- Une fois la non-interaction des variables établie, nous pouvons tester l'effet du facteur (et de la variable explicative quantitative).

- Une nouvelle fois, ce test peut se réaliser via la fonction anova().

```
anova(anco2)
```

```
Analysis of Variance Table

Response: logabondance
               Df  Sum Sq Mean Sq  F value    Pr(>F)
altitude_index  1 275.089 275.089 183.7740 < 2.2e-16 ***
sector          3  34.191  11.397   7.6137  0.000129 ***
Residuals      95 142.205   1.497
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- La p-valeur du test d'effet de la variable facteur est très basse (0.000129), alors avec un risque d'erreur de 1ère espèce de 5%, nous pouvons conclure que le secteur à un effet sur l'abondance du papillon Apollon.

Plan

1. Introduction
2. Analyse de variance à un facteur is back !
3. Analyse de variance à deux facteurs fixes
4. Analyse de covariance
5. Quelques méthodes de régressions avancées

D'autres modèles à explorer

- Analyse de la variance avec des facteurs aléatoires
- Modèles linéaires non gaussien : Modèles linéaires généralisés (glm)
  - Régression logistique, Régression de Poisson, etc.
- Modèles linéaires mixtes (généralisés)
- Modèles de régression non-linéaires

This is the end of this chapter !

What will we do next time ?

Partie II. Réduction de dimension

Remarque sur la décomposition de variance

- En utilisant la décomposition :

$$y_{i,j} - \bar{y} = y_{i,j} - \bar{y}_i + \bar{y}_i - \bar{y} ,$$

nous pouvons montrer que :

$$\underbrace{\sum_{i,j} (y_{i,j} - \bar{y})^2}_{\text{Variation totale}} = \underbrace{\sum_{i=1}^{I} n_i (\bar{y}_i - \bar{y})^2}_{\text{Variation inter-groupes}} + \underbrace{\sum_{i,j} (y_{i,j} - \bar{y}_i)^2}_{\text{Variation intra-groupes}} .$$

C'est la formule : $\quad SCT = SCM + SCR$