Chapitre 3. Réduction de Dimension : Analyse en Composantes Principales

Introduction compréhensive à l'analyse statistique (linéaire) multivariée

École d'ingénieur.e.s en Agronomie & Agroalimentaire - 2e année

Léo Dort leo.dort@institut-agro.fr

Ressources & Références pour ce chapitre

- Ressource Rmarkdown compagnon : ACP.Rmd

- Références principales : Ce cours est tiré des (avec quelques légères modifications.)
  - cours de Julien Chiquet (DR INRAe) ; et
  - cours de François Husson (Prof. Institut Agro Rennes-Angers)



- Livres :
  - Analyse factorielle multiple avec R, de Jérome Pagès
  - Analyses factorielles simple et multiple, de Brigitte Escoffier & Jérome Pagès

Exemple compagnon du chapitre

Mesures morphologiques du crabe Leptograpsus variegatus

Le jeu de données crabs possède 200 lignes et 8 colonnes, décrivant 5 mesures morphologiques de 200 individus (50 des deux couleurs et deux sexes), de l'espèce Leptograpsus variergatus.

```
crabs <- MASS::crabs
```

```
head(crabs)
```

	sp <fctr>	sex <fctr>	index <int>	FL <dbl>	RW <dbl>	CL <dbl>	CW <dbl>	BD <dbl>
1	B	M	1	8.1	6.7	16.1	19.0	7.0
2	B	M	2	8.8	7.7	18.1	20.8	7.4
3	B	M	3	9.2	7.8	19.0	22.4	7.7
4	B	M	4	9.6	7.9	20.1	23.1	8.2
5	B	M	5	9.8	8.0	20.3	23.0	8.2

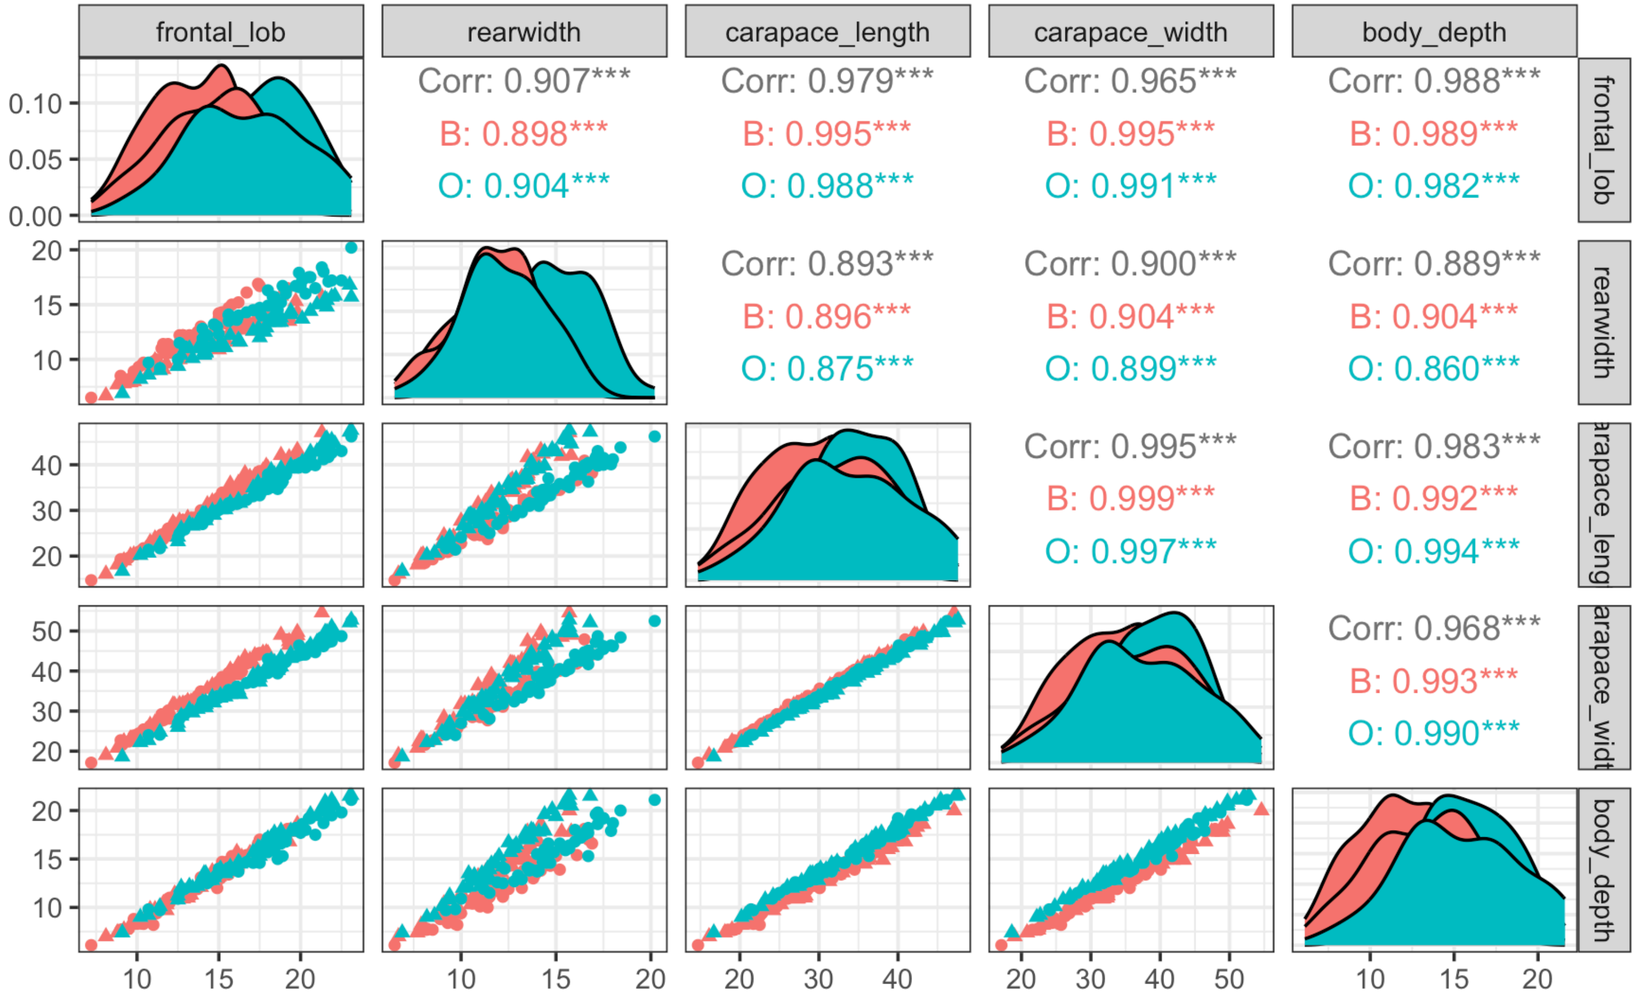


Source : Wikipédia

Exemple compagnon du chapitre

Mesures morphologiques du crabe Leptograpsus variegatus

```
ggpairs(
  data = crabs,
  columns = 3:7,
  aes(
    colour = species,
    shape = sex
    )
  )
```



Objectifs d'une réduction de dimension

- Objectif principal : trouver une représentation des données dans un espace de plus faible dimension capturant l'essence des données (en grande dimension).

- Application en Apprentissage Automatique (Machine Learning) (Préprocessing, Régularisation)
  - Compression, débruitage, détection d'anomalies
  - Réduire le sur-apprentissage en apprentissage supervisé

- Application en Statistique et Analyse de données (Meilleures compréhension des données)
  - Méthodes descriptives et d'exploration de données de grande dimension
  - Visualisation (difficile de visualiser et interpréter des données en $> 3d$)

Qu'est-ce qu'une réduction de dimension ?

- Cadre de travail :
  - Ensemble d'entrainement : $\mathscr{D} = \{x_1, \ldots, x_n\}$, où $x_i \in \mathbb{R}^p$.
  - L'espace $\mathbb{R}^p$ est possiblement de grande dimension (p très grand, ou p très grand par rapport à n).

- Réduction de dimension :
  - Construire une application Φ de l'espace $\mathbb{R}^p$ à valeurs dans l'espace $\mathbb{R}^q$ de plus petite dimension.
  - Cette application doit permettre de « conserver au maximum » les relations entre individus, les relations entre les variables, et doit permettre de réaliser des interprétations.

Exemples d'utilisation de méthodes de réduction de dimension

- Analyse sensorielle : note du jury j sur le produit i
- Marketing : valeur d'indice de satisfaction j pour la marque i
- Écologie : caractéristique physicochimique j du sol i
- Économie : valeur de l'indicateur j pour l'année i
- Génétique : expression du gène j pour le patient i
- Biologie : mesure morphologique j pour l'animal i
- etc.

Focus sur l'ACP

- L'analyse en composantes principales est une méthode de réduction de dimension pour des données continues.

- Pour des données non-continues, il existe :
  - l'analyse factorielle des correspondances : données sous forme de table de contingence ;
  - l'analyse des correspondances multiples : variables catégorielles ;
  - l'analyse factorielle multiple : données mixtes, multi-tableaux.

- Ces méthodes sont toutes basées sur l'analyse en composantes principales, mais adaptées à des données non-continues.

Nous nous focalisons sur l'ACP. Les autres méthodes seront mises en pratique en TD.

Plan

1. Problèmes & Objectifs
2. Axes principaux & Maximisation de variances
3. Représentations & Interprétations
4. D'autres types de données, d'autres analyses statistiques

Plan

1. Problèmes & Objectifs
2. Axes principaux & Maximisation de variances
3. Représentations & Interprétations
4. D'autres types de données, d'autres analyses statistiques

Quel type de données pour l'ACP ?

- L'ACP s'intéresse à des tableaux de données rectangulaires avec :
  - des individus en lignes ; et
  - des variables quantitatives (actives) en colonnes.

$\mathbf{X}$ =

	X_1	...	X_j	...	X_p
e_1	x_{11}	...	x_{1j}	...	x_{1p}
$\vdots$					
e_i	x_{i1}	...	x_{ij}	...	x_{ip}
$\vdots$					
e_n	x_{n1}	...	x_{nj}	...	x_{np}

p : nombre de variables actives

n : nombre d'individus

Deux points de vues

Tableau = ensemble de lignes OU ensembles de colonnes

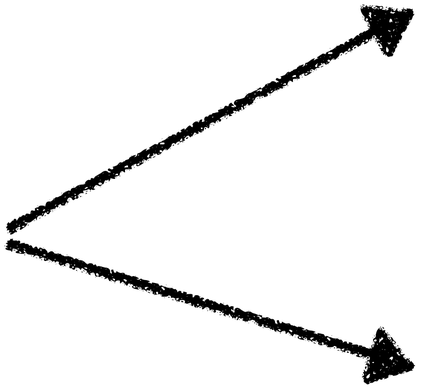
Variables ⟷

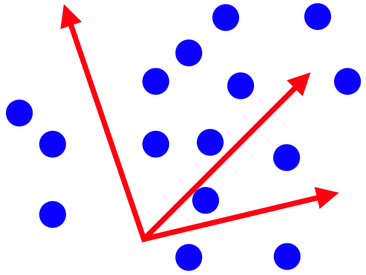
Individus ⟷

	X_1	...	X_j	...	X_p
e_1	x_{11}	...	x_{1j}	...	x_{1p}
⋮					
e_i	x_{i1}	...	x_{ij}	...	x_{ip}
⋮					
e_n	x_{n1}	...	x_{nj}	...	x_{np}

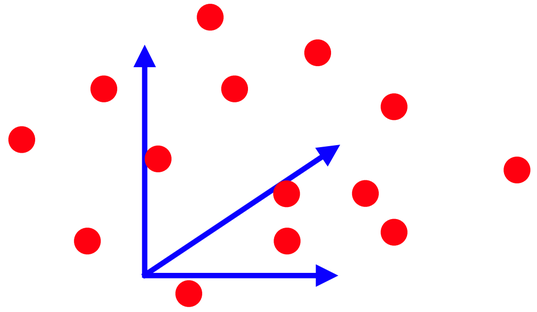
$\parallel$

$\bowtie$





n points (individus e_i) dans $\mathbb{R}^p$



p vecteurs (variables X_j) dans $\mathbb{R}^n$

Étude des individus

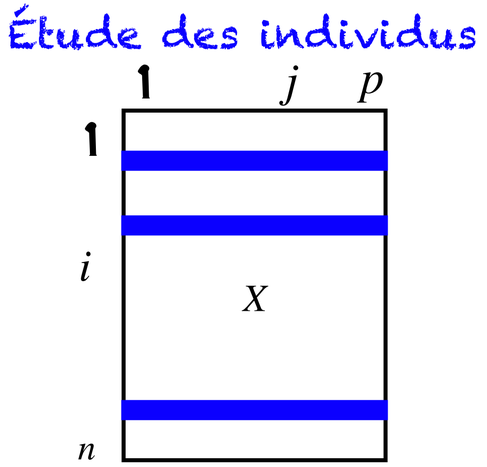
Tableau = ensemble de lignes OU ensembles de colonnes

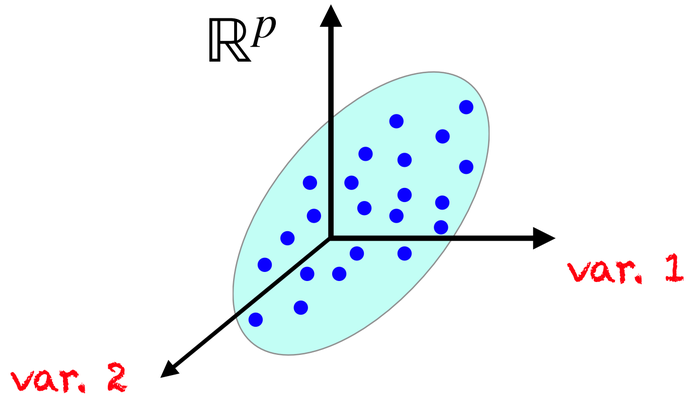
Étude des individus

- Construction de groupes d'individus se ressemblant du point de vue de l'ensemble des variables
- Bilan des ressemblances, partition des individus

Dans notre exemple :

- Un crabe est un individu, c'est-à-dire une ligne du tableau.
- Un crabe est représenté par un point à 5 coordonnées (toutes les variables ne sont pas nécessairement considérées).
- L'ensemble des 200 crabes forment un nuage de 200 points dans un espace à 5 dimensions.





Étude des variables

Tableau = ensemble de lignes OU ensembles de colonnes

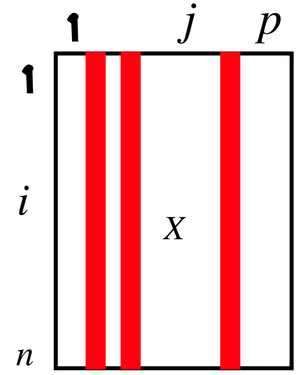
Étude des variables

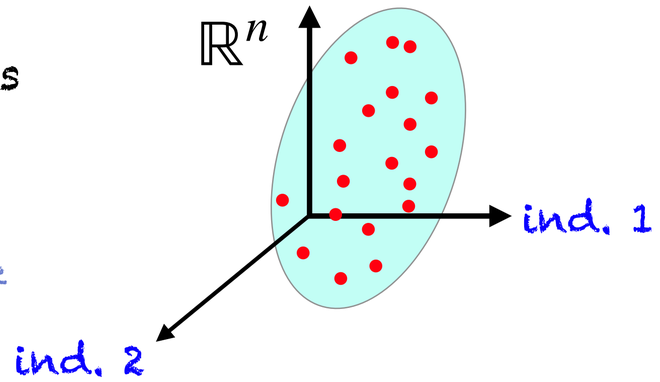
- Recherche de ressemblances, liaisons (linéaires) entre variables
- Bilan des liaisons : visualisation de la matrice des corrélations
- Recherche d'indicateurs synthétiques résumant les variables

Dans notre exemple :

- Un indicateur morphologique est une variable, c'est-à-dire une colonne du tableau.
- Un indicateur est représenté par un point à 200 coordonnées.
- L'ensemble des indicateurs forment un nuage de 5 points dans un espace à 200 dimensions.

Étude des variables





Lien entre les deux études

Tableau = ensemble de lignes OU ensembles de colonnes

Étude des individus

- Construction de groupes d'individus se ressemblant du point de vue de l'ensemble des variables
- Bilan des ressemblances, partition des individus

Étude des variables

- Recherche de ressemblances, liaisons (linéaires) entre variables
- Bilan des liaisons : visualisation de la matrice des corrélations
- Recherche d'indicateurs synthétiques résumant les variables

Lien entre les deux études

- Caractérisation des classes d'individus par les variables
- Individus spécifiques pour comprendre les liaisons entre variables

L'ACP en images (1)

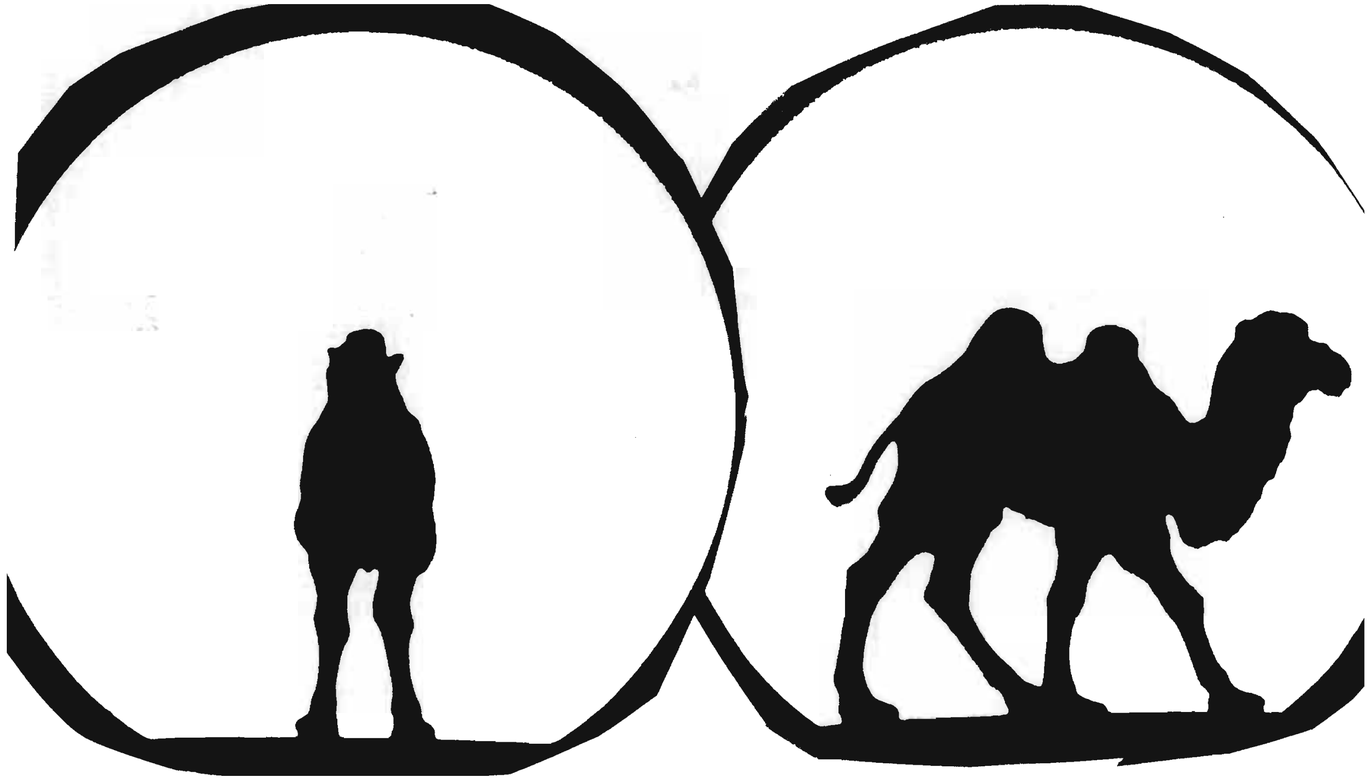
Exemple extrait du cours de François Husson.
Source J-P. Fénelon.



Quel animal voyez-vous ?

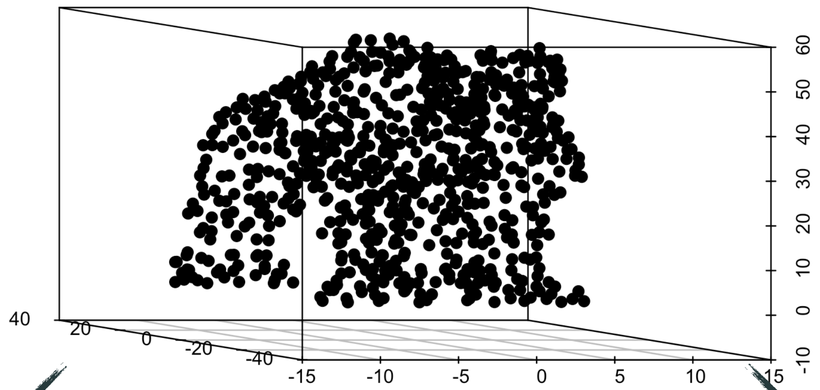
L'ACP en images (2)

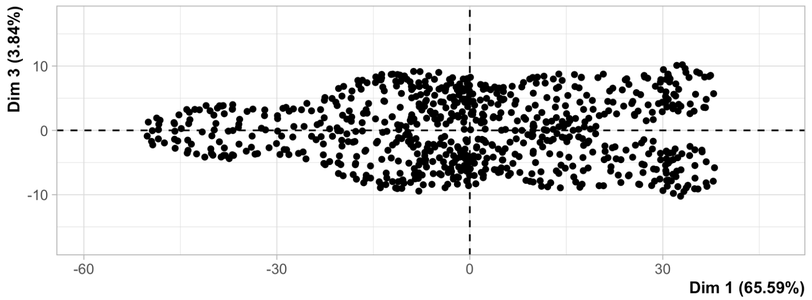
Exemple extrait du cours de François Husson.
Source J-P. Fénelon.

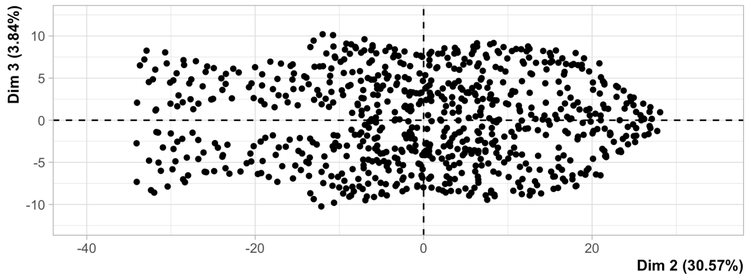


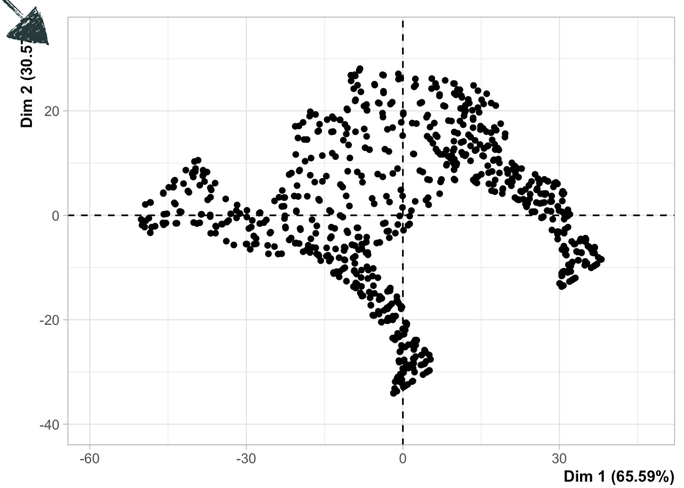
Quel animal voyez-vous ?

L'ACP en images (3)



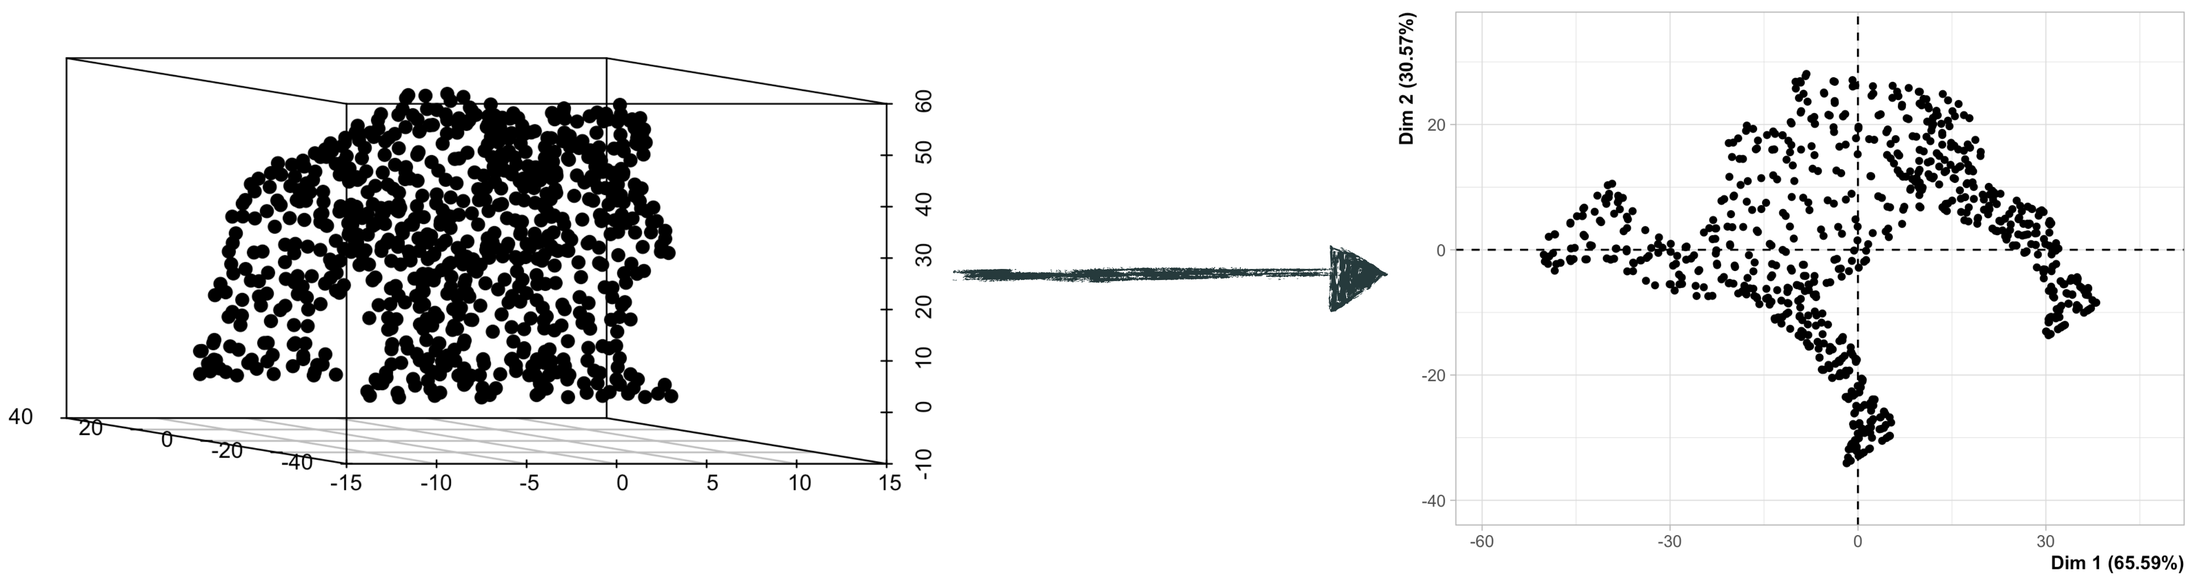






Réduction de dimension : Projection « intelligente » sur un sous-espace « minimal »

Problèmatique



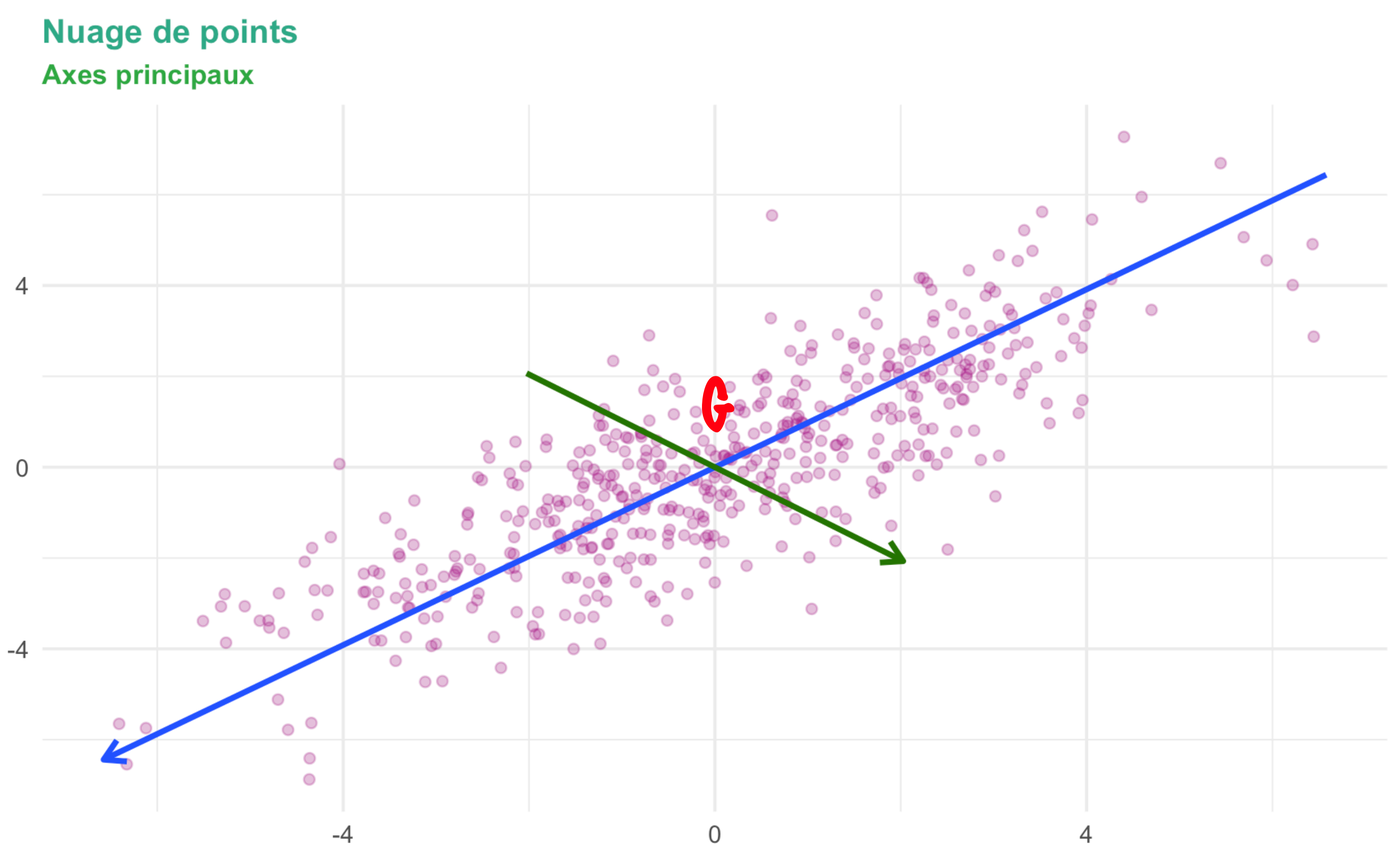
Comment déterminer la représentation de droite ?

Plan

1. Problèmes & Objectifs
2. Axes principaux & Maximisation de variances
3. Représentations & Interprétations
4. D'autres types de données, d'autres analyses statistiques

Réduction de dimension

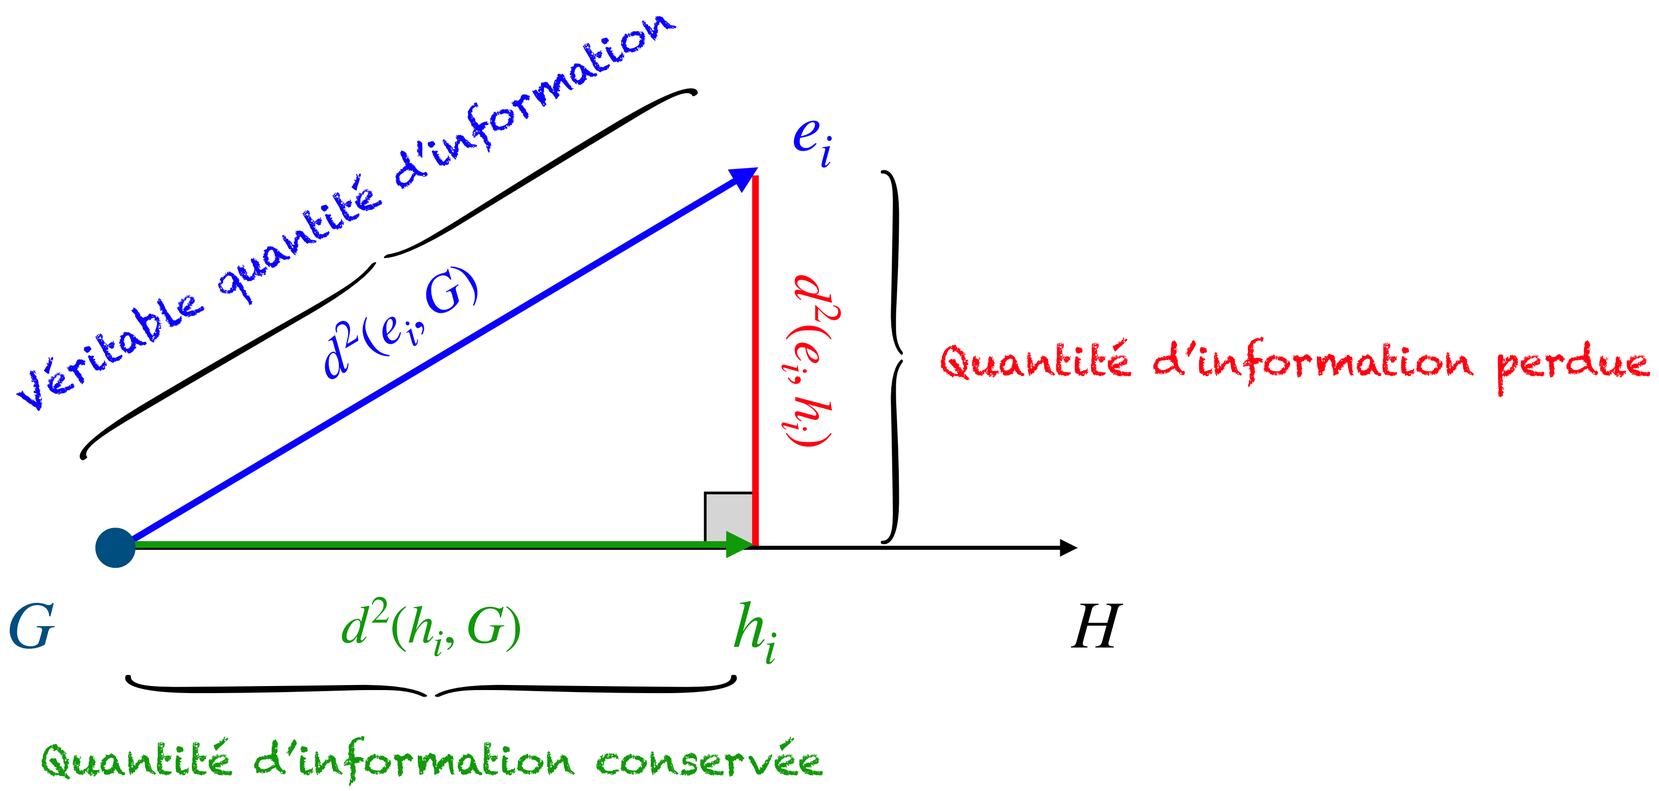
Objectif : Trouver une représentation conservant au maximum la **forme du nuage** !



- Il s'agit de déterminer les « directions » principales du nuage de points.
- La notion d'information d'un nuage de points est mesurée par la variance autour du centre de gravité du nuage.
- L'information totale (variance totale) contenue dans le nuage de points est :

$$\frac{1}{n}\sum_{i=1}^{n} d^2(e_i, G) \ .$$

Projection d'un individu e_i sur une droite H

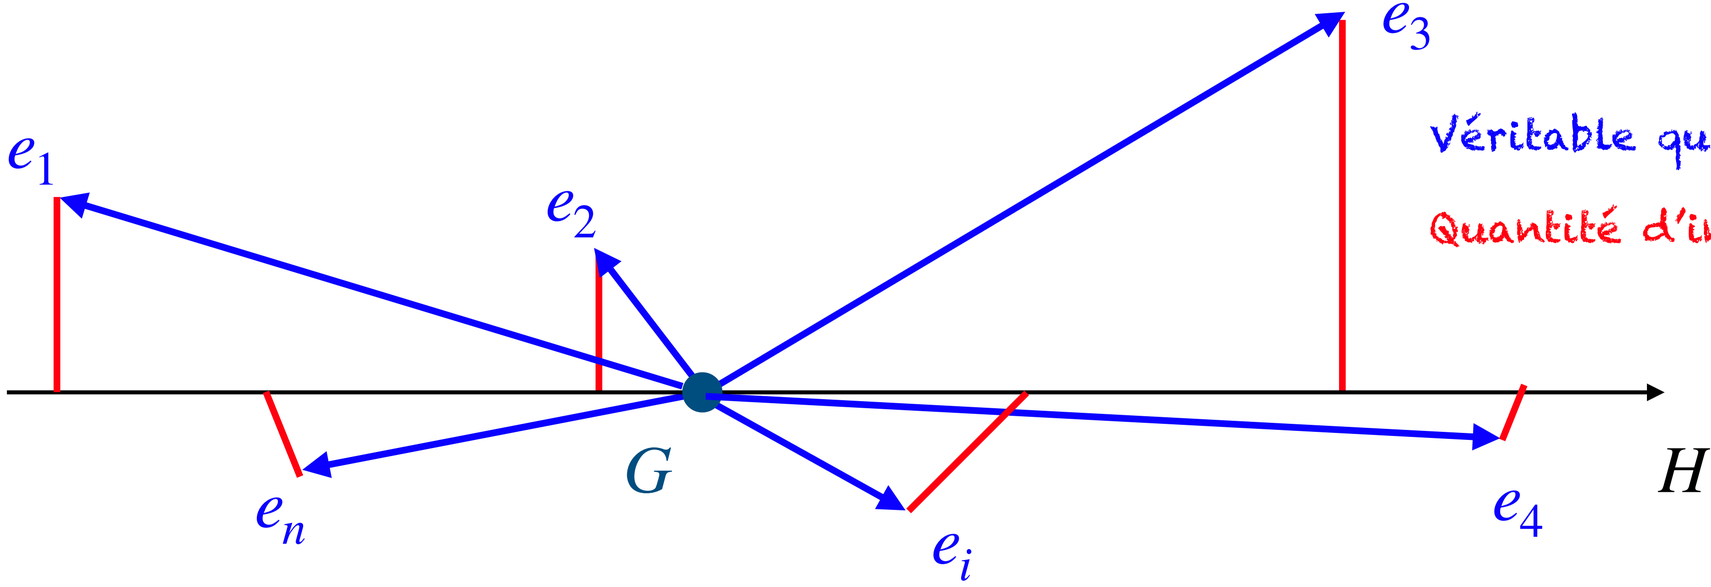


Par le théorème de Pythagore :

$$d^2(e_i, G) = d^2(e_i, h_i) + d^2(G, h_i) .$$

Réduction de dimension

Projection d'un individu e_1, ..., e_n sur une droite H



Véritable quantité d'information

Quantité d'information perdue

Par le théorème de Pythagore :

$$\underbrace{\frac{1}{n}\sum_{i=1}^{n} d^2(e_i, G)}_{\text{Toute l'information}} = \underbrace{\frac{1}{n}\sum_{i=1}^{n} d^2(e_i, h_i)}_{= I_H \text{ : À minimiser : erreur commise lors de l'approximation}} + \underbrace{\frac{1}{n}\sum_{i=1}^{n} d^2(G, h_i)}_{= I_{H^\perp} \text{ : À maximiser : variance portée par l'axe}} .$$

Méthodologie : Une approche itérative (basée sur l'algèbre linéaire)

1. **Projection sur une droite.**
   - Nous cherchons la droite H_1 sur laquelle nous projetons les points en minimisant l'information perdue.

2. **Projection sur un plan.**
   - Nous cherchons une 2e droite H_2, orthogonale à H_1, qui rend maximale l'information restante.
   - Le plan obtenu, déterminé par H_1 et H_2, est appelé plan principal ou plan 1-2.

3. **Projection sur des espaces de dimensions supérieures.**
   - Nous pouvons chercher un 3e, 4e, ..., axes de la même manière.
   - Les axes trouvés sont appelés axes factoriels ou composantes principales.

Mathématiquement : Trouver le premier axe factoriel (1)

- Il s'agit de résoudre un problème d'optimisation en algèbre linéaire.
- Notons I_{H_1} (resp. $I_{H_1^\perp}$) l'inertie de la projection du nuage sur H_1 (resp. l'orthogonal $H_1^\perp$).
- Le problème est alors de trouver un vecteur directeur u_1 de H_1, de norme $\|u_1\| = 1$ maximisant :

$$
\begin{aligned}
I_{H_1^\perp} &= \frac{1}{n}\sum_{i=1}^{n} d(x_i, H_1^\perp)^2 \\
&= \frac{1}{n}\sum_{i=1}^{n} u_1^\perp\,(x_i - \bar{x})(x_i - \bar{x})^\perp\, u_1 \\
&= u_1^\perp \Big(\sum_{i=1}^{n} \frac{1}{n}(x_i - \bar{x})(x_i - \bar{x})^\perp\Big)\, u_1 \\
&= u_1^\perp\, \hat{\Sigma}\, u_1
\end{aligned}
$$

Mathématiquement : Trouver le premier axe factoriel (2)

- Par ailleurs :

$$\underset{u_1 : \|u_1\|=1}{\text{maximiser}} \; u_1^\perp \hat{\Sigma}\, u_1 \quad \Longleftrightarrow \quad \underset{u_1 \in \mathbb{R}^p,\, \lambda_1 > 0}{\text{maximiser}} \; u_1^\perp \hat{\Sigma}\, u_1 - \lambda_1 \left(\|u_1\|^2 - 1 \right) .$$

- La résolution de ce problème conduit à la solution suivante :

$$\begin{cases} \hat{\Sigma}\, u_1 & = \lambda_1\, u_1 \\ u_1^\perp \hat{\Sigma}\, u_1 & = \lambda\, u_1^\perp u_1 = \lambda_1 = I_{H_1^\perp} \end{cases}$$

- En résumé :
  - u_1 est le premier vecteur propre (normalisé) de la matrice $\hat{\Sigma}$;
  - λ_1 est la première valeur propre de $\hat{\Sigma}$.
    - La variance « portée » par l'axe H_1 est égale à λ_1, la plus grande valeur propre de $\hat{\Sigma}$.

Mathématiquement : Trouver les axes suivants

- **Deuxième meilleur axe.**
  - Trouver la droite H_2, de vecteur directeur u_2, orthogonale à H_1 résolvant le problème

$$\underset{u_2 \in \mathbb{R}^p}{\text{maximiser}} \; u_2^\perp \hat{\Sigma} \, u_2 \,, \qquad \text{with } \|u_2\| = 1 \quad \text{and } u_1^\perp u_2 = 0 \;.$$

  - u_2 est le deuxième vecteur propre de $\hat{\Sigma}$ de valeur propre λ_2.

- **Et ainsi de suite.**
  - Il s'agit donc de trouver une nouvelle base orthogonale de vecteurs propres :

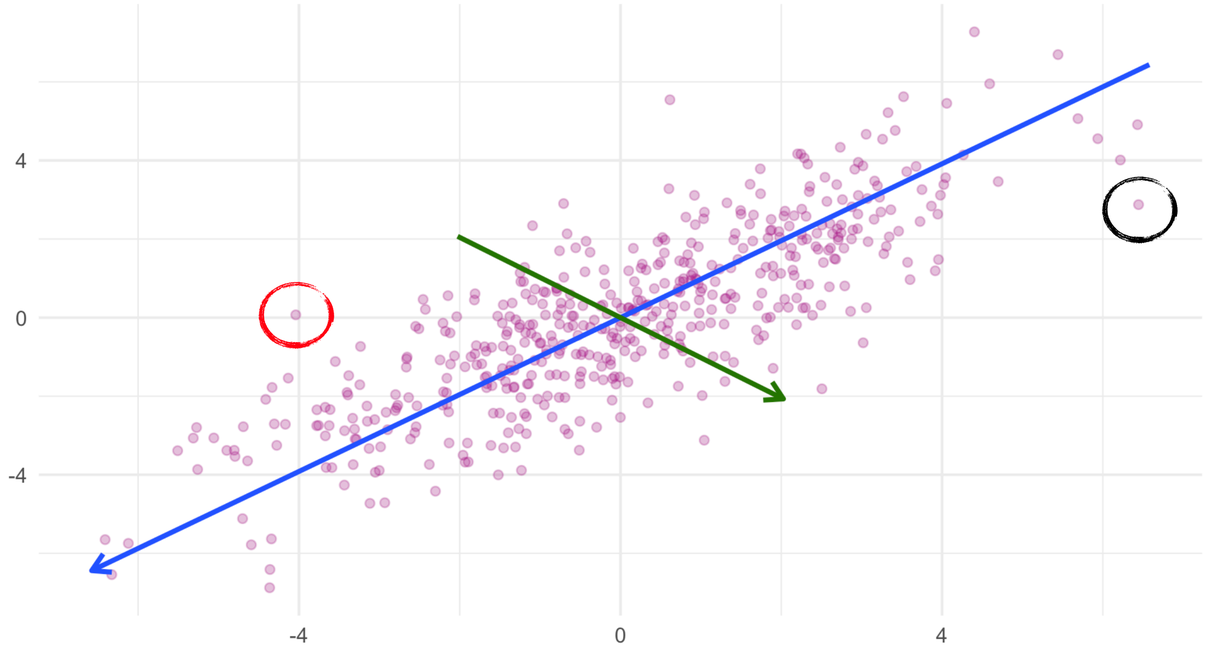
$$\begin{cases} u_1 \perp \ldots \perp u_p \\ \lambda_1 > \ldots > \lambda_p \\ I_{H_1^\perp} > \ldots > I_{H_p^\perp} \end{cases}$$

  - L'ACP est donc une rotation appropriée sur des axes maximisant la variance du nuage de points.

Nouvelle base de vecteurs

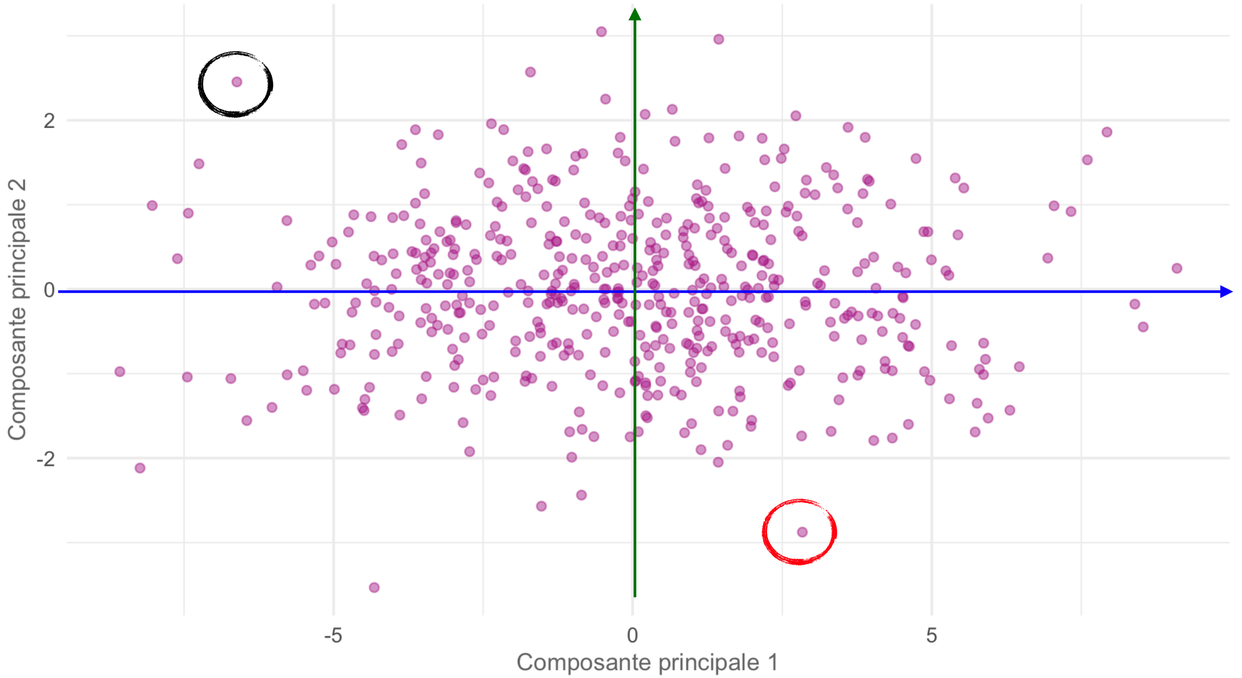
Nuage de points

Axes principaux



Nuage de points

Coordonnées du plan principal



Notion de gain d'information : Illustration via la compression d'images (1)

- Considérons une image et déterminons les composantes principales comme présentées ci-dessus.

- Une image est encodée comme une matrice en deux dimensions (pour chaque couleur RGB) dont les éléments sont des niveaux de R, G, ou B.

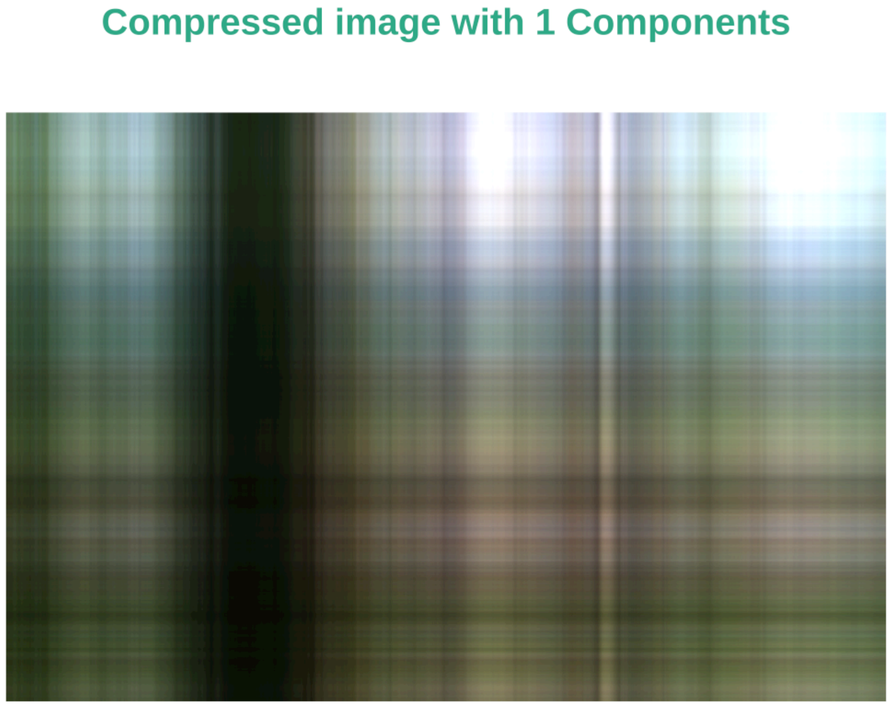
- Les lignes (864) sont les individus, et les colonnes sont les variables (1264).

- Déterminons les axes principaux et reconstituons l'image sur les premières composantes principales.



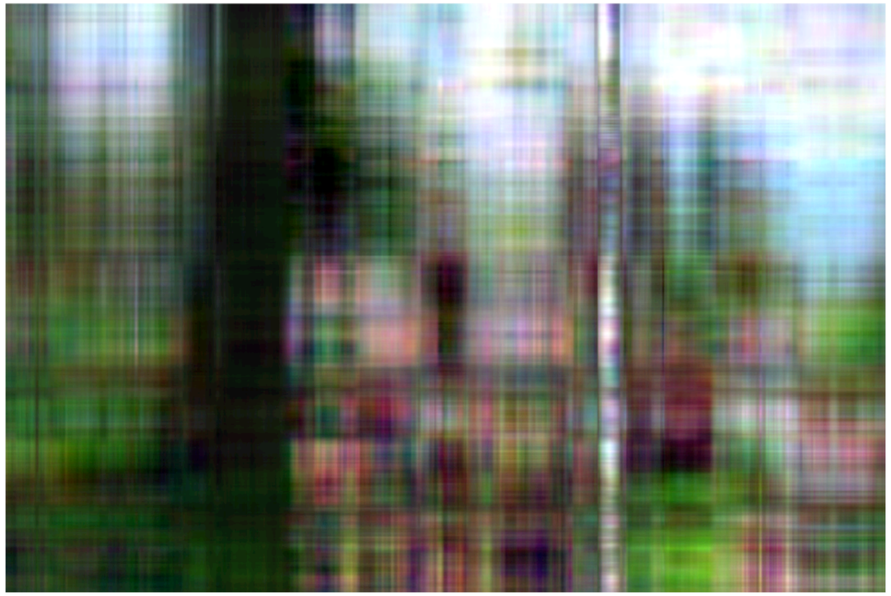
Notion de gain d'information : Illustration via la compression d'images (1)

- Projection sur la première composante principale.



Notion de gain d'information : Illustration via la compression d'images (2)

- Projection sur les 5 premières composantes principales.



Notion de gain d'information : Illustration via la compression d'images (3)

- Projection sur les 25 premières composantes principales.



Notion de gain d'information : Illustration via la compression d'images (4)

- Projection sur les 50 premières composantes principales.



Notion de gain d'information : Illustration via la compression d'images (5)

- Projection sur les 864 premières composantes principales.

- Cet exemple montre que nous devrons choisir judicieusement le nombre de composantes principales sur lesquelles projetées nos données.

Compressed image with 864 Components



Plan

1. Problèmes & Objectifs

2. Axes principaux & Maximisation de variances

3. Représentations & Interprétations

   (a) Qualité de la reconstruction

   (b) Étude du nuage des individus

   (c) Étude du nuage des variables

   (d) Description des dimensions

4. D'autres types de données, d'autres analyses statistiques

Transformation des données ?

- Centrer les données, c'est-à-dire forcer que les moyennes de toutes les variables soient égales à 0, ne modifie pas la forme du nuage de points.
  - Les fonctions ACP sur R le font automatiquement.

- Réduire les données, c'est-à-dire transformer les données pour que la variance de chaque variable soient égales à 1, est indispensable pour éviter les biais d'unité !
  - Il faut le préciser aux fonctions ACP sur R.

Mise en place d'une ACP sur R

- Nous utilisons les paquets FactoMineR et factoextra pour réaliser les analyses exploratoires factorielles.

```
pca.crabs <- select(crabs, -species, -sex) %>%
    FactoMineR::PCA(graph = FALSE)
```

Plan

1. Problèmes & Objectifs

2. Axes principaux & Maximisation de variances

3. Représentations & Interprétations

   (a) Qualité de la reconstruction

   (b) Étude du nuage des individus

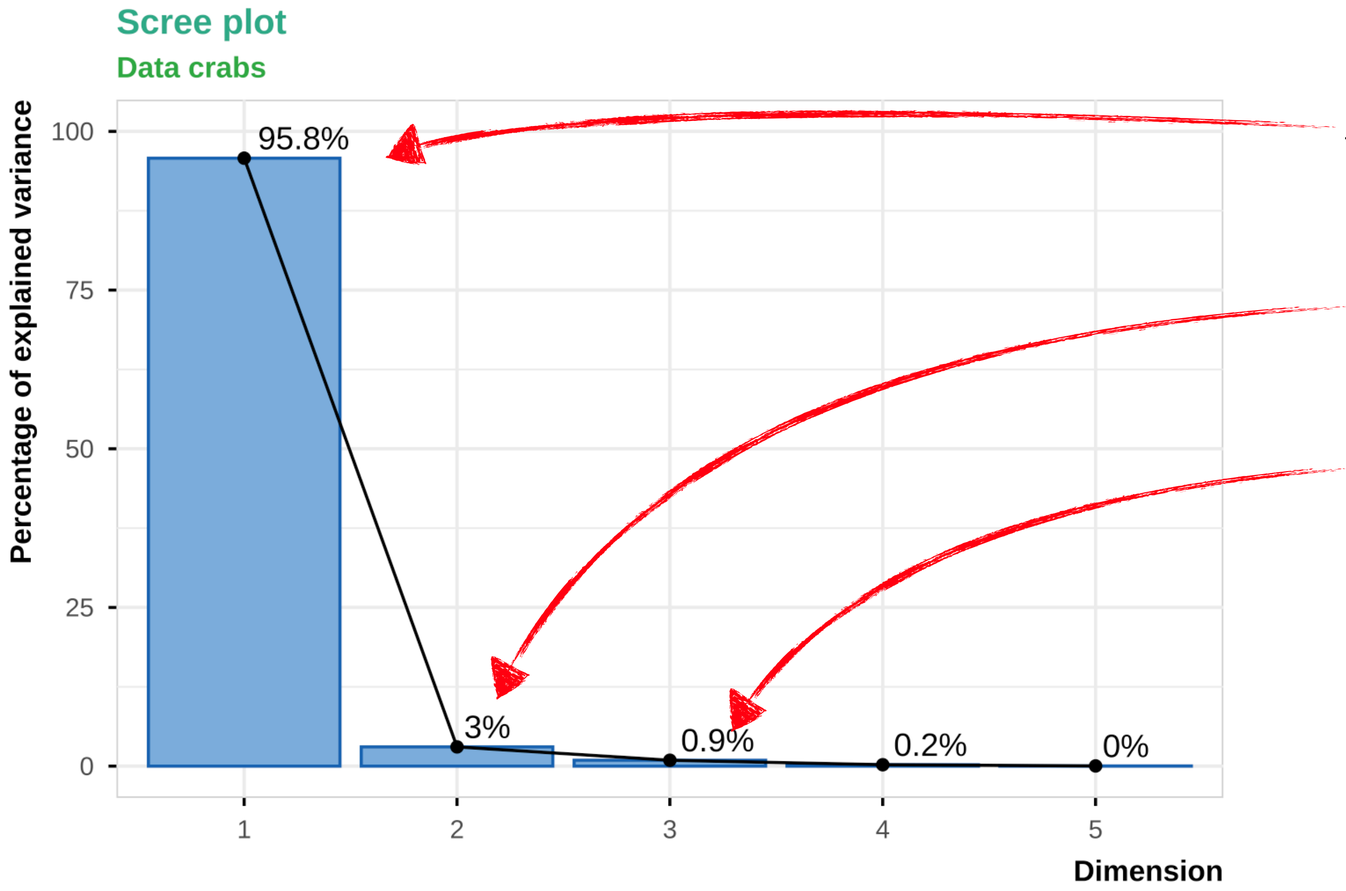
   (c) Étude du nuage des variables

   (d) Description des dimensions

4. D'autres types de données, d'autres analyses statistiques

Variance expliquée par les axes factoriels

```
fviz_eig(pca.crabs)
```



~ 95.8% de variance expliquée par le 1er axe

~3% de variance expliquée par le 2e axe

~ 0.9% de variance expliquée par le 3e axe

etc.

Choisir un nombre d'axes factoriels à interpréter !

Nombres d'axes à retenir

- Il n'existe pas de critère absolu et théorique de « bonne » représentation.

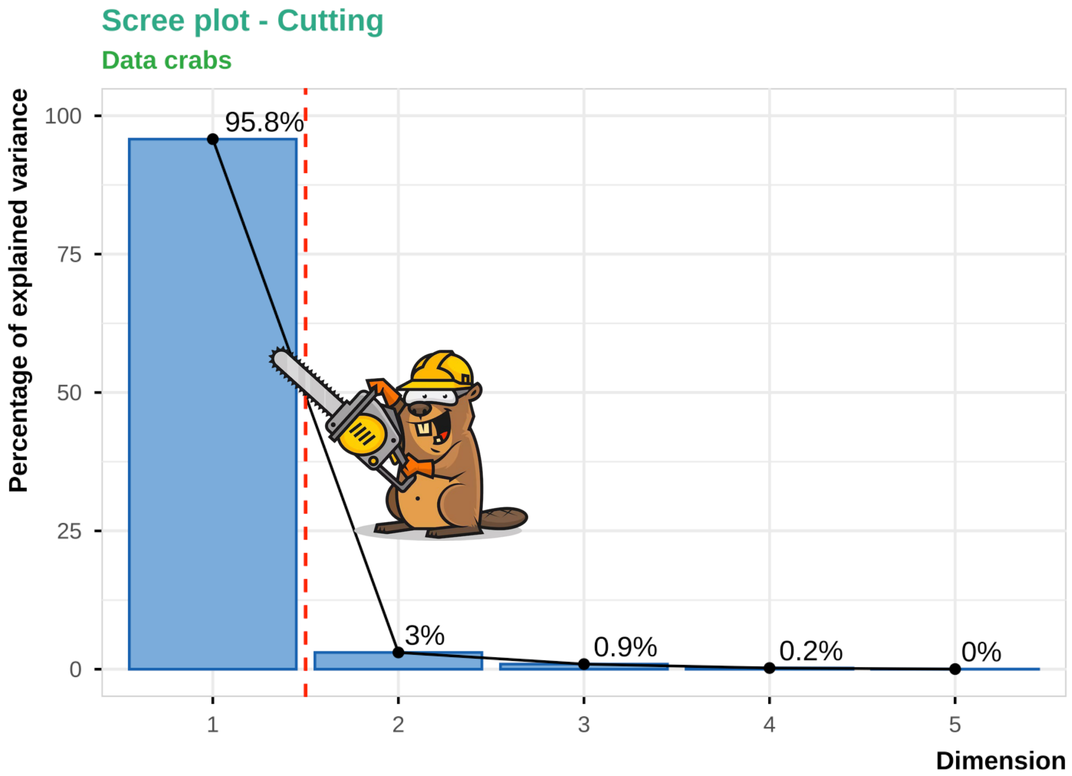
- En général, nous gardons le nombre d'axes factoriels tel que le pourcentage de variance expliquée soit supérieur à un certain seuil :
  - à partir de 80% de variance expliquée cumulée, la représentation est considérée comme très bonne ;
  - entre 65% et 80% de variance expliquée pour le plan principal, la représentation est considérée comme bonne

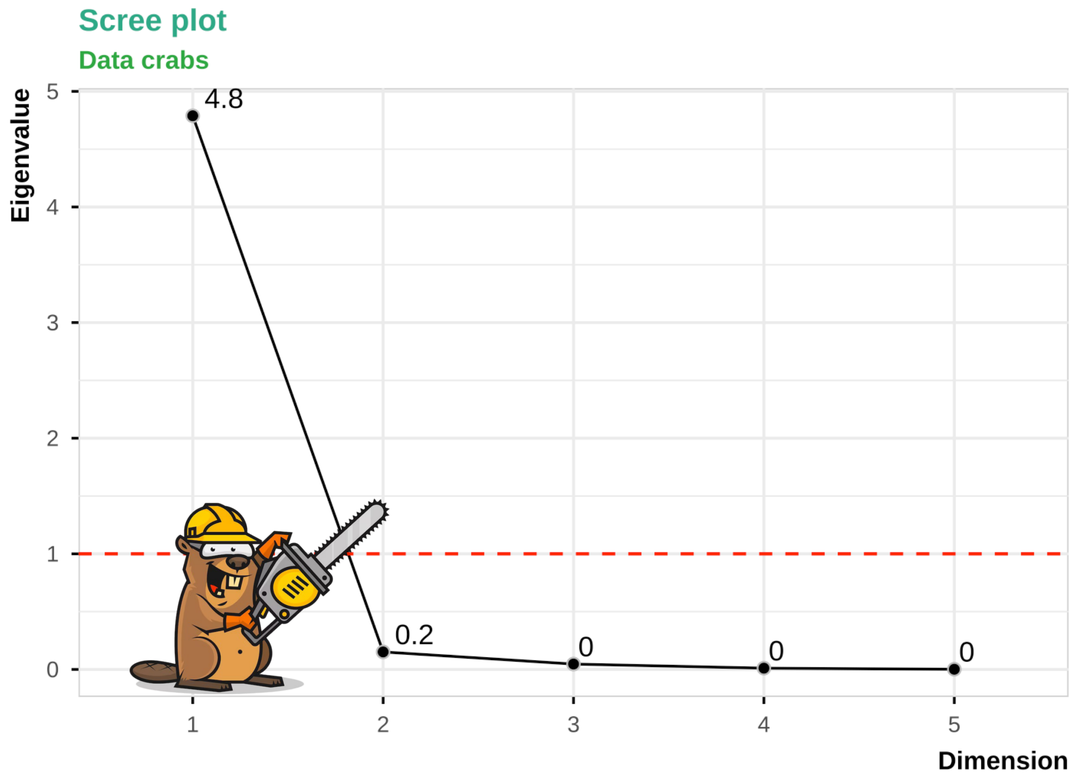
    ... mais ...

    il faut regarder si la variance expliquée du 3e axe factoriel apporte éventuellement une variance expliquée plus importante.

- Il existe d'autres critères :
  - Critère de Kaiser : nous gardons les composantes principales dont les valeurs propres sont >1.

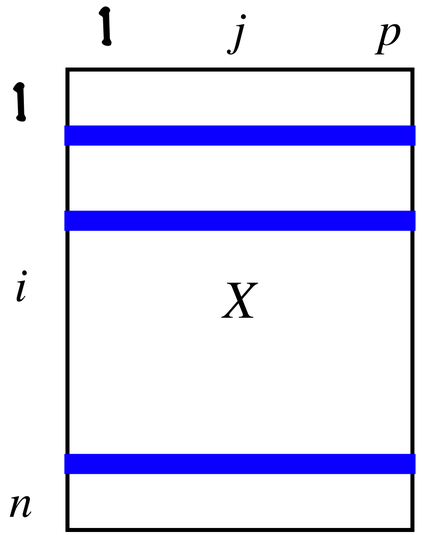
Variance expliquée par les axes factoriels

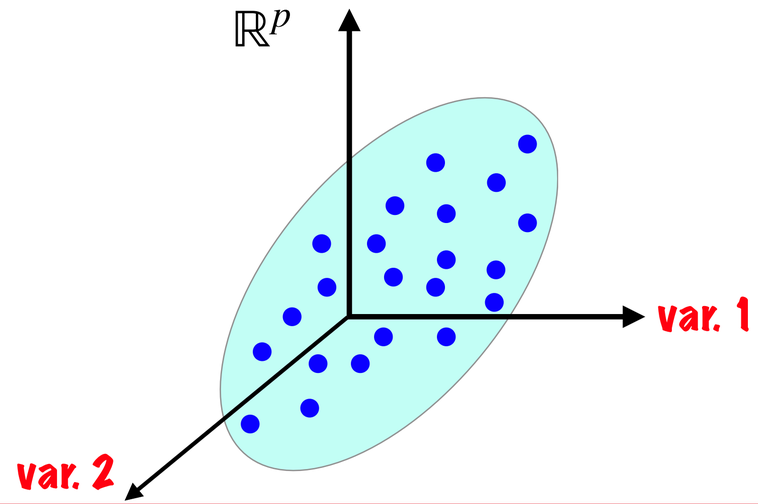




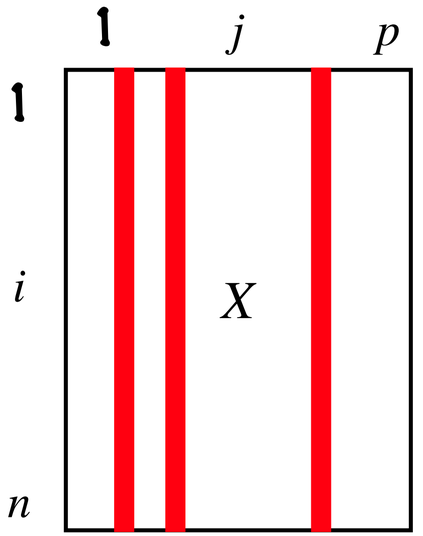
Deux nuages de points

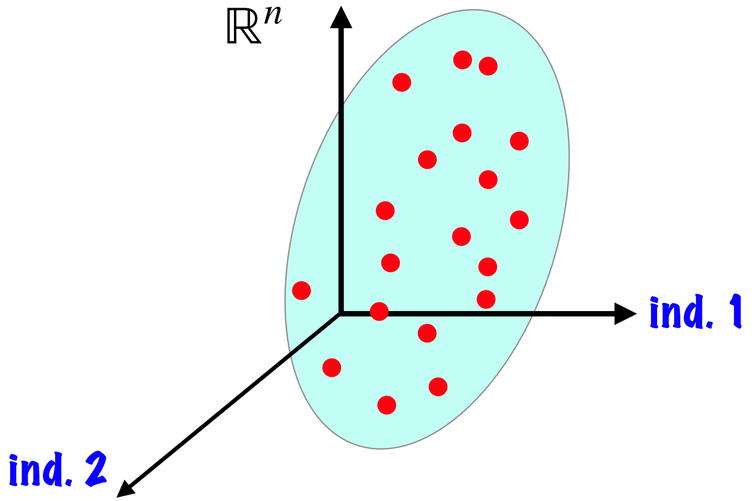
Étude des individus





Étude des variables





Plan

1. Problèmes & Objectifs

2. Axes principaux & Maximisation de variances

3. Représentations & Interprétations

   (a) Qualité de la reconstruction

   (b) Étude du nuage des individus

   (c) Étude du nuage des variables

   (d) Description des dimensions

4. D'autres types de données, d'autres analyses statistiques

Représentation des individus dans la nouvelle base

- Projection de x_i sur le k-ème axe factoriel.

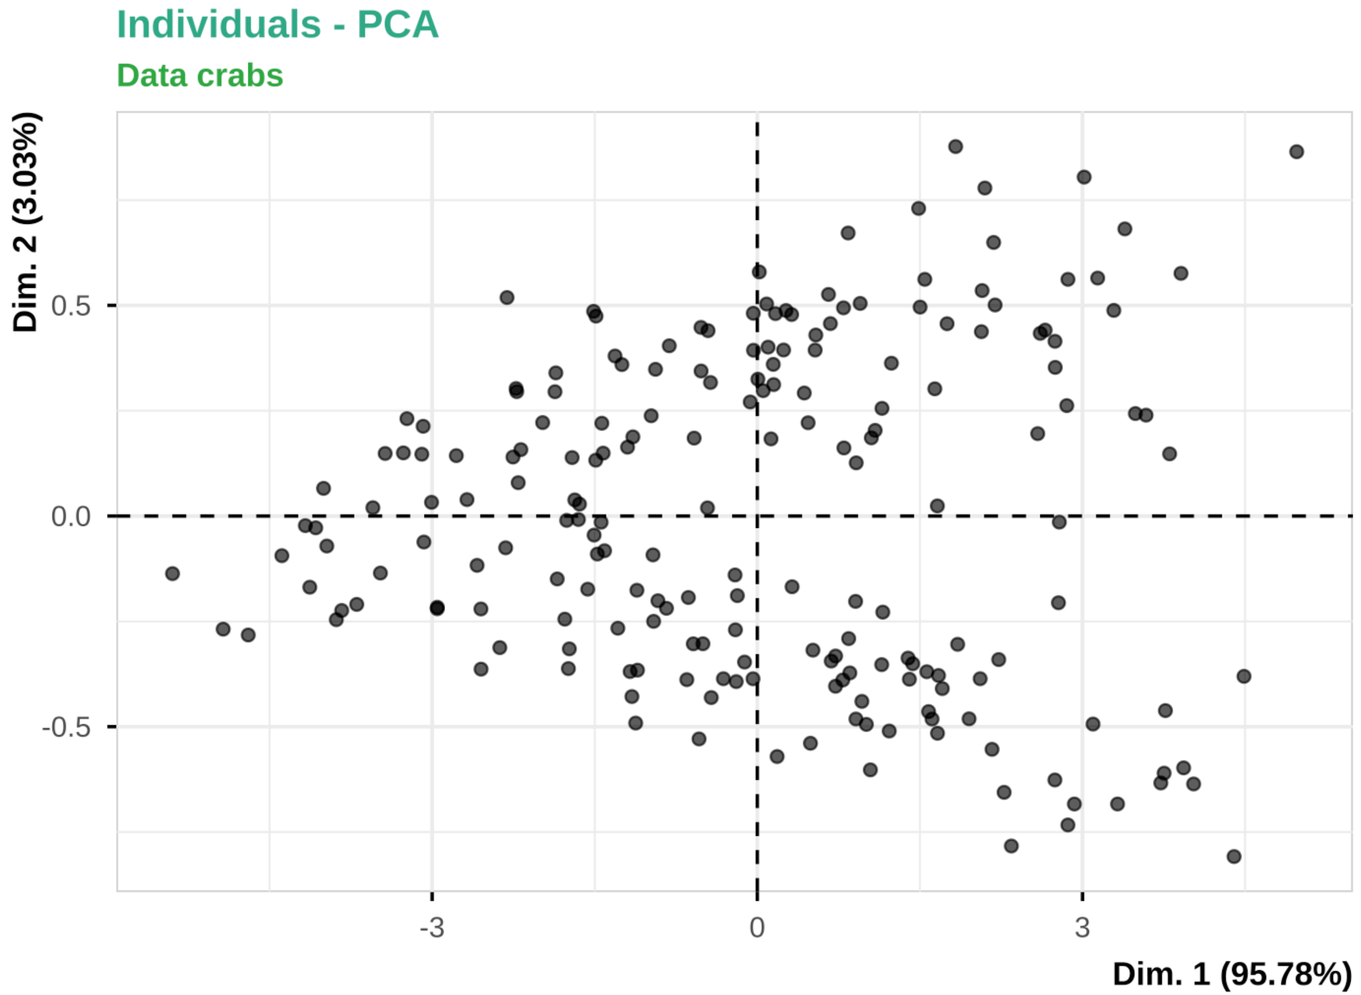
  - Projection de l'individu x_i sur l'axe H_k est $c_{ik}\, u_k$ avec

$$c_{ik} = u_k^{\perp}(x_i - \overline{x}) \ ,$$

  la i-ème coordonnée dans la base u_k (le long de l'axe H_k).

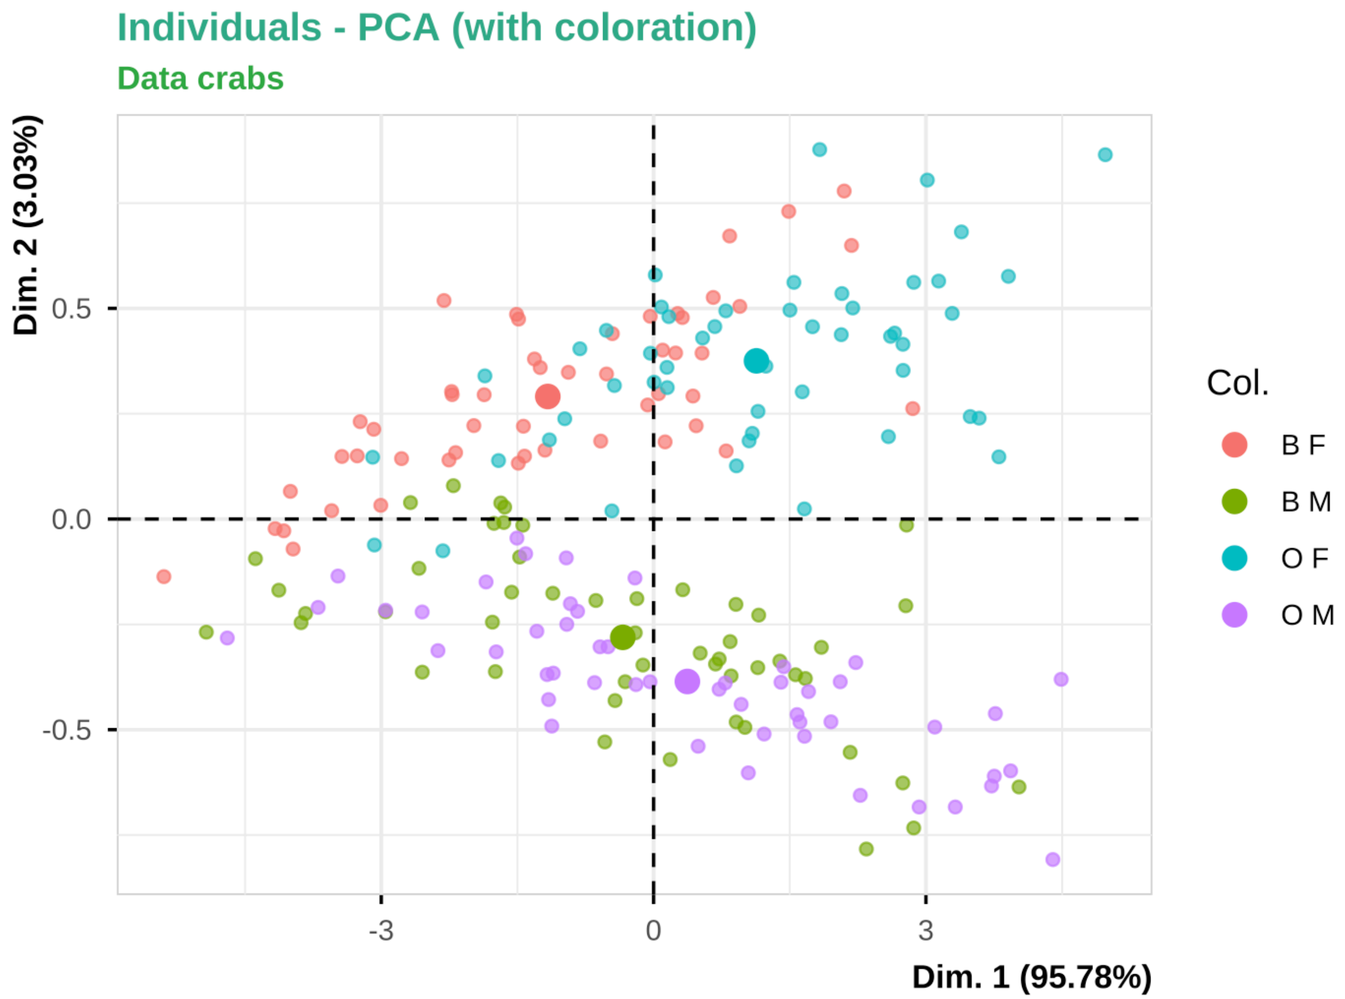
Nuage des individus : Projection sur le plan principal (1)

```
fviz_pca_ind(pca.crabs)
```



Nuage des individus : Projection sur le plan principal (2)

```
fviz_pca_ind(pca.crabs, col.ind = paste(crabs$species, crabs$sex))
```



Qualité de la représentation des individus (1)

- Un individu est bien représenté par l'axe H_k s'il est proche de cet axe.
  - Autrement dit, les vecteurs $x_i - \bar{x}$ et u_k sont presque colinéaires.

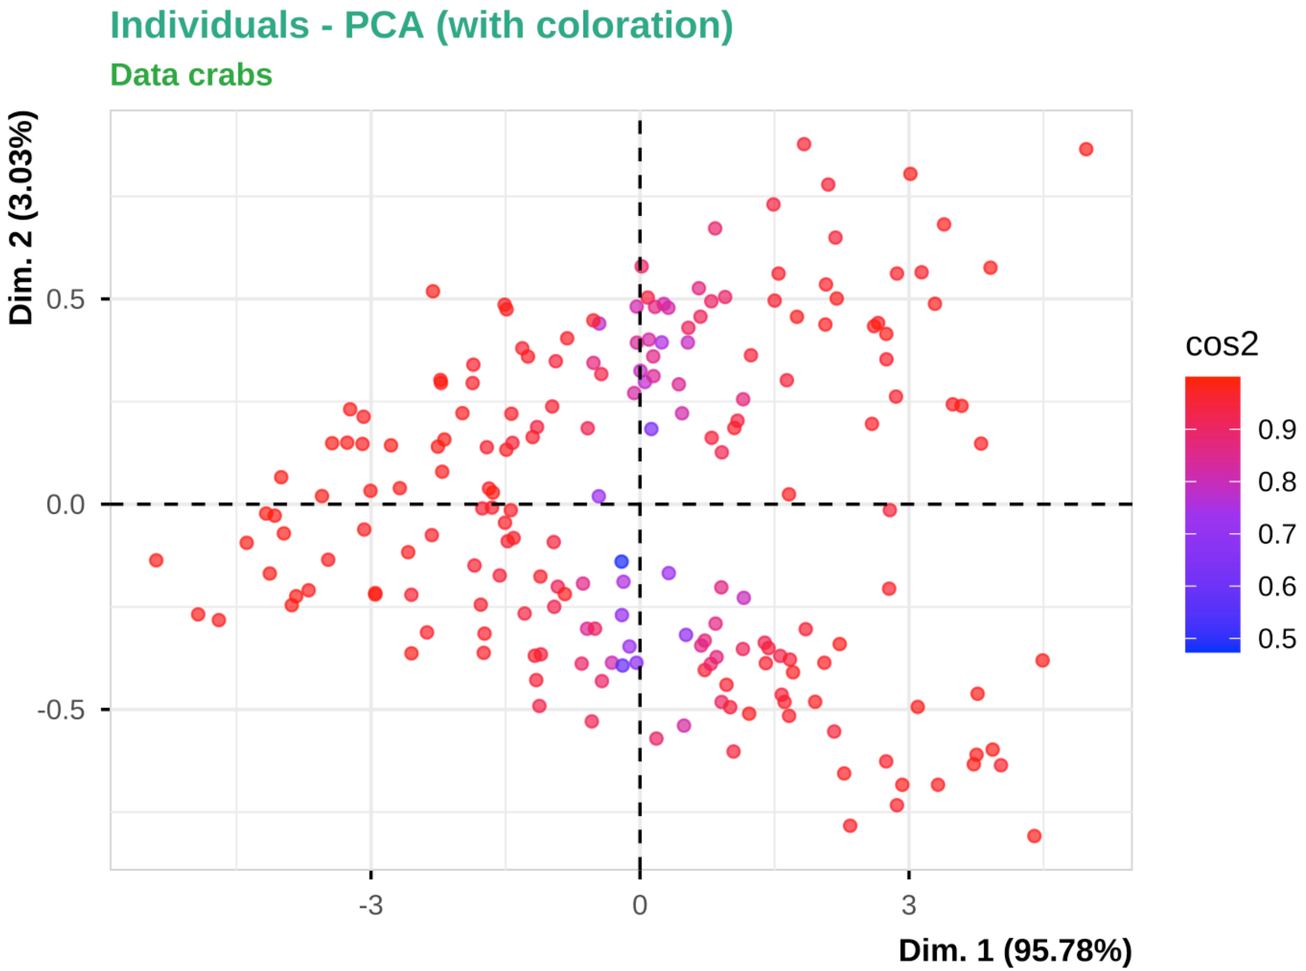
- La qualité de la représentation peut se mesurer au travers du cosinus de l'angle formé par $x_i - \bar{x}$ et u_k.

```
get_pca_ind(pca.crabs)$cos2 %>% head(5)
```

```
      Dim.1        Dim.2        Dim.3        Dim.4        Dim.5
1 0.9961694 0.0029565053 6.132250e-04 6.286310e-05 1.979931e-04
2 0.9994582 0.0004597565 7.995965e-05 1.552837e-06 4.839818e-07
3 0.9980940 0.0016698901 6.627629e-05 8.498293e-05 8.482196e-05
4 0.9959656 0.0039962883 1.388527e-05 2.407348e-05 1.141801e-07
5 0.9963345 0.0034058775 1.538721e-05 2.023077e-04 4.196886e-05
```

Qualité de la représentation des individus (2)

```
fviz_pca_ind(pca.crabs, col.ind = "cos2")
```



Contribution des individus aux axes factoriels (1)

- La contribution de x_i à l'axe H_k est la proportion d'inertie portée par l'individu i :

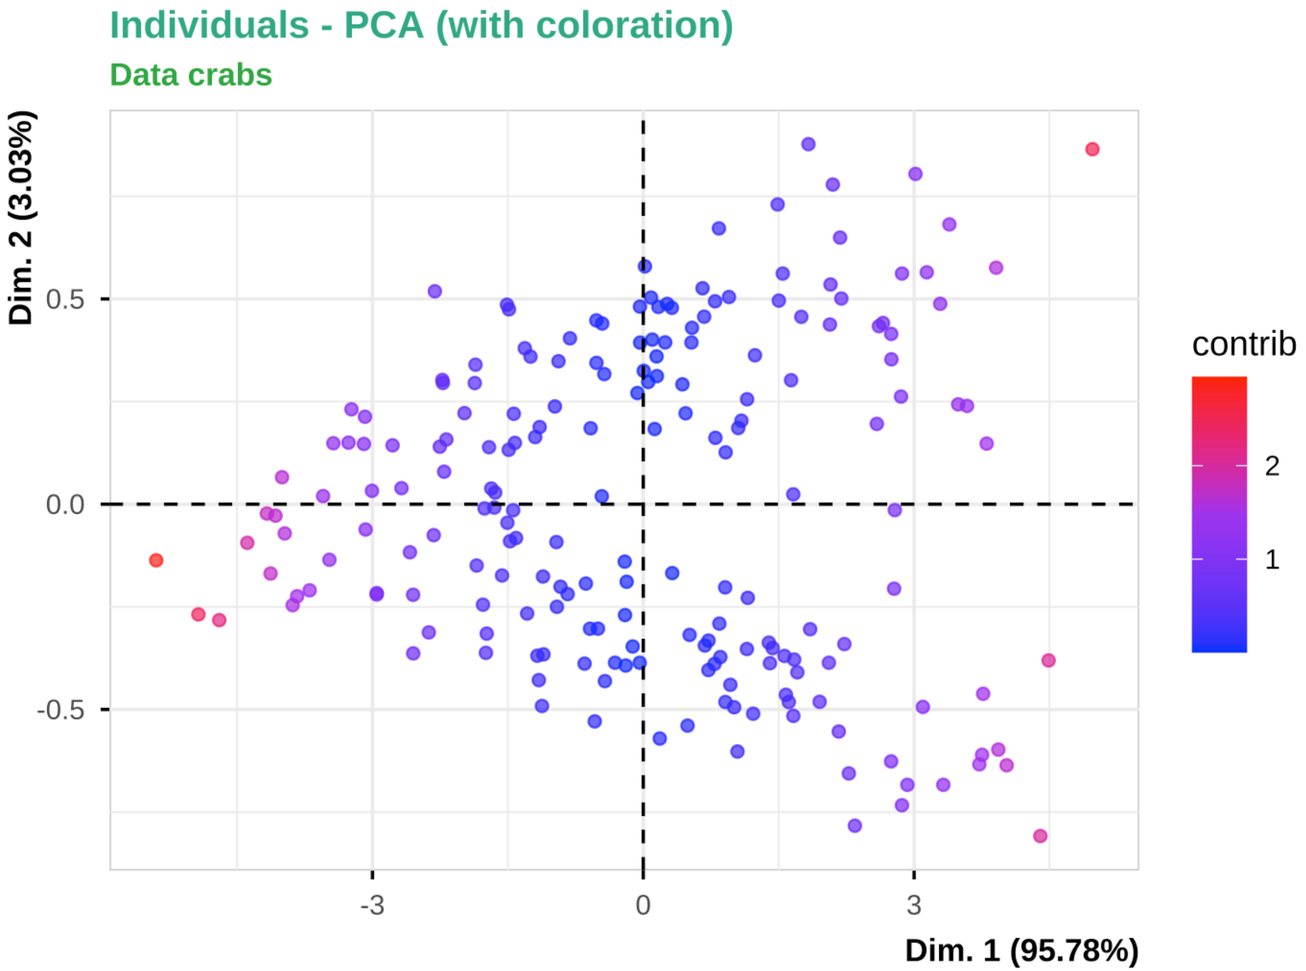
$$\text{contrib}(x_i) = \frac{n^{-1}\, d(H_k^{\perp}, x_i)}{I_{H_k^{\perp}}} = \frac{\left(u_k^{\perp}\,(x_i - \overline{x})\right)^2}{\lambda_k}\,.$$

```
get_pca_ind(pca.crabs)$contr %>% head(5)
```

```
      Dim.1      Dim.2       Dim.3       Dim.4        Dim.5
1 2.535165 0.23754090 0.160261688 0.068800973 1.4097140795
2 2.008687 0.02917173 0.016502711 0.001342144 0.0027213514
3 1.779751 0.09400745 0.012136199 0.065169615 0.4231593469
4 1.574807 0.19949240 0.002254624 0.016369954 0.0005051045
5 1.534818 0.16564079 0.002434156 0.134026251 0.1808783885
```

Contribution des individus aux axes factoriels (2)

```
fviz_pca_ind(pca.crabs, col.ind = "contrib")
```



Plan

1. Problèmes & Objectifs

2. Axes principaux & Maximisation de variances

3. Représentations & Interprétations

   (a) Qualité de la reconstruction

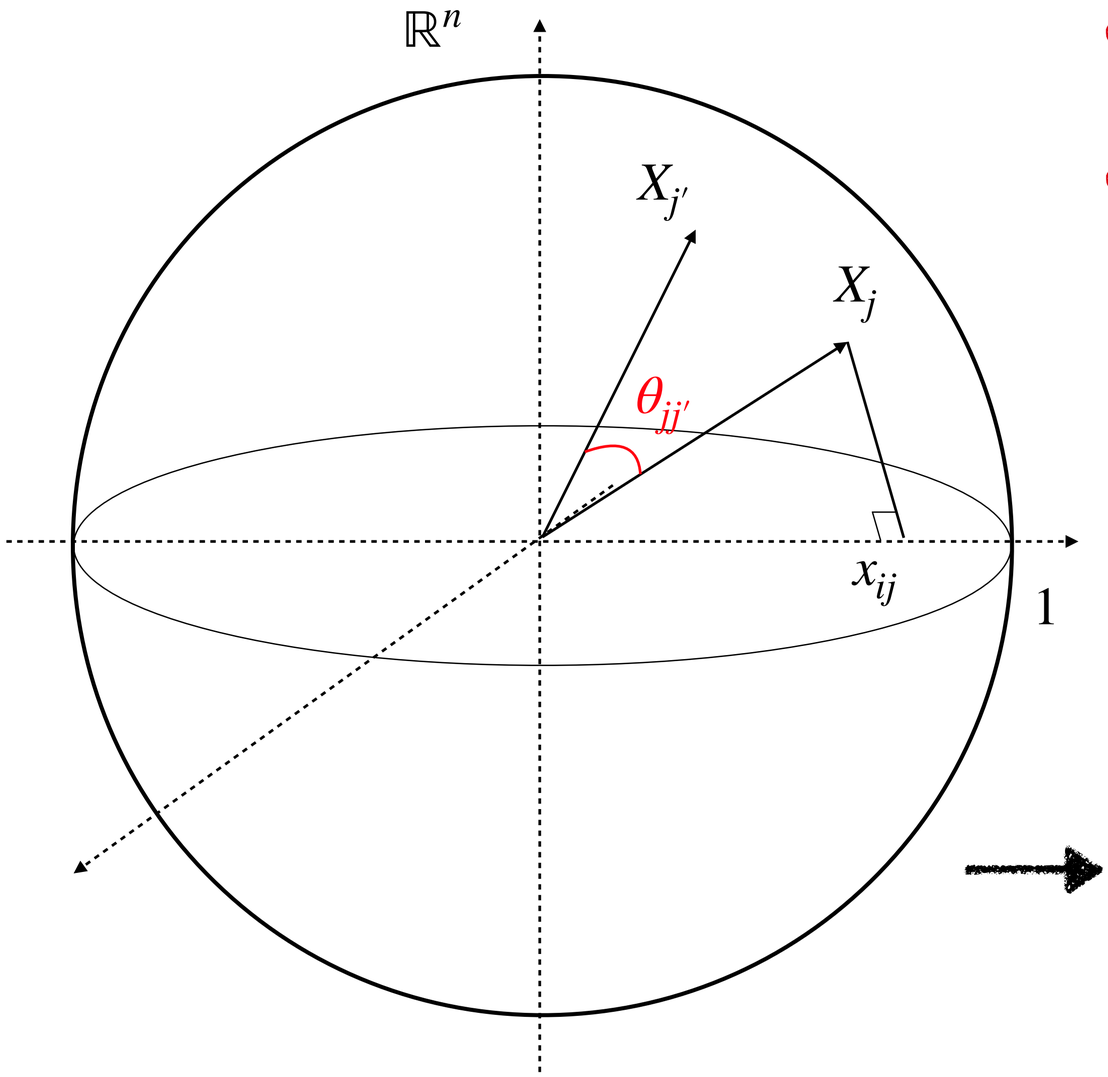
   (b) Étude du nuage des individus

   (c) Étude du nuage des variables

   (d) Description des dimensions

4. D'autres types de données, d'autres analyses statistiques

Représentation des variables (1)



- 1 variable = 1 point dans un espace à n dimensions
- Les variables sont réduites : elles sont toutes à distance 1 de l'origine !
- Les variables sont centrées :

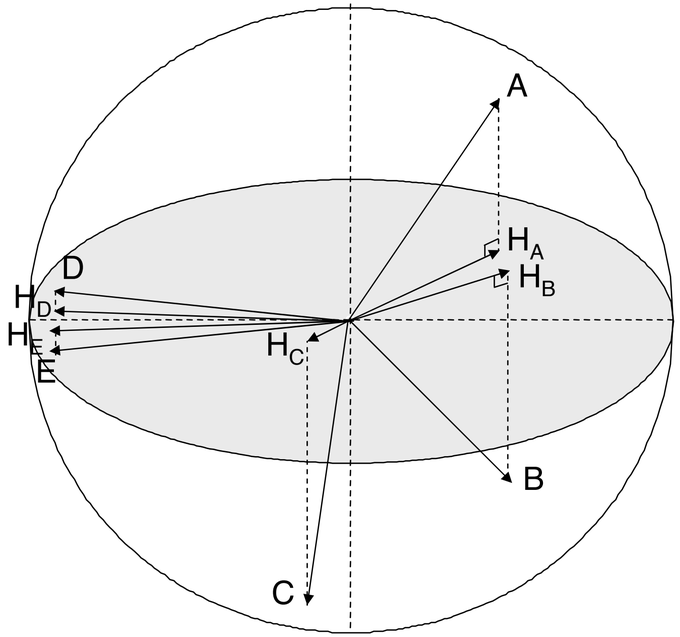
$$\cos(\theta_{jj'}) = \text{cor}(X_j, X_{j'})$$

Équivalence entre géométrie et statistique

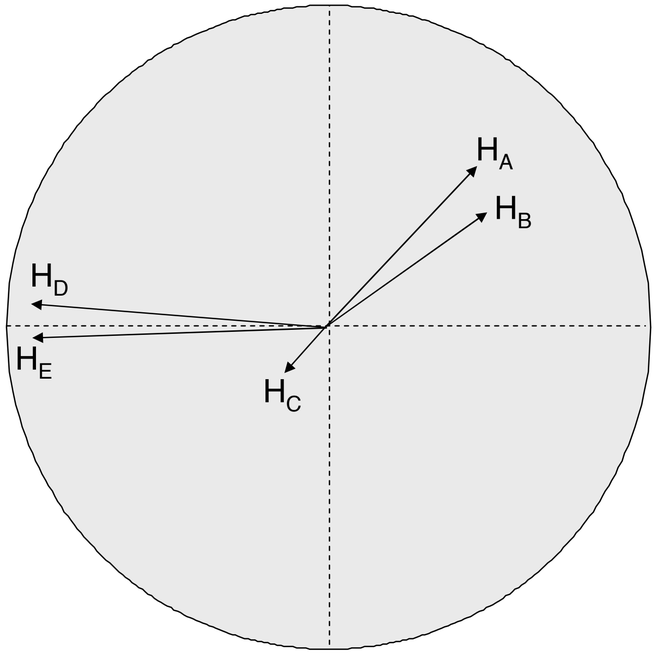
→ Deux variables sont proches si leur coefficient de corrélation est proche de 1 (ou -1), c'est-à-dire si « leur » cosinus est 0 (ou π).

Representation des variables (2)

But : Projeter les variables dans un espace plus petit en gardant le maximum d'information !



Visualisation dans l'espace des variables

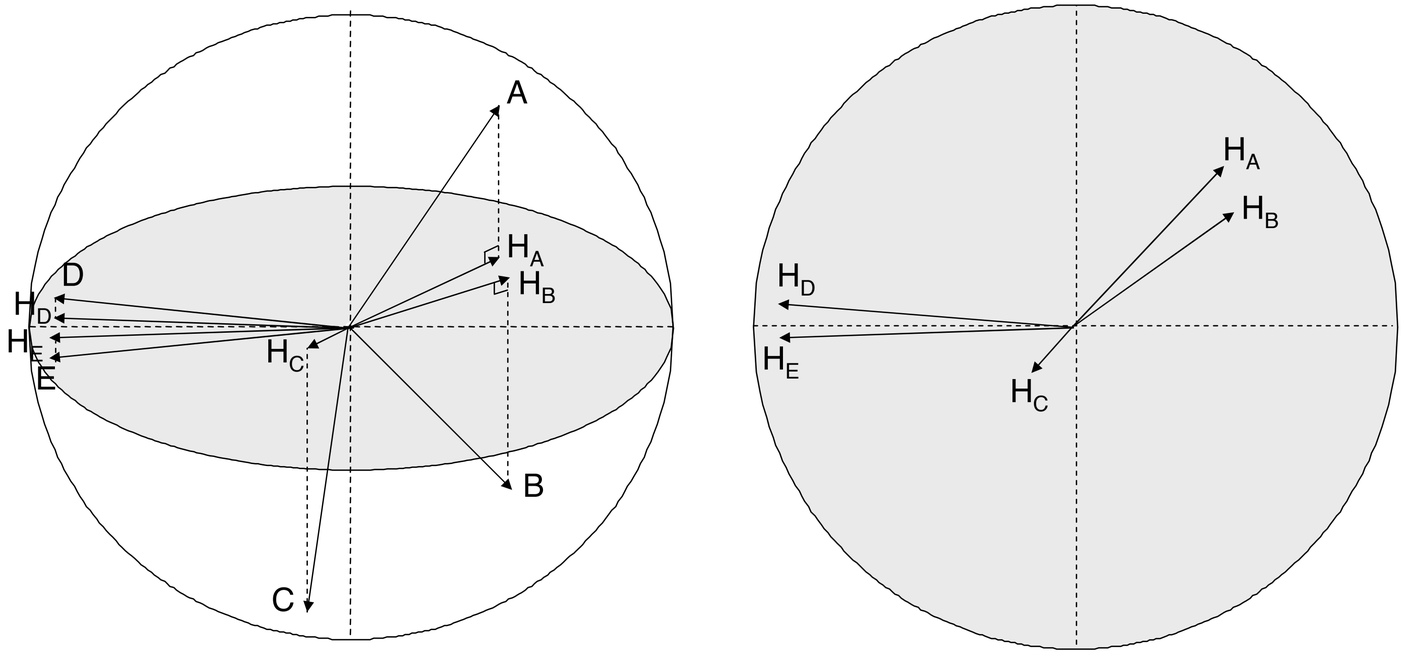


Visualisation des projetés dans le plan principal

Représentation des variables (3)

- Si les variables sont bien projetées, l'information est conservée (au maximum), c'est-à-dire que :

$$\cos(\theta_{A,B}) \approx \cos(\theta_{H_A,H_B}) .$$



Visualisation dans l'espace des variables

Visualisation des projetés dans le plan principal

Composantes principales

- **Représentation duale.**
  - Un raisonnement symétrique peut être effectué dans $\mathbb{R}^n$ pour les variables, de la même manière que pour les individus dans $\mathbb{R}^p$.
  - Les nouveaux axes sont des combinaisons linéaires des variables originelles, qui peuvent être vues comme de nouvelles variables dans le nouvel espace latent.

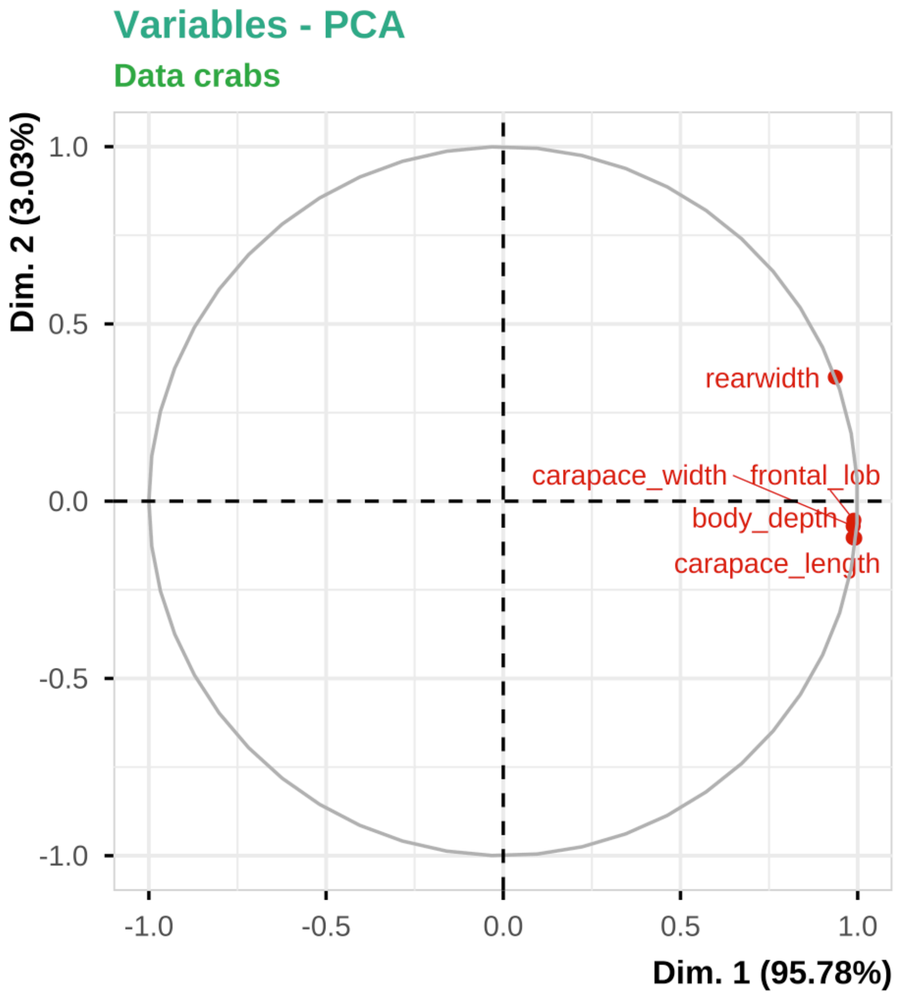
- **Composantes principales.**

- Il s'agit de la combinaison linéaire formée par les variables originelles de poids données par les vecteurs propres $u_k = (u_{k1}, \ldots, u_{kj}, \ldots, u_{kp})$:

$$f_k = \sum_{j=1}^{p} u_{kj} (x_j - \bar{x}_j) \ .$$

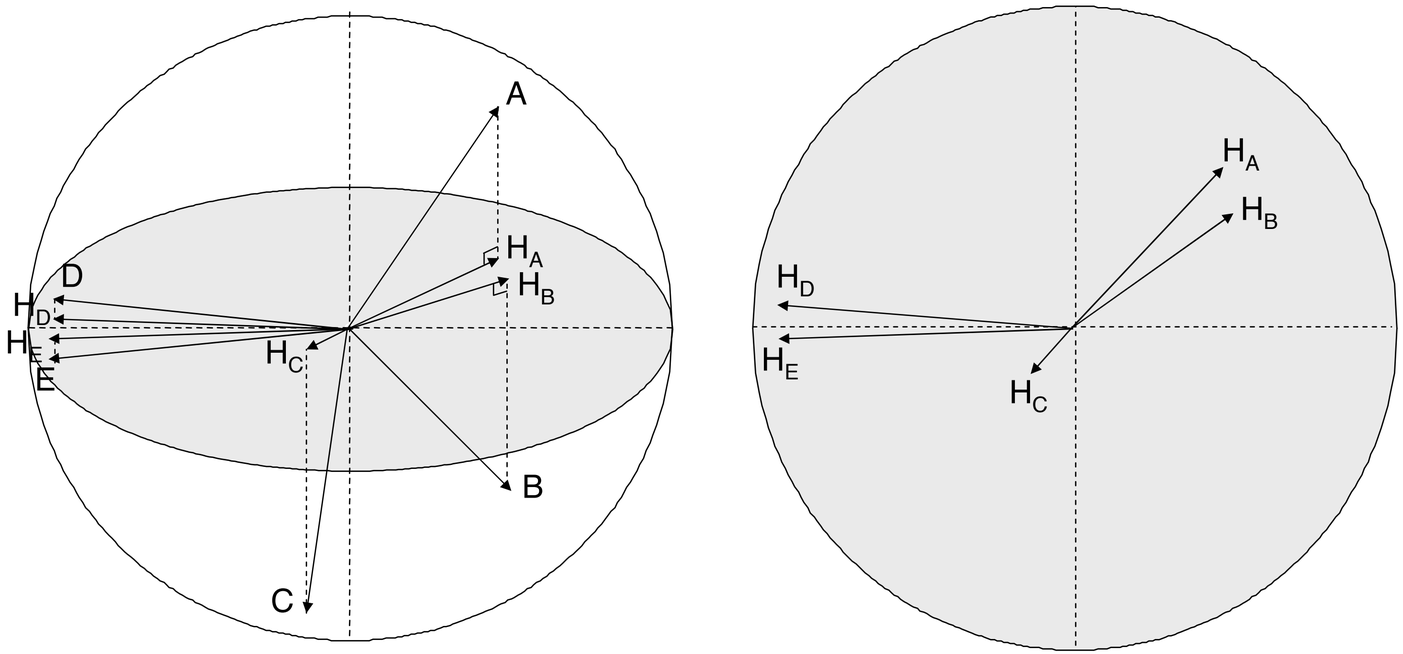
Cercles des corrélations

```
fviz_pca_var(pca.crabs)
```



Angles après projection

- Comme pour le graphe des individus, projections proches ne signifie pas que les variables sont proches !



- Ceci est vrai si les variables sont bien représentées dans le sous-espace.

Qualité de la représentation des variables (1)

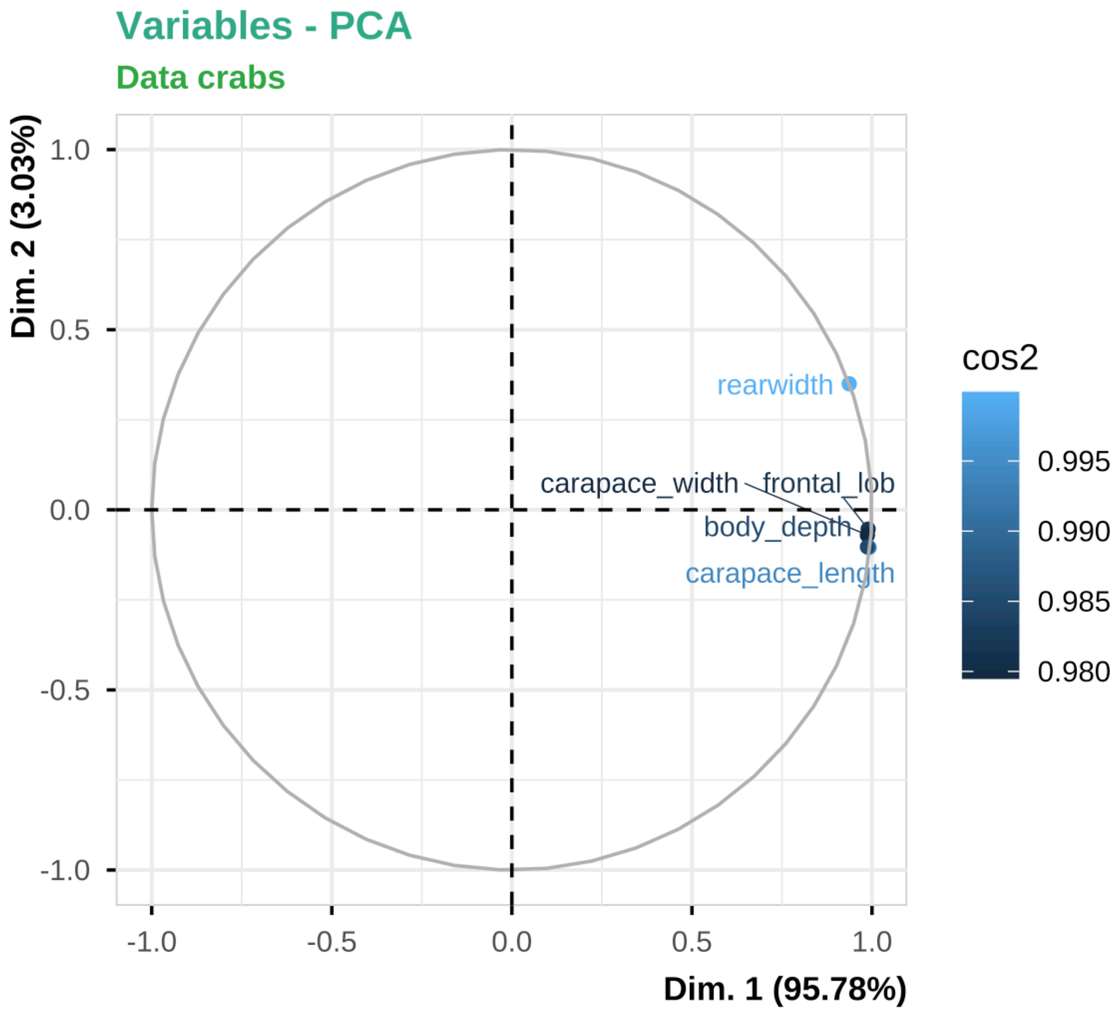
- La projection de la variable j doit être proche de la frontière du cercle de corrélation.
- La qualité de la projection peut être mesurée par le carré du cosinus de l'angle entre la variable et l'axe factoriel.

```
get_pca_var(pca.crabs)$cos2 %>% head(5)
```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
frontal_lob	0.9785672	0.002871189	1.313721e-02	5.408467e-03	1.593678e-05
rearwidth	0.8775551	0.122355169	6.691831e-06	7.801683e-05	5.068747e-06
carapace_length	0.9835409	0.010914009	4.472226e-03	2.323908e-08	1.072814e-03
carapace_width	0.9745407	0.004947193	1.985851e-02	8.857583e-05	5.649922e-04
body_depth	0.9746309	0.010597646	9.158329e-03	5.560274e-03	5.286638e-05

Qualité de la représentation des variables (2)

```
fviz_pca_var(pca.crabs, col.var = "cos2")
```



Contribution des variables aux axes factoriels (1)

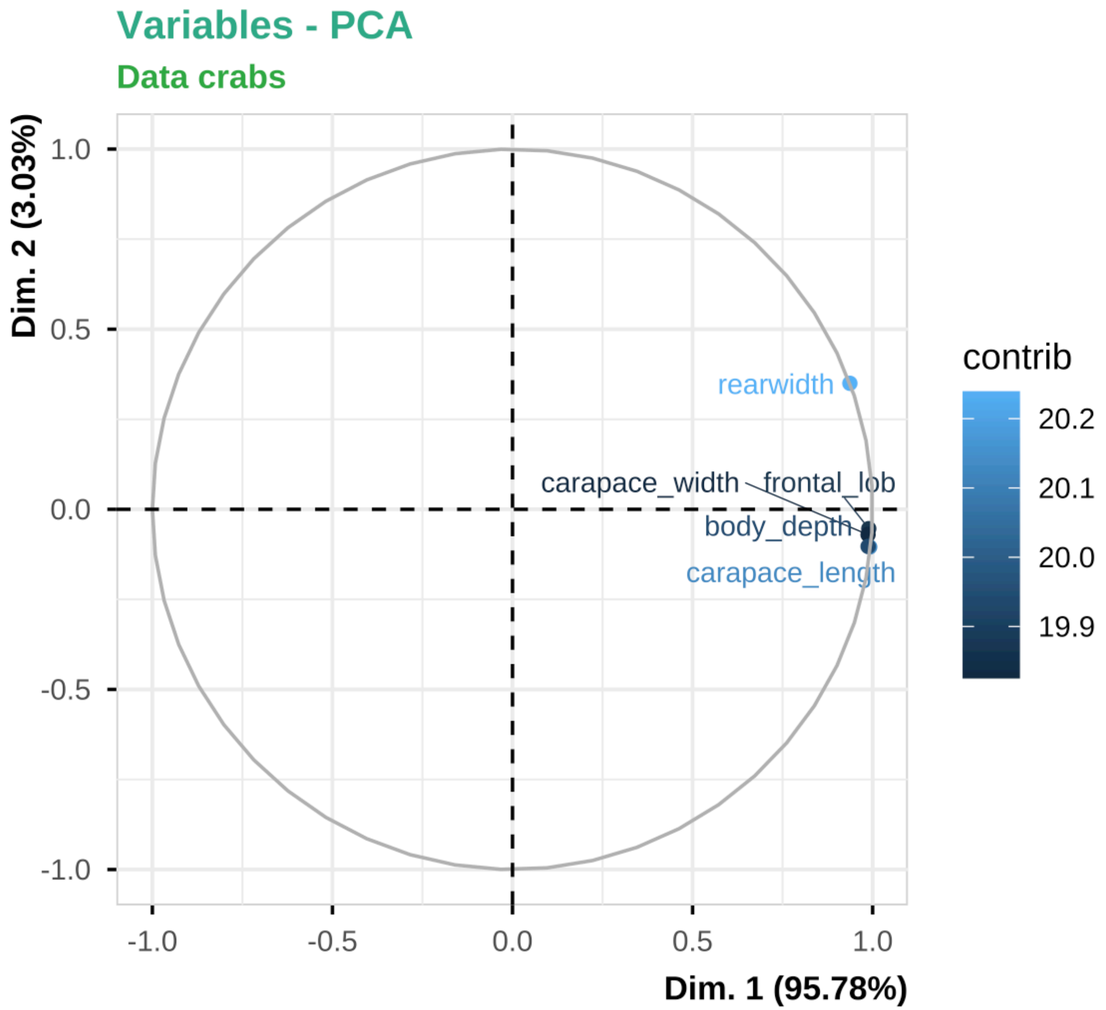
- De la même manière que pour les individus, nous pouvons mesurer la contribution de chaque variable à chaque axe factoriel.

```
get_pca_var(pca.crabs)$contr %>% head(5)
```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
frontal_lob	20.43435	1.892860	28.171510	4.857022e+01	0.9310620
rearwidth	18.32502	80.663877	0.014350	7.006226e-01	0.2961274
carapace_length	20.53821	7.195170	9.590266	2.086963e-04	62.6761450
carapace_width	20.35027	3.261487	42.584703	7.954467e-01	33.0080946
body_depth	20.35215	6.986605	19.639170	4.993350e+01	3.0885710

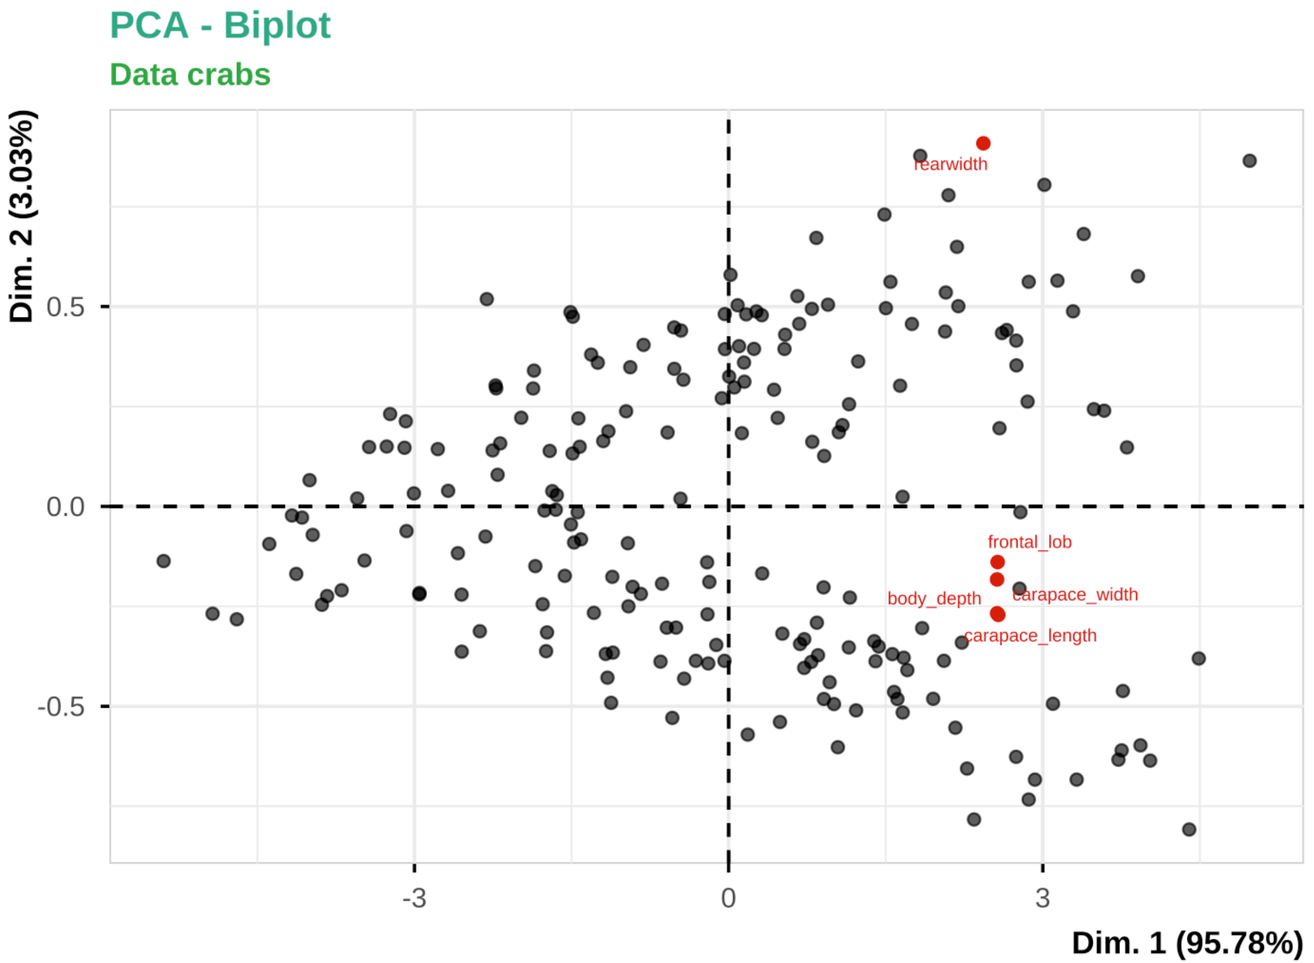
Contribution des variables aux axes factoriels (2)

```
fviz_pca_var(pca.crabs, col.var = "contrib")
```



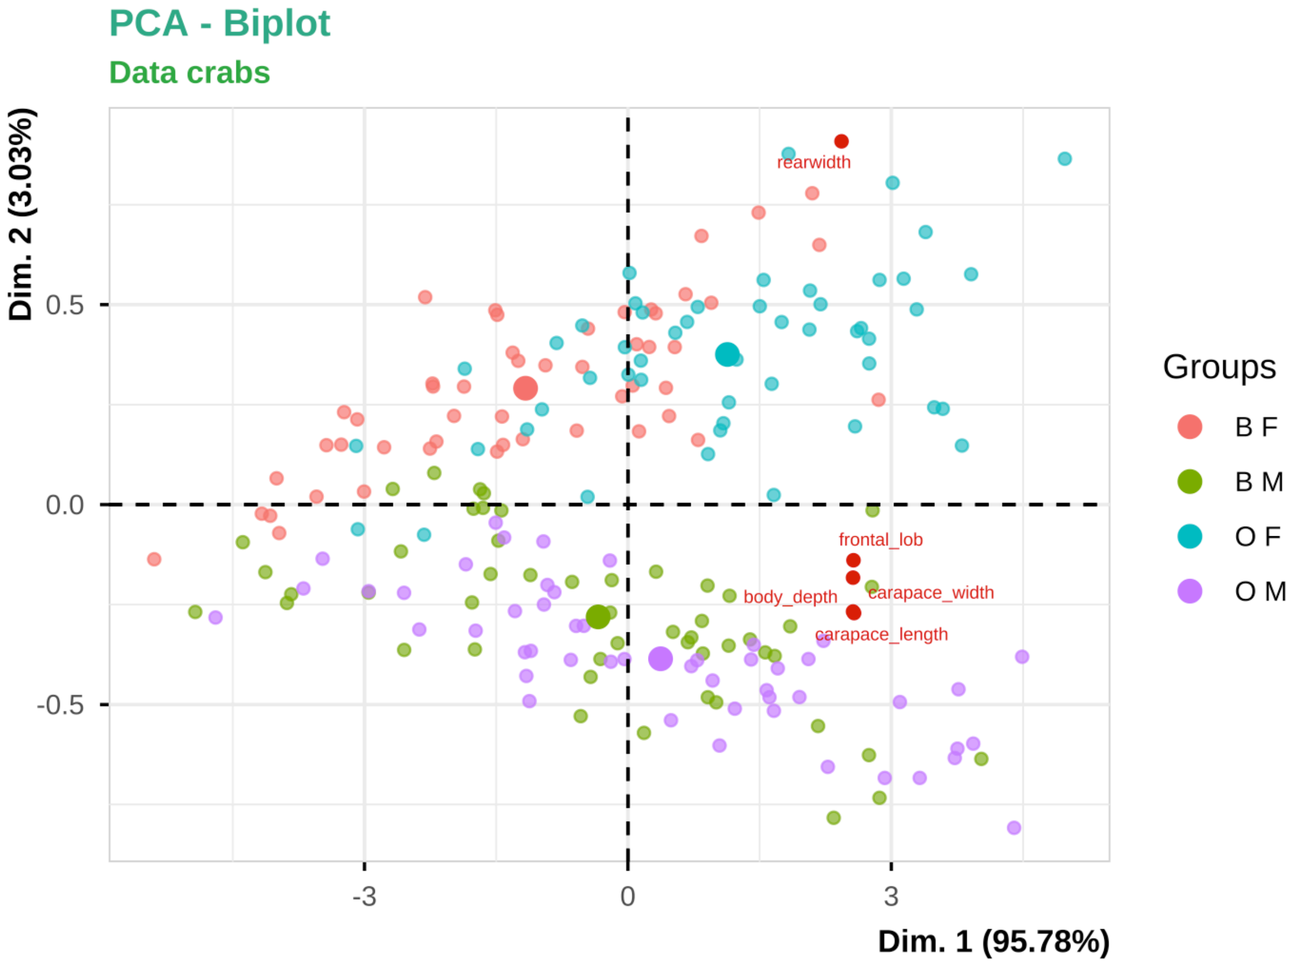
Biplot (1)

```
fviz_pca_biplot(pca.crabs)
```



Biplot (2)

```
fviz_pca_biplot(pca.crabs, col.ind = paste(crabs$species, crabs$sex))
```



Plan

1. Problèmes & Objectifs

2. Axes principaux & Maximisation de variances

3. Représentations & Interprétations

   (a) Qualité de la reconstruction

   (b) Étude du nuage des individus

   (c) Étude du nuage des variables

   (d) Description des dimensions

4. D'autres types de données, d'autres analyses statistiques

Description des dimensions

- Par des variables quantitatives.
  - Calcul du coefficient de corrélation entre chaque variable et les coordonnées des individus sur un axe.
    - Tri des coefficients de corrélation ;
    - Les coefficients de corrélation significativement différents de 0 sont fournis.

- Par des variables qualitatives.
  - Analyse de variance avec les coordonnées des individus en fonction de la variable qualitative.
    - Un test-F par variable ;
    - Un test-t de Student par modalité pour comparer la moyenne de la modalité à la moyenne générale.

Description des dimensions : Exemple du 1er axe factoriel

```
dimdesc(pca.crabs, axes = 1)
```

```
$Dim.1

Link between the variable and the continuous variables (R-square)
=================================================================================

Link between the variable and the categorical variable (1-way anova)
=============================================
          R2      p.value
1.182418e-01 6.185250e-07

Link between variable and the categories of the categorical variables
================================================================
            Estimate     p.value
species=0  0.7524895 6.18525e-07
species=B -0.7524895 6.18525e-07
```

	correlation <dbl>	p.value <dbl>	n <dbl>
carapace_length	0.9917363	1.516200e-178	200
frontal_lob	0.9892256	3.424057e-167	200
body_depth	0.9872340	6.092697e-160	200
carapace_width	0.9871883	8.656845e-160	200
rearwidth	0.9367791	3.070897e-92	200

Plan

1. Problèmes & Objectifs

2. Axes principaux & Maximisation de variances

3. Représentations & Interprétations

4. D'autres types de données, d'autres analyses statistiques

Autres analyses statistiques linéaires dans l'exploration de données

Type de données	Méthodes linéaires classiques
2 variables binaires (table de contingence)	Analyse des correspondances (CA)
Variables catégorielles	Analyse des correspondances multiples (MCA)
Données mixtes	Analyse des factorielles multiples (MFA)
Si les relations entre variables ne sont pas linéaires	Méthodes non-linéaires comme Multidimensionnal scaling (MDS)

This is the end of this chapter !

What will we do next time ?

Chapitre 4. Classification automatique non-supervisée

Annexes

- Les diapositives suivantes développent différents points non vus en cours.
- Elles peuvent également donner des éléments précisant la compréhension de certaines parties.
- Elles peuvent être passées en première lecture, mais elles restent néanmoins des éléments importants de l'analyse en composantes principales.

Annexes

A. Feuille de route pratique de l'analyse en composantes principales

B. L'ACP vue mathématiquement

Annexes

A. Feuille de route pratique de l'analyse en composantes principales

B. L'ACP vue mathématiquement

Feuille de route pratique

Pour l'analyse en composantes principales :

1. Charger les données, vérifier que les variables sont bien de la nature attendue (qualitative / quantitative).
2. Choisir les variables actives.
3. Choisir de réduire ou non les variables.
4. Réaliser l'ACP sur R.
5. Choisir le nombre de dimensions à interpréter.
6. Interpréter simultanément le graphe des individus et celui des variables.
7. Utiliser les indicateurs pour enrichir l'interprétation.
8. Revenir aux données brutes pour interpréter.

Annexes

A. Feuille de route pratique de l'analyse en composantes principales

B. L'ACP vue mathématiquement

L'ACP vue mathématiquement

- À venir !